

# 有机光电存算一体系统的算法—器件协同设计 研究

硕士学位论文草稿

作者：李松桥

导师、学院、学位类别等正式元数据待提交前确认

2026 年 5 月



## 摘 要

存内计算 (Compute-in-Memory, CIM) 架构通过在存储阵列内部直接执行矩阵-向量乘法, 消除了制约传统数字系统的数据搬运瓶颈。在诸多新兴器件路线中, 有机光电子器件凭借其多级电导可调性、低压操作与本征光敏性, 为神经形态视觉系统提供了独特的物理载体。然而, 将器件级进展转化为系统级视觉性能, 仍面临器件变异性、有限模数转换器 (Analog-to-Digital Converter, ADC) 精度、保留漂移及跨制造实例可迁移性等关键挑战。

本研究建立了一个面向有机光电子存内计算阵列的可复用硬件感知训练 (Hardware-Aware Training, HAT) 仿真框架, 支持具有真实器件非理想性的视觉 Transformer (Vision Transformer, ViT) 与卷积神经网络 (Convolutional Neural Network, CNN)。该框架采用配置文件驱动设计, 可将文献报道的器件特性 (电导窗口、周期到周期变异性、器件到器件失配、保留动力学、光响应非线性、写入非线性) 映射为任务级视觉精度。

实验首先系统评估了 ResNet-18、ConvNeXt-Tiny 与 Tiny-ViT-5M 在 CIFAR-10、CIFAR-100、Flowers-102 及 ImageNet-1k 上的 baseline 精度。在此基础上, 本研究提出 HAT 训练范式的系统分类学, 并发现硬件实例过拟合现象: 标准固定掩膜 HAT 在训练时硬件实例上表现良好, 但在全新器件失配实例上崩溃至接近随机水平 (CIFAR-10 上  $10.00 \pm 0.00\%$ )。为应对此问题, 本研究提出 Ensemble HAT——在每个训练轮次边界重采样结构化器件到器件 (Device-to-Device, D2D) 失配场——将 fresh-instance 精度恢复至  $86.16 \pm 0.19\%$ 。

进一步地, 本研究构建了面向有机光电子 CIM 部署的失效模式图谱 (failure mode atlas), 系统刻画了五种可复现的失效模式及其边界: (1) 硬件实例过拟合与 Ensemble HAT 缓解; (2) 严重写入非线性 ( $NL = 2.0$ ) 下的双注意力通路崩溃; (3) 多层感知机 (Multi-Layer Perceptron, MLP) 线性补偿的 32% fresh-instance 诊断上界; (4) 空间相关 D2D 的有界退化; (5) 保留漂移的 79% 渐近平台期。所有失效模式均通过严格的负结果 (negative results) 加以界定, 从而将瓶颈定位为结构性泛化障碍而非优化缺口。

本研究的贡献包括: (1) 一个可复用、可扩展的有机光电子 CIM 仿真框架; (2) HAT 范式的系统分类学与硬件实例过拟合的发现; (3) 一个受经验数据约束的部署包络, 明确了哪些噪声模型与训练干预组合能够迁移至新硬件实例、哪些不能。这些结果为有机光电子神经形态硬件的算法-器件协同设计提供了系统级决策依据。

**关键词:** 存内计算; 硬件感知训练; 视觉 Transformer; 有机光电子器件; 硬件实例过拟合



# Abstract

Compute-in-memory (CIM) architectures eliminate the data-movement bottleneck of conventional digital systems by performing matrix–vector multiplications directly inside memory arrays. Among emerging device routes, organic optoelectronic devices offer a distinctive physical substrate for neuromorphic vision systems thanks to their multi-level conductance tunability, low-voltage operation, and intrinsic photosensitivity. Yet translating device-level progress into system-level visual performance remains hindered by device variability, limited analog-to-digital converter (ADC) resolution, retention drift, and cross-fabrication-instance transferability.

This thesis presents a reusable hardware-aware training (HAT) simulation framework for organic optoelectronic CIM arrays that supports vision transformers (ViT) and convolutional neural networks (CNN) under realistic device non-idealities. The framework adopts a profile-driven design that maps literature-reported device characteristics—conductance window, cycle-to-cycle variability, device-to-device (D2D) mismatch, retention dynamics, photoresponse nonlinearity, and write nonlinearity—into task-level visual accuracy.

Experiments first systematically evaluate ResNet-18, ConvNeXt-Tiny, and Tiny-ViT-5M on CIFAR-10, CIFAR-100, Flowers-102, and ImageNet-1k. Building on these baselines, the thesis introduces a taxonomy of HAT regimes and discovers *hardware-instance overfitting*: standard fixed-mask HAT performs well on the training-time hardware instance yet collapses to near-chance level on fresh mismatch realizations ( $10.00 \pm 0.00\%$  on CIFAR-10). To address this, the thesis proposes Ensemble HAT, which resamples structured D2D mismatch fields at epoch boundaries during training, recovering fresh-instance accuracy to  $86.16 \pm 0.19\%$ .

Furthermore, the thesis constructs a *failure mode atlas* for organic optoelectronic CIM deployment, systematically cataloguing five reproducible breakdown patterns and their boundaries: (1) hardware-instance overfitting and its Ensemble HAT remedy; (2) dual-attention-pathway collapse under severe write nonlinearity ( $NL = 2.0$ ); (3) the 32% fresh-instance diagnostic ceiling of MLP-only linearization; (4) bounded degradation under spatially correlated D2D; (5) the 79% asymptotic retention plateau. Each failure mode is bounded by rigorous negative results, locating bottlenecks as structural generalization barriers rather than optimization gaps.

Contributions include: (1) a reusable, extensible simulation framework for organic optoelectronic CIM; (2) a taxonomy of HAT regimes and the discovery of hardware-instance

overfitting; (3) an empirically constrained deployment envelope that delineates which noise-model and training-intervention combinations transfer to new hardware instances and which do not. These results provide system-level decision support for algorithm–device co-design of organic optoelectronic neuromorphic hardware.

**Keywords:** compute-in-memory; hardware-aware training; vision transformer; organic optoelectronic device; hardware-instance overfitting

## 致 谢

本研究在课题组的持续讨论、计算资源支持与多轮论文审阅中逐步完成。

衷心感谢导师在整个研究过程中给予的悉心指导与学术启发。感谢实验室同门在器件表征、仿真调试与论文写作中提供的宝贵建议与无私帮助。感谢相关合作团队在有机光电子器件制备、测量与建模讨论方面提供的支持。

最后，感谢家人在求学期间给予的持续理解与鼓励。

李松桥

2026 年 5 月



# 目录

|                               |     |
|-------------------------------|-----|
| 摘要                            | i   |
| Abstract                      | iii |
| 致谢                            | v   |
| 第一章 引言：硬件感知训练与硬件实例过拟合         | 1   |
| 1.1 研究背景                      | 1   |
| 1.1.1 有机光电子存内计算               | 1   |
| 1.1.2 硬件感知训练                  | 1   |
| 1.1.3 视觉 Transformer 的混合部署    | 1   |
| 1.2 问题陈述：从器件到系统的翻译鸿沟          | 2   |
| 1.3 研究贡献                      | 2   |
| 1.4 “10 % 崩溃”现象               | 3   |
| 1.4.1 核心实验观察                  | 3   |
| 1.4.2 方法论意义                   | 3   |
| 1.5 硬件实例过拟合的机制                | 4   |
| 1.6 Ensemble HAT：分布级训练目标      | 4   |
| 1.6.1 期望形式化                   | 4   |
| 1.6.2 优化稳定性与迁移保证的权衡           | 4   |
| 1.7 对后续章节的启示                  | 5   |
| 第二章 相关工作                      | 7   |
| 2.1 存内计算模拟器与混合映射              | 7   |
| 2.1.1 系统级 CIM 评估层次            | 7   |
| 2.1.2 IBM AIHWKit 与批次级随机变异性   | 7   |
| 2.1.3 MemTorch 与 PyTorch 原生嵌入 | 7   |
| 2.1.4 CrossSim 与 GPU 加速查表训练   | 8   |
| 2.2 有机神经形态与光电子器件              | 8   |
| 2.2.1 器件特性与近期进展               | 8   |
| 2.2.2 从器件到网络的鸿沟               | 8   |
| 2.3 视觉 Transformer 与混合映射策略    | 9   |
| 2.3.1 ViT 的模拟部署挑战             | 9   |

|            |                           |           |
|------------|---------------------------|-----------|
| 2.3.2      | 低精度 ViT 量化的启示             | 9         |
| 2.4        | 域随机化与 sim-to-real 迁移      | 9         |
| 2.5        | 领域空白与本研究定位                | 9         |
| 2.5.1      | 现有工具链的局限                  | 9         |
| 2.5.2      | 本研究的定位                    | 10        |
| 2.5.3      | 有机光电子 CIM 的系统级评估空白        | 10        |
| <b>第三章</b> | <b>方法论：配置文件驱动硬件感知训练框架</b> | <b>11</b> |
| 3.1        | 引言：HAT 作为设计空间             | 11        |
| 3.2        | 配置文件驱动的仿真框架               | 11        |
| 3.2.1      | 设计原则：从测量实验室到算法训练循环的桥梁     | 11        |
| 3.2.2      | 器件配置文件作为结构化配置对象           | 11        |
| 3.2.3      | 器件变异性：D2D 与 C2C           | 12        |
| 3.2.4      | 非线性写入非对称性                 | 12        |
| 3.2.5      | 保留漂移                      | 13        |
| 3.2.6      | 光电子前端补偿                   | 13        |
| 3.2.7      | ADC 量化与外围非理想性             | 13        |
| 3.2.8      | PCM 器件模型集成 (AIHWKit)      | 14        |
| 3.3        | PyTorch 自动微分集成            | 14        |
| 3.3.1      | 直通估计器量化器                  | 14        |
| 3.3.2      | 差分对电导映射                   | 15        |
| 3.3.3      | 前向路径噪声注入                  | 16        |
| 3.3.4      | 模型转换与层替换                  | 16        |
| 3.4        | HAT 重采样频率的形式化定义           | 16        |
| 3.4.1      | 固定掩膜 HAT                  | 17        |
| 3.4.2      | Ensemble HAT (轮次级重采样)     | 17        |
| 3.4.3      | 每批次重采样                    | 17        |
| 3.4.4      | 三种体制的可视化比较                | 17        |
| 3.5        | Ensemble 频率扫描：频率消融        | 18        |
| 3.5.1      | 实验协议                      | 18        |
| 3.5.2      | 结果                        | 19        |
| 3.5.3      | 解读：为何轮次级重采样胜出             | 19        |
| 3.6        | 噪声轮廓靶向：均匀、比例与混合           | 20        |
| 3.6.1      | 均匀（加性）噪声                  | 20        |
| 3.6.2      | 比例（状态相关）噪声                | 20        |
| 3.6.3      | 混合轮廓                      | 20        |
| 3.6.4      | 体制匹配训练与跨体制崩溃              | 21        |
| 3.7        | 核心洞见：重采样频率作为隐式迁移保证        | 21        |

|            |                                      |           |
|------------|--------------------------------------|-----------|
| 3.7.1      | 固定掩膜 HAT: 单例保证                       | 21        |
| 3.7.2      | 每批次 HAT: 乘积分布保证                      | 21        |
| 3.7.3      | 轮次级 HAT: 块平稳保证                       | 22        |
| 3.7.4      | 噪声轮廓匹配作为分布对齐条件                       | 22        |
| 3.8        | 评估协议                                 | 22        |
| 3.8.1      | 源域评估 (Source-domain evaluation)      | 22        |
| 3.8.2      | Fresh-instance 评估                    | 22        |
| 3.8.3      | 跨数据集评估 (Cross-dataset evaluation)    | 23        |
| 3.9        | 本章小结                                 | 23        |
| <b>第四章</b> | <b>基准实验</b>                          | <b>27</b> |
| 4.1        | 引言                                   | 27        |
| 4.2        | 实验设置与评估协议                            | 27        |
| 4.2.1      | 模型与数据集                               | 27        |
| 4.2.2      | 评估体制定义                               | 27        |
| 4.2.3      | Fresh-Instance 协议                    | 28        |
| 4.3        | CIFAR-10/100 基准结果                    | 28        |
| 4.3.1      | ResNet-18                            | 28        |
| 4.3.2      | ConvNeXt-Tiny                        | 29        |
| 4.3.3      | Tiny-ViT V1-V6                       | 29        |
| 4.4        | 跨数据集评估                               | 30        |
| 4.4.1      | Flowers-102: 数据稀缺场景                  | 30        |
| 4.4.2      | ImageNet-1k: 大规模验证                   | 31        |
| 4.5        | Fresh-Instance 评估                    | 31        |
| 4.5.1      | Tiny-ViT V4: 标准 HAT 的崩溃              | 31        |
| 4.5.2      | ConvNeXt C4 的 Fresh-Instance 行为      | 32        |
| 4.6        | PCM 器件真实感基准测试                        | 32        |
| 4.6.1      | 实验设置                                 | 32        |
| 4.6.2      | 精度—保持阶梯 (Precision-Retention Ladder) | 32        |
| 4.6.3      | 扩展验证: 预设独立性与噪声必要性                    | 33        |
| 4.6.4      | 负面基线与消融                              | 33        |
| 4.6.5      | 扩展漂移评估                               | 34        |
| 4.7        | 讨论与小结                                | 34        |
| 4.7.1      | 架构比较的三条规律                            | 34        |
| 4.7.2      | 本章小结                                 | 34        |

|                                                   |           |
|---------------------------------------------------|-----------|
| <b>第五章 失效模式与诊断框架</b>                              | <b>37</b> |
| 5.1 引言：从症状到机制                                     | 37        |
| 5.2 失效模式分类学                                       | 37        |
| 5.2.1 模式一：硬件实例过拟合 (Hardware-Instance Overfitting) | 37        |
| 5.2.2 模式二：尺度掩蔽区 (Scale-Masking Regime)            | 38        |
| 5.2.3 模式三：ADC 精度悬崖                                | 38        |
| 5.2.4 模式四：空间相关 D2D 退化                             | 38        |
| 5.2.5 模式五：保持漂移                                    | 39        |
| 5.2.6 模式六：严重非线性写入                                 | 39        |
| 5.2.7 模式七：精度-漂移权衡 (Precision-Retention Trade-off) | 40        |
| 5.2.8 模式间耦合与复合应力                                  | 40        |
| 5.3 诊断协议                                          | 40        |
| 5.3.1 协议 A：快速实例级筛选                                | 40        |
| 5.3.2 协议 B：模块级瓶颈定位                                | 41        |
| 5.3.3 协议 C：参数敏感性排序                                | 41        |
| 5.3.4 协议 D：时序退化特征提取                               | 41        |
| 5.4 案例研究                                          | 42        |
| 5.4.1 案例一：从 10% 到 86%——实例过拟合的治愈                   | 42        |
| 5.4.2 案例二：OPECT 零样本迁移                             | 42        |
| 5.4.3 案例三：严重 NL 下的 M 系列证据                         | 42        |
| 5.4.4 案例四：比例噪声的体制特异性                              | 43        |
| 5.5 本章小结与向第六章的过渡                                  | 43        |
| <b>第六章 大语言模型 KV 缓存的有机光电存内计算映射</b>                 | <b>45</b> |
| 6.1 研究动机                                          | 45        |
| 6.1.1 大语言模型推理的存储瓶颈                                | 45        |
| 6.1.2 现有数字方案的固有折衷                                 | 45        |
| 6.1.3 KV 缓存与注意力机制的计算特征                            | 46        |
| 6.1.4 存内计算的技术机遇                                   | 47        |
| 6.2 有机光电 CIM 的物理匹配性                               | 47        |
| 6.2.1 KV 缓存的访问模式特征                                | 47        |
| 6.2.2 存储技术的保持时间—耐久性匹配分析                           | 48        |
| 6.2.3 光学刷新的独特优势                                   | 49        |
| 6.3 问题定义与核心假设                                     | 50        |
| 6.3.1 形式化问题陈述                                     | 50        |
| 6.3.2 核心假设                                        | 50        |
| 6.3.3 与现有工作的区别                                    | 51        |
| 6.4 目标模型与评估框架                                     | 52        |

|            |                                  |           |
|------------|----------------------------------|-----------|
| 6.4.1      | 目标模型选择                           | 52        |
| 6.4.2      | 评估指标                             | 53        |
| 6.4.3      | 对比基线                             | 54        |
| 6.5        | 实验设计详述                           | 55        |
| 6.5.1      | 实验一：注意力对模拟 KV 存储的噪声鲁棒性           | 55        |
| 6.5.2      | 实验二：架构探索与帕累托分析                   | 56        |
| 6.5.3      | 实验三：KV 缓存压缩与有机模拟协同设计             | 57        |
| 6.5.4      | 实验四：时间动态与刷新策略                    | 58        |
| 6.5.5      | 实验结果：Remote 107 阶段性验证            | 59        |
| 6.6        | 预期贡献与创新点                         | 61        |
| 6.7        | 范围边界与明确排除项                       | 62        |
| 6.8        | 本章小结与向第七章的过渡                     | 64        |
| <b>第七章</b> | <b>部署包络</b>                      | <b>67</b> |
| 7.1        | 部署场景定义                           | 67        |
| 7.1.1      | 目标应用：边缘视觉推理                      | 67        |
| 7.1.2      | CIM 阵列规模与外围约束                    | 67        |
| 7.1.3      | 功耗约束与刷新策略                        | 68        |
| 7.2        | ADC 分辨率包络                        | 69        |
| 7.2.1      | 6-bit 悬崖：量化主导区与 D2D 主导区的分界       | 69        |
| 7.2.2      | Sobol 全局敏感度分解                    | 70        |
| 7.2.3      | ADC 非理想性的边际效应                    | 70        |
| 7.3        | D2D 失配包络                         | 70        |
| 7.3.1      | 固定掩膜 HAT 的硬件实例过拟合                | 70        |
| 7.3.2      | Ensemble HAT 的跨实例统计              | 70        |
| 7.4        | 噪声-非线性权衡                         | 71        |
| 7.4.1      | 严重非线性写入的恢复带                      | 71        |
| 7.4.2      | 从 $NL = 1.0$ 到 $NL = 2.0$ 的系统性退化 | 72        |
| 7.5        | 跨器件零样本迁移                         | 72        |
| 7.5.1      | 文献标定器件：OPECT 代理                  | 72        |
| 7.5.2      | 内部实测器件：Doctor OECT               | 72        |
| 7.5.3      | 跨仿真器验证：CrossSim 基准               | 72        |
| 7.6        | 跨架构验证                            | 73        |
| 7.7        | 部署建议与风险排序                        | 74        |
| 7.7.1      | 三级成熟度决策矩阵                        | 74        |
| 7.7.2      | 风险排序：非协商项与可协商项                   | 75        |
| 7.7.3      | 对项目管理者行动清单                       | 75        |
| 7.7.4      | 包络的显式边界                          | 76        |

|                      |           |
|----------------------|-----------|
| <b>第八章 展望与结论</b>     | <b>77</b> |
| 8.1 研究总结 . . . . .   | 77        |
| 8.2 未来研究方向 . . . . . | 77        |
| 8.3 结论 . . . . .     | 79        |

# 第一章 引言：硬件感知训练与硬件实例过拟合

## 1.1 研究背景

### 1.1.1 有机光电子存内计算

存内计算 (Compute-in-Memory, CIM) 架构通过在存储阵列内部直接执行稠密矩阵-向量乘法, 消除了制约传统数字系统的数据搬运瓶颈<sup>1-3</sup>。在静态随机存取存储器 (SRAM) 与新兴阻变存储器之外, 有机光电子器件 (organic optoelectronic devices) 凭借其多级电导可调性、低压操作特性以及本征光敏性, 为直接光学信号处理提供了新的物理载体<sup>4-6</sup>。近期实验进展涵盖了模拟电导态<sup>5,7</sup>、长保留尾迹<sup>8</sup>, 以及集成式光电子突触阵列<sup>9-11</sup>。

然而, 将这些器件级进展转化为系统级视觉性能, 仍面临关键的方法论鸿沟。有机光电子文献仍以器件中心表征为主导<sup>12</sup>: 网络级研究多局限于小型基准或简单感知机, 而变异性、模数转换器 (Analog-to-Digital Converter, ADC) 分辨率、保留诱导漂移, 以及跨制造实例的可迁移性等问题, 在系统分析中或完全缺失, 或仅被定性讨论<sup>7,8</sup>。最具相关性的前期工作是 Lin *et al.* 的蒙特卡罗研究, 其为简单的有机阻变感知机采样了器件参数<sup>13</sup>, 但尚未形成将现代视觉主干网络映射至有机阵列的完整框架。

### 1.1.2 硬件感知训练

硬件感知训练 (Hardware-Aware Training, HAT, 硬件感知训练) 通过在优化前向路径中注入器件扰动, 来缓解模拟非理想性的影响<sup>14</sup>。尽管其在精神上与量化感知训练 (Quantization-Aware Training, QAT, 量化感知训练)<sup>15</sup> 以及 sim-to-real 迁移中的域随机化 (domain randomization, 域随机化)<sup>16</sup> 相关, CIM 场景下的 HAT 面临额外困难: 器件间失配 (device-to-device mismatch, D2D 失配) 具有空间结构性, 且在单个硬件实例上固定不变, 不同于独立的热噪声或采样噪声。标准 HAT 通常在整个训练过程中保持一张随机 D2D 掩膜固定不变。如后文所示, 这一选择会使模型拟合特定硬件实例而非部署分布, 在迁移至新实例时导致灾难性精度崩溃。

### 1.1.3 视觉 Transformer 的混合部署

在 CIM 语境下, 稠密线性算子天然适合映射至交叉阵列 (crossbar), 而深度可分离卷积及高度不规则的算子往往利用率低下<sup>17-19</sup>。近期面向视觉 Transformer (Vision Transformer, ViT, 视觉 Transformer) 的异构 CIM 加速器证实了这一定势: 线性投影 (query-key-value, Q/K/V, 输出层、前馈层) 被映射至模拟阵列, 而注意力分数、softmax 归一化及其他动态交互则因精度要求和 irregular 访问模式而保留在数字域<sup>20,21</sup>。本研究采用的混合逻辑 (hybrid mapping, 混合映射) 与此一致, 具体层划分见第三章。

## 1.2 问题陈述：从器件到系统的翻译鸿沟

有机光电子存内计算系统通常通过器件级品质因数 (figures of merit) 加以介绍：电导窗口、保留时间、写入非对称性以及光响应度。这些指标是必要的，但不足以回答对部署真正重要的系统问题：当现代视觉主干网络被映射至具有结构性失配和有限读出精度的模拟阵列时，究竟有多少精度能够存活？本研究将这一问题视为材料到系统的翻译问题，而非纯粹的器件问题。

研究的出发点是在全文中使用的 canonical HAT 训练范式。在训练时所见的硬件实例上进行 nominal 评估时，HAT 看似有效：混合 Tiny-ViT (Tiny Vision Transformer) 在 canonical 模拟噪声模型下恢复了大部分源域 (source-domain, 训练域) 精度。然而，这种表面上的成功具有误导性。当训练好的模型在全新硬件实例 (fresh hardware instance, 即从相同分布中采样的新固定 D2D 失配实现) 上评估时，标准 HAT 模型崩溃至接近随机水平。这表明标准 HAT 的鲁棒性局限于训练时实例本身，而非部署分布——对模拟噪声的鲁棒性与对硬件实例偏移的鲁棒性并非同一回事。

一个自然的假设是：保护多层感知机 (Multi-Layer Perceptron, MLP) 模块，同时对器件噪声进行重采样，或许能够打破这一天花板。第 5 章报告了该假设的证伪结果：三项独立训练干预在严重非线性 (nonlinearity, NL) 条件下均收敛于约 32.6% 的全新实例精度 (参见 `nl_fresh_instance_controls_all_only_20260418.json`)，这表明瓶颈存在于注意力通路 (attention pathway) 中的结构性泛化障碍，而非优化缺口。

## 1.3 研究贡献

本研究贡献可归纳为以下三方面：

- 1. 可复用的仿真框架：**建立了面向有机光电子存内计算阵列的 HAT 训练仿真框架，支持具有真实器件非理想性的视觉 Transformer，并通过可替换的器件配置文件 (device profile, 器件配置文件) 接口将文献报道的器件特性映射至任务级视觉精度。
- 2. HAT 范式分类与硬件实例过拟合的发现：**提出了 HAT 训练范式的系统分类学，并发现硬件实例过拟合 (hardware-instance overfitting, 硬件实例过拟合) 现象——即固定掩膜训练产生的模型会记忆特定的器件失配实现，并在全新硬件实例上崩溃至随机水平。在 CIFAR-10 上，固定掩膜标准 HAT 的 fresh-instance 精度为 10.00% (参见 `fresh_instance_eval.json`)，而 Ensemble HAT 将其提升至  $86.16 \pm 0.19\%$ 。
- 3. 部署包络与结构性泛化边界的建立：**系统映射了哪些噪声模型与训练干预组合能够迁移至新硬件实例、哪些不能，包括严格的负结果 (negative results) 以证伪自然的缓解假设，从而确立结构性泛化障碍而非优化缺口。例如，在严重写入非线性 ( $NL = 2.0$ ) 条件下，源域救援精度可达 87.79% (MLP-only 线性补偿) 和 87.49% (全线性补偿)，但 fresh-instance 迁移仍停留在  $32.60 \pm 9.18\%$ ；对应的非线性缓解与 fresh-instance 控制实验记录在论文源数据的 JSON 汇总文件中。




图 1.1: Fresh-instance 迁移对比（复用自论文补充材料）。标准 HAT 对单张结构性失配场过拟合，而 Ensemble HAT 在硬件实例分布上学习。

## 1.4 “10% 崩溃”现象

### 1.4.1 核心实验观察

决定本研究走向的实验观察十分简洁：采用单张固定 D2D 掩膜训练的标准 HAT 模型，在训练时实例上可达较高的源域精度（Tiny-ViT V4 在 CIFAR-10 上最佳测试精度为 91.94%，参见 `noise_sweep_results_gpt.json`），然而其全新实例精度崩溃至约 10.00%——即 CIFAR-10 的单类基线水平。相比之下，Ensemble HAT 变体在三种子汇总协议下将 fresh-instance 精度提升至  $86.16 \pm 0.19\%$ ；单个检查点的全新实例评估仍采用 10 个硬件实例、每实例 5 次蒙特卡罗运行的协议。这一差距过于悬殊，无法以普通随机波动解释；它反映了训练目标在部署偏移下的结构性失效。

图 1.1 复用了论文中的 fresh-instance 迁移可视化，展示了标准 HAT 与重采样替代方案之间的差异。关键不在于一条曲线低于另一条，而在于固定掩膜模型表现得如同针对某一特定硬件实现过拟合的估计器。一旦该实现改变，其校准（calibration）和已学习的特征路由便不再有效。

### 1.4.2 方法论意义

这一崩溃现象在方法论上亦有启示。它表明模拟部署实验必须区分三种评估体制：

1. **源域精度**（source-domain accuracy）：在训练时实例上的精度；
2. **重复蒙特卡罗精度**（repeated Monte Carlo accuracy）：在同一实例上多次前向运行的平均精度；
3. **迁移精度**（transfer accuracy）：在新采样阵列上的精度。

只有第三种量才能回答实际的部署问题。这一区分将贯穿全文，尤其体现在后续关于严重写入非线性和空间相关失配的章节中。

第二个推论是，fresh-instance 评估协议（10 个实例  $\times$  5 次蒙特卡罗运行）本身成

为判断缓解策略是否达到部署级标准的标准工具。在此视角下，Ensemble HAT 属于面向部署的干预措施，而后续的严重非线性补偿策略则未能完全达到这一标准。

## 1.5 硬件实例过拟合的机制

在固定掩膜 HAT 中，优化器面对的是一个与特定失配场  $M_0$  耦合的前向路径。模型通过尺度恢复与阵列特定校准将权重分布与  $M_0$  的局部偏差协同调整，在  $M_0$  上获得高精度；然而，这种调整本质上是记忆而非泛化。当部署阵列呈现来自  $p(M)$  的不同固定实现  $M'$  时，为  $M_0$  学习的校准不再有效，精度随之崩溃（第 5 章给出完整分类学诊断）。固定掩膜模型在训练实例上的源域精度可达 91.94%，但在全新阵列上崩溃至 10.00%，表明其鲁棒性完全局限于训练时实例本身。

## 1.6 Ensemble HAT：分布级训练目标

### 1.6.1 期望形式化

Ensemble HAT 的核心思想是将训练目标从单实例风险最小化转变为对失配分布的期望最小化。在固定掩膜 HAT 中，目标为

$$\theta_{\text{fix}}^* = \arg \min_{\theta} \frac{1}{N} \sum_{n=1}^N \ell(f(x_n; \theta, M_0), y_n), \quad (1.1)$$

其中  $M_0$  为训练前采样并保持不变的单张 D2D 实现。

Ensemble HAT 则在每个训练轮次（epoch）边界重采样结构化 D2D 失配场，目标变为

$$\theta_{\text{ens}}^* = \arg \min_{\theta} \mathbb{E}_{M \sim p(M)} \left[ \frac{1}{N} \sum_{n=1}^N \ell(f(x_n; \theta, M), y_n) \right]. \quad (1.2)$$

由于每轮次开始时抽取一张新图，模型在训练过程中接触序列  $\{M^{(1)}, M^{(2)}, \dots, M^{(E)}\}$  中的多个结构化空间实例。该期望通过  $E$  次独立采样进行蒙特卡罗估计， $E$  为训练轮次数。关键的是，同一轮次内的小批量梯度在相同  $M^{(e)}$  下相关，因此优化器拥有足够的平稳步数来适应该实例的特征提取，再于轮次切换时接触新实例。

### 1.6.2 优化稳定性与迁移保证的权衡

轮次级重采样（epoch-level resampling）在优化稳定性与分布覆盖之间取得了最佳权衡。探索性的 50 轮次 held-out 扫描（参见 `ensemble_frequency_ablation.json`）显示，轮次级重采样（88.41%）优于固定掩膜（87.18%）和每批次重采样（86.16%），即使在弱化训练预算下相对顺序仍成立（第 3 章给出完整频率消融）。

每批次重采样虽然暴露模型于更多 D2D 多样性，却反而表现更差，这说明优化器需要足够长的时间在单一结构化实例下学习兼容的特征，然后再通过足够多样的实例来泛化至整个分布。固定掩膜训练拥有不受限的单实例时间，因此源域精度高，但缺乏分

布广度。轮次级重采样正好处于最优平衡点：每个轮次提供足够的稳定性使优化器下降，而轮次序列提供足够的分布广度以防止实例特定过拟合。

## 1.7 对后续章节的启示

为使上述论断可证伪，本章后续将引入贯穿全文的仿真框架。后续章节将界定严重非线性 (severe nonlinearity) 源域救援的上界：MLP-only 线性补偿可达 87.79%，全线性补偿可达 87.49% (见 NL 缓解汇总记录)，而 fresh-instance 迁移仍停留在  $32.60 \pm 9.18\%$  (见 NL fresh-instance 控制评估记录)。

第 3 章将系统阐述 HAT 范式的分类学，形式化定义固定掩膜、轮次级和每批次三种 canonical 协议，并将重采样频率解释为隐式的迁移保证。第 4 章将进一步探讨不同失效模式 (failure modes) ——从 ADC 精度悬崖到光响应前端畸变——如何与硬件实例过拟合相互作用。第 6 章将在物理真实感扩展 (相关 D2D、保留漂移) 下验证块平稳保证 (block-stationary guarantee) 的稳健性。最终，第 7 章将尝试联合训练实验，以耦合替代模型保真度修复与部署不变性。



## 第二章 相关工作

### 2.1 存内计算模拟器与混合映射

#### 2.1.1 系统级 CIM 评估层次

存内计算 (CIM) 仿真工具链的建立遵循从器件到系统的层次化模板: 器件模型 feeding 电路模型, 电路模型 feeding 架构模型, 最终报告精度、能耗与面积。DNN+NeuroSim 是这一样板的奠基工作, 其支持完整的片上训练, 并已与 fabricated macro 进行验证<sup>2</sup>。在这一层次结构中, 硬件感知训练 (Hardware-Aware Training, HAT, 硬件感知训练) 以训练层选项的形式出现, 但标准 DNN+NeuroSim 工作流并不强调 fresh-instance 迁移: D2D 失配通常被视为一次性制造扩散, 训练好的模型在与其训练时相同的扩散上进行评估。本研究因此扩展了 DNN+NeuroSim 的哲学, 将 fresh-instance 协议作为标准评估原语纳入。

#### 2.1.2 IBM AIHWKit 与批次级随机变异性

IBM 的 AIHWKit 提供了与 PyTorch 集成的模拟交叉阵列仿真工具包, 支持硬件感知训练<sup>22</sup>。其噪声模型实用且经过良好校准, 主要针对相变存储器 (PCM) 与阻变存储器 (ReRAM) 器件。在底层实现中, AIHWKit 注入每批次权重噪声 (per-batch weight noise), 并支持 per-tile 变异性, 但并未暴露一种 canonical 基线来针对每个硬件实例重采样完整的结构化 D2D 失配图。作为方法一致性检验, 在共享体制 (shared regime) 下——4 位权重、 $\sigma = 5\%$  噪声——数字基线达到 95.46%, 而 AIHWKit 模拟瓦片基线达到  $90.08 \pm 0.21\%$  (10 次运行, 参见 `framework_comparison.json`)。这一结果仅用于验证本文模拟器与成熟无机工具包在单一匹配体制下的数值一致性; 它并不为保留、光响应或有机非线性写入建立物理验证。因此, 本框架并非声称在数字基准上 outperform 成熟的 RRAM 模拟器, 而是作为补充工具, 专门用于暴露有机特异性物理非理想性的系统级后果。

#### 2.1.3 MemTorch 与 PyTorch 原生嵌入

MemTorch 展示了如何将忆阻器非理想性嵌入 PyTorch 工作流以进行端到端评估<sup>23</sup>。其器件模块在概念上与本文使用的配置文件接口相似, 但面向丝状 ReRAM 而非有机光电子电导调控。MemTorch 中的频率讨论针对推理时故障注入 (inference-time fault injection), 而非训练时 D2D 重采样。本研究扩展了这一 PyTorch 原生哲学, 将重采样频率 (resampling cadence, 重采样频率) 作为一等训练超参数。

### 2.1.4 CrossSim 与 GPU 加速查表训练

CrossSim 提供了 GPU 加速的交叉阵列精度 workflow，涵盖寄生电阻、ADC 模型与漂移<sup>24</sup>。其训练模型基于查表 (lookup-table) 而非直通估计器 (Straight-Through Estimator, STE)，这改变了 HAT 的语义：替代模型是预表征的非理想性查表，而非可微噪声注入。CrossSim 因此不直接支持本文开发的轮次级 D2D 重采样协议，因为其查表与特定器件表征绑定。本研究的 STE 方法以部分物理保真度换取梯度路径灵活性，从而实现了作为本章焦点的频率与噪声轮廓扫描。

为验证基线一致性，本文在共享体制 (8 位 ADC、均匀噪声、确定性基线、标准差分映射) 下与 CrossSim 进行了交叉框架比较。在 1,000 张 CIFAR-10 测试子集上，干净基线体制中两框架产出一致：86.2% (本文) 对 83.7% (CrossSim)；在  $\sigma = 5\%$  均匀噪声注入下，预测出现显著分歧： $81.63 \pm 0.56\%$  (本文) 对  $67.20 \pm 2.67\%$  (CrossSim)，差距达 14.43 个百分点 (参见 `crosssim_clean_baseline.json`、`crosssim_standard_noise.json`)。这一分歧恰恰说明：精度预测对噪声到电导映射的具体实现极度敏感——方差以全局窗口还是局部状态为参考、噪声在量化前还是量化后添加、差分对共模抵消如何建模。CrossSim 比较因此作为基线实现的有价值 sanity check，同时确认了有机特异性扩展 (光响应、保留、比例噪声、集成重采样) 代表了超越共享无机工具集的真实能力增量。

## 2.2 有机神经形态与光电子器件

### 2.2.1 器件特性与近期进展

有机突触与忆阻器件为神经形态硬件提供了光学敏感性、多级电导可调性以及柔性基底兼容性<sup>4;6;25;26</sup>。近期实验演示包括多级存储<sup>5;7</sup>、长保留尾迹<sup>8</sup>，以及集成光电子阵列<sup>9;10;27;28</sup>。阵列级研究开始将主动矩阵寻址、空间光学响应与串扰视为系统约束而非纯粹的材料观测<sup>29-31</sup>；耐温有机突触与高温突触光晶体管则表明热稳定性也正成为部署相关因素<sup>32;33</sup>。

### 2.2.2 从器件到网络的鸿沟

尽管器件进展迅速，该文献的主体仍以器件为中心。网络演示往往局限于理想化映射或小型基准，而变异性或完全缺失，或仅被定性处理。在面向有机变异性 aware 仿真的前期工作中，Lin *et al.* 的蒙特卡罗研究为简单有机阻变感知机采样了器件参数<sup>13</sup>。本研究继承了这一变异性 aware 视角，但将其扩展至现代深度学习软件、CIFAR 规模任务，以及更具表达能力的视觉主干网络。

## 2.3 视觉 Transformer 与混合映射策略

### 2.3.1 ViT 的模拟部署挑战

近期异构 CIM 加速器面向视觉 Transformer (Vision Transformer, ViT, 视觉 Transformer) 的映射策略与本研究采用的策略高度趋同: 线性投影 (query-key-value, Q/K/V, 输出层、前馈层) 映射至模拟阵列, 而注意力分数、softmax 归一化及其他动态交互因精度要求和 irregular 访问模式而保留数字域或委托给专用混合信号子路径<sup>20;21</sup>。模拟忆阻器自注意力加速器亦作为竞争方向被探索<sup>34-36</sup>, 但它们依赖与本研究保守混合映射 substantially 不同的硬件分区策略。

### 2.3.2 低精度 ViT 量化的启示

本研究对混合映射的选择与近期低比特 ViT 量化发现收敛: 在激进精度缩减下, 注意力邻接计算被反复识别为尤其敏感<sup>37-39</sup>。将稠密线性算子映射至交叉阵列、将动态注意力乘积保留数字的分割方式, 因此并非本研究模拟器的产物, 而是对交叉阵列权重 stationary 优势与动态、输入依赖算子需求之间错配的广泛采用的架构回应。

## 2.4 域随机化与 sim-to-real 迁移

Ensemble HAT 在概念上与机器人学中的域随机化 (domain randomization, 域随机化) 相关, 后者通过随机化训练环境使策略泛化至真实世界<sup>16</sup>。关键差异在于结构: 域随机化通常随机化独立同分布 (i.i.d.) 的纹理或光照参数, 而 D2D 失配是空间相关的固定场 (spatially correlated fixed field)。本研究中的对比实验表明, 当 D2D 场被替换为每轮次独立采样的 i.i.d. 噪声时, fresh-instance 精度下降至约 87.39% (参见 ensemble\_hat\_ablation\_FIXED.json), 低于结构化重采样的 86.57% 源域表现, 但差距不如空间结构完全丧失时显著。更关键的是, 当 i.i.d. 噪声改为每批次采样时, 精度进一步下降。这确认了空间结构的重要性: Ensemble HAT 不仅仅是“更多噪声增广”, 而是与部署分布的相关结构相匹配的增广。

## 2.5 领域空白与本研究定位

### 2.5.1 现有工具链的局限

面向无机存储器的系统级 CIM 模拟器——DNN+NeuroSim<sup>2</sup>、MemTorch<sup>23</sup>、AIH-WKit<sup>22</sup>、CrossSim<sup>24</sup>——并不直接捕获定义有机光电子推理的耦合光响应、保留与写入非线性。这些成熟模拟器主要围绕无机阻变存储器开发, 而有机特异性扩展——逆伽马 (inverse-gamma) 光响应、双指数保留 (double-exponential retention) ——并非其一等器件原语。

### 2.5.2 本研究的定位

本研究的行为配置文件驱动 (behavioral profile-driven, 行为配置文件驱动) 方法因此作为有机特异性补充, 而非这些无机工具包的直接替代。

- 与 DNN+NeuroSim 相比: 添加了 fresh-instance 协议作为标准评估原语;
- 与 AIHWKit 相比: 暴露了完整结构化 D2D 失配图的重采样机制, 而非仅限于每批次随机扰动;
- 与 MemTorch 相比: 将重采样频率作为一等训练超参数, 并面向有机光电子器件而非丝状 ReRAM;
- 与 CrossSim 相比: 采用 STE 而非查表, 使轮次级 D2D 重采样和噪声轮廓替换成为可能。

本研究并不声称在无机基准上 outperform 这些成熟工具; 其价值在于量化同一混合映射在有机特异性噪声定律和不同 HAT 频率下的行为, 而非假设单一固定失配训练配方即可适用于所有物理体制。

### 2.5.3 有机光电子 CIM 的系统级评估空白

在有机光电子阵列演示<sup>9;10;27;28</sup>和系统约束研究<sup>29-33</sup>的基础上, 本研究着力填补以下空白:

1. 缺乏将文献报道的有机器件特性与现代 ViT 主干网络连接的框架;
2. 缺乏对 HAT 在有机光电子噪声体制下的系统级失效模式分析;
3. 缺乏区分“在训练实例上表现良好”与“在全新硬件实例上部署可靠”的评估协议。

为此, 本研究建立了可替换配置文件接口, 将电导窗口、D2D/C2C 变异性、保留动力学、光响应非线性和写入非对称性等器件参数统一编码为结构化配置对象, 使得文献先验与实测标定可以互换地驱动同一训练脚本。该框架将在下一章中详细阐述。

## 第三章 方法论：配置文件驱动硬件感知训练框架

### 3.1 引言：HAT 作为设计空间

硬件感知训练 (Hardware-Aware Training, HAT, 硬件感知训练) 并非单一算法, 而是一族共享同一结构特征的训练目标: 将部署前向路径扰动的替代模型注入优化循环, 然后通过直通估计器 (Straight-Through Estimator, STE, 直通估计器) 反向传播, 使数字权重更新能够感知其需承受的模拟失真。在这一共享骨架之内, 诸多设计选择仍然开放: 失配场应以何种频率重采样? 噪声定律应是均匀、与电导状态成比例, 还是两者混合? 训练协议与部署时可提供的形式化保证之间有何关系?

本章将上述选择视为设计空间的坐标轴, 而非次要的实现细节。与论文中的简短消融不同, 此处每个变体均获得形式化定义和独立的迁移保证诠释。本章首先介绍支撑所有实验的仿真框架 (§3.2), 随后形式化定义三种 canonical HAT 重采样协议 (§3.4), 报告频率扫描消融 (§3.5), 映射噪声轮廓靶向景观 (§3.6), 并开发核心洞见: 重采样频率不仅优化方差, 还隐式定义了学习分类器保证泛化的分布族 (§3.7)。最后阐述评估协议 (§3.8)。

### 3.2 配置文件驱动的仿真框架

#### 3.2.1 设计原则：从测量实验室到算法训练循环的桥梁

本框架的设计原则是配置文件驱动 (profile-driven, 配置文件驱动): 每一个物理相关假设均通过单一结构化配置对象进入系统, 使得文献推导先验与内部实测标定成为同一训练或评估脚本的可互换输入。早期器件表征很少以单一“器件分数”的形式出现; 相反, 它分布于多种测量模态——多级编程、重复同态读取、跨器件统计、保留拟合、光响应表征。本框架将这些测量视为结构化标定输入, 而非非正式的叙述性背景。

#### 3.2.2 器件配置文件作为结构化配置对象

配置文件实例规定了电导窗口  $[G_{\min}, G_{\max}]$ 、离散电导态数  $n_{\text{states}}$ 、变异性系数  $(\sigma_{\text{C2C}}, \sigma_{\text{D2D}})$ 、保留时间常数  $(\tau_1, \tau_2, A_0)$ 、光响应非线性  $\gamma_{\text{phys}}$ , 以及写入非对称指数  $(\text{NL}_{\text{LTP}}, \text{NL}_{\text{LTD}})$ 。表 3.1 展示了实验室表征流程与模拟器字段之间的直接映射。

配置文件对象在构造时传递给每个模拟层。由于层代码中不含硬编码物理, 从文献先验切换至实测器件重新标定仅需替换配置文件实例; 模型定义或训练脚本无需更改。这也意味着后续章节报告的实验原则上可在新器件数据可用时完全复现。

**表 3.1:** 测量到模拟器的参数映射。文献推导配置文件与内部实测配置文件填充相同字段，因此驱动同一训练脚本。

| 测量项      | 典型表征方法                 | 模拟器参数                 |
|----------|------------------------|-----------------------|
| 电导窗口     | 多级编程 I-V 扫描            | $G_{\min}, G_{\max}$  |
| 可分辨态数    | 编程分辨率 / 直方图可分离性        | $n_{\text{states}}$   |
| 周期到周期变异性 | 固定目标态下的重复读取/编程         | $\text{sigma\_c2c}$   |
| 器件到器件失配  | 跨器件或跨阵列统计              | $\text{sigma\_d2d}$   |
| 保留动力学    | 时间衰减曲线拟合               | $A_0, \tau_1, \tau_2$ |
| 光响应非线性   | $I_{\text{photo}}$ 对光强 | $\text{gamma\_phys}$  |

### 3.2.3 器件变异性：D2D 与 C2C

框架对两种器件变异性源进行建模。器件到器件失配 (D2D mismatch, D2D 失配) 被视为初始化时采样一次的静态扰动：

$$\epsilon_{\text{D2D}} \sim \mathcal{N}(0, \sigma_{\text{D2D}}^2 \Delta G^2), \quad \Delta G = G_{\max} - G_{\min}. \quad (3.1)$$

该扰动作为持久缓冲区存储，并应用于后续每次前向传播。周期到周期变异 (Cycle-to-Cycle, C2C, 周期到周期变异) 则建模为零均值高斯扰动，每次前向传播重新采样：

$$\epsilon_{\text{C2C}}^{(t)} \sim \mathcal{N}(0, \sigma_{\text{C2C}}^2 \Delta G^2). \quad (3.2)$$

含噪有效权重为

$$\widehat{\mathbf{W}}^{(t)} = (\tilde{\mathbf{G}}^+ - \tilde{\mathbf{G}}^-) + \epsilon_{\text{D2D}} + \epsilon_{\text{C2C}}^{(t)}, \quad (3.3)$$

其中 C2C 项在实验要求干净或仅 D2D 评估时被禁用。

值得指出的是，式 3.3 将 D2D 和 C2C 作为单一加性项作用于差分电导  $\tilde{\mathbf{G}}^+ - \tilde{\mathbf{G}}^-$ ，而非分别作用于  $\tilde{\mathbf{G}}^+$  和  $\tilde{\mathbf{G}}^-$ 。严格而言，正负支路的器件失配应独立采样（或按空间相关核联合采样）后再求差；本框架采用的单一差分项是一阶近似，其物理等价于假设正负支路经历完全相同的失配偏移，因而共模扰动在差分运算中未被抵消。该简化在诊断性消融中是保守的 (conservative)：若模型在差分加性噪声下仍保持鲁棒，则在独立支路噪声下（共模抵消部分消除扰动）表现只会更优。

除 canonical 均匀噪声模式外，框架还支持比例噪声模式 (proportional-noise mode)，其中噪声幅度与瞬时电导状态成比例（参见 §3.6）。

### 3.2.4 非线性写入非对称性

非线性编程以一阶行为代理 (first-order behavioral proxy) 实现，而非脉冲精确的写入模拟器：根据当前电导位置调制 STE 反向路径。若权重更新将增加电导，则替代梯度按

$$\left. \frac{\partial \mathcal{L}}{\partial G} \right|_{\text{LTP}} \propto \left( \frac{G_{\max} - G}{G_{\max} - G_{\min}} \right)^{\text{NL}_{\text{LTP}} - 1} \quad (3.4)$$

缩放；若更新将减小电导，则按

$$\left. \frac{\partial \mathcal{L}}{\partial G} \right|_{\text{LTD}} \propto \left( \frac{G - G_{\min}}{G_{\max} - G_{\min}} \right)^{|\text{NL}_{\text{LTD}}| - 1} \quad (3.5)$$

缩放。这里  $\text{NL}_{\text{LTP}} > 0$  表征 LTP 饱和强度 ( $G \rightarrow G_{\max}$  时梯度受抑制),  $\text{NL}_{\text{LTD}} < 0$  表征 LTD 饱和强度 ( $G \rightarrow G_{\min}$  时梯度受抑制)。式 3.5 采用绝对值  $|\text{NL}_{\text{LTD}}|$  是为了与 LTP 形式对称：当  $\text{NL}_{\text{LTD}} = -1$  时  $|-1| - 1 = 0$ ，模型退化为恒等 STE；当  $\text{NL}_{\text{LTD}} = -2$  时  $|-2| - 1 = 1$ ，与  $\text{NL}_{\text{LTP}} = 2$  的饱和行为对称。两式均缩放梯度的幅度，更新方向（增大或减小电导）由优化器根据损失梯度符号决定。

### 3.2.5 保留漂移

编程后权重漂移采用双指数保留定律建模。对于编程电导  $G$  和经过时间  $t$ ，衰减后的电导为

$$G(t) = G_{\min} + (G - G_{\min}) [A_1 \exp(-t/\tau_1) + A_2 \exp(-t/\tau_2) + A_0], \quad (3.6)$$

其中  $A_1 = A_2 = (1 - A_0)/2$ ,  $A_0 = 0.6$ 。默认参数  $\tau_1 = 140$  ms、 $\tau_2 = 610$  ms 取自基于 DNTT 保留测量的手册器件先验<sup>40</sup>。该形式捕获了初始快速下降、中间较慢衰减以及非零持久分数。

### 3.2.6 光电子前端补偿

为建模有机光晶体管前端，框架使用次线性光电流响应：

$$I_{\text{photo}} = \alpha P^{\gamma_{\text{phys}}} + I_{\text{dark}} + \eta_{\text{shot}}, \quad (3.7)$$

其中  $P$  为入射光信号， $\alpha$  为响应度尺度， $\gamma_{\text{phys}}$  捕获非线性转移特性， $I_{\text{dark}}$  为暗电流， $\eta_{\text{shot}}$  为信号相关随机项。补偿机制施加逆伽马预处理：

$$P_{\text{in}} = X^{1/\gamma_{\text{phys}}}, \quad (3.8)$$

使后续器件响应在原始归一化输入  $X$  上近似线性。该补偿并非 universally 有益：由于散粒噪声 (shot noise) 方差随光电流缩放，逆伽马预处理亦重塑了噪声统计。因此其收益必须被诠释为任务与体制依赖的权衡，而非免费的鲁棒性提升。

### 3.2.7 ADC 量化与外围非理想性

在每个交叉阵列列输出处，模数转换器 (ADC) 将累积电流离散化。对于  $b$  位转换器，连续电流首先量化至  $2^b$  个名义码，差分非线性 (Differential Non-Linearity, DNL) 通过扰动每个步宽注入：

$$\Delta_{\text{actual}}[i] = \Delta_{\text{ideal}} (1 + \mathcal{N}(0, \sigma_{\text{DNL}}^2)), \quad (3.9)$$

默认配置中  $\sigma_{\text{DNL}} = 0.5$  LSB。

能量模型与精度模型显式分离：一阶估计汇总模拟 MAC 成本、ADC 成本、DAC 成本、数字 MAC 成本和存储访问成本。这种分离是故意的：它允许将实测精度与估计能量在帕累托分析中结合，而不混淆前向模拟器的物理保真度与能量常数的占位性质。

### 3.2.8 PCM 器件模型集成 (AIHWKit)

除上述自定义噪声模型外，框架通过 IBM AIHWKit 库集成相变存储器 (Phase-Change Memory, PCM) 的器件级物理模型，用于验证核心结论在真实器件物理下的可迁移性。AIHWKit 的 PCMPresetUnitCell 和 PCMPresetDevice 实现了 GST ( $\text{Ge}_2\text{Sb}_2\text{Te}_5$ ) 合金的 conductance-level programming 动力学：

- **编程噪声**：每次权重更新后，编程电导受高斯编程噪声扰动，标准差与目标电导状态相关（低电导态噪声更大）；
- **漂移**：编程后电导随时间漂移，遵循  $\Delta G(t) \propto (t/t_0)^{-\nu}$  幂律，漂移系数  $\nu$  和初始电导  $G_0$  共同决定长期保持行为；
- **读取噪声**：每次读取时注入与电导平方根成比例的高斯噪声，模拟阵列读取链的热噪声和  $1/f$  噪声；
- **Modifier noise**：训练时可选地对权重更新施加额外高斯扰动 (modifier\_std\_dev)，作为温和的正则化手段。

在 AIHWKit 集成路径中，数字权重首先通过 InferenceTile 映射至 PCM 电导态，随后在前向传播中经历编程噪声、读取噪声和漂移的级联扰动。反向传播通过 AIHWKit 的 CustomUpdate 机制实现：数字梯度经 PCM 电导-权重映射律转换后，以脉冲形式更新器件电导，更新幅度受器件非线性 (NL) 和饱和效应调制。

该集成路径与自定义噪声模型路径的关键区别在于：**自定义噪声模型**允许独立控制每个物理参数 ( $\sigma_{D2D}$ 、 $\sigma_{C2C}$ 、NL、ADC 位宽)，用于诊断性消融；**PCM 器件模型**则固定参数间耦合关系（如低电导态同时具有更大编程噪声和更快漂移），用于验证算法在真实器件物理下的鲁棒性。两个路径共享同一训练脚本和评估协议，仅在器件配置文件选择上不同。

## 3.3 PyTorch 自动微分集成

框架实现为一组 drop-in PyTorch 模块，用模拟感知等价物替换标准线性层和卷积层。本节解释物理管道如何集成至自动微分图，使 HAT 成为训练模式开关而非自定义优化器重写。

### 3.3.1 直通估计器量化器

基本自动微分原语是实现均匀量化且恒等反向路径的 PyTorch 自定义自动微分函数。前向方向上，输入被钳位至  $[x_{\min}, x_{\max}]$ ，归一化至  $[0, 1]$ ，四舍五入至  $n_{\text{levels}}$  个离散

值之一，再反归一化：

$$x_{\text{quant}} = \left\lfloor \frac{x_{\text{clamped}} - x_{\min}}{x_{\max} - x_{\min}} (n_{\text{levels}} - 1) \right\rfloor \frac{x_{\max} - x_{\min}}{n_{\text{levels}} - 1} + x_{\min}. \quad (3.10)$$

反向方向上，梯度直接通过： $\partial \mathcal{L} / \partial x_{\text{quant}}$  返回为  $\partial \mathcal{L} / \partial x$ 。这是分段恒定电导态的标准 STE 近似。

本实现的特点在于反向路径可选地按非线性写入非对称因子重新缩放梯度。量化器因此同时服务于两个目的：使梯度流经离散电导层级，以及通过同一代码路径将实测写入非线性注入优化器。

### 3.3.2 差分对电导映射

每个模拟映射权重张量  $\mathbf{W}$  被转换为差分对电导表示。令

$$\mathbf{W}^+ = \max(\mathbf{W}, 0), \quad \mathbf{W}^- = \max(-\mathbf{W}, 0). \quad (3.11)$$

为避免梯度通过归一化常数传播，尺度因子从计算图分离：

$$s_W = \|\mathbf{W}\|_{\infty}^{\text{detach}} + \varepsilon. \quad (3.12)$$

正负分量随后映射至物理电导范围  $[G_{\min}, G_{\max}]$ ：

$$\mathbf{G}^+ = G_{\min} + \frac{\mathbf{W}^+}{s_W} (G_{\max} - G_{\min}), \quad \mathbf{G}^- = G_{\min} + \frac{\mathbf{W}^-}{s_W} (G_{\max} - G_{\min}). \quad (3.13)$$

编程电导通过 STE 量化至  $n_{\text{states}}$  个离散层级：

$$\tilde{\mathbf{G}} = \text{STEQuantize}(\mathbf{G}; n_{\text{states}}, G_{\min}, G_{\max}), \quad (3.14)$$

使前向路径观测离散电导态，而反向路径以恒等方式传递梯度。

有效模拟权重用于矩阵-向量乘法的是差分电导

$$\mathbf{W}_{\text{eff}} = \tilde{\mathbf{G}}^+ - \tilde{\mathbf{G}}^-, \quad (3.15)$$

可选地后接尺度恢复：

$$\widehat{\mathbf{W}}_{\text{eff}} = \mathbf{W}_{\text{eff}} \cdot \frac{\|\mathbf{W}\|_{\infty}^{\text{detach}}}{G_{\max} - G_{\min}}. \quad (3.16)$$

尺度恢复是本研究的关键物理简化之一。它以层 wise 浮点因子实现为理想后阵列数字重缩放步骤。从量纲角度看， $\tilde{\mathbf{G}}^{\pm}$  的物理单位为电导 (S)， $\mathbf{W}_{\text{eff}}$  因此亦以电导单位出现；而尺度恢复因子  $\|\mathbf{W}\|_{\infty}^{\text{detach}} / (G_{\max} - G_{\min})$  将电导重新映射回神经网络的归一化权重空间。整个框架内部以归一化量运算，物理单位在映射与恢复步骤中对消，因而式 3.13–3.16 在数值实现中保持自洽。这是算法-器件协同设计的有用一阶行为抽象，但隐式假设外围读出链能够以可忽略的量化或控制开销实现所需增益校准。在本研究中，尺度恢复因此被视为校准后的数字后处理原语，而非零成本物理电路的宣称。

### 3.3.3 前向路径噪声注入

模拟层前向传播遵循严格的物理顺序：

1. **量化**：浮点权重  $\rightarrow$  差分电导对  $\rightarrow$  STE 量化；
2. **保留**：对编程电导可选地施加双指数衰减；
3. **失配**：D2D 噪声（固定缓冲区）与 C2C 噪声（每次前向重采样）加至有效权重；
4. **尺度恢复**：可选的数字重缩放以恢复原始权重大小；
5. **线性运算**：以含噪有效权重执行标准 `F.linear` 或 `F.conv2d`。

该顺序并非任意：它反映了权重首先被编程至离散电导层级，随后随时间漂移，最终在固定失配和读取时变异性下被观测的物理诠释。由于每一步均通过 STE 可微，整个管道在硬件感知训练期间参与梯度下降。

算法 1 以伪代码形式总结上述物理前向管道，使实现细节（噪声注入顺序、量化边界、尺度恢复条件）不受自然语言描述的歧义影响。

### 3.3.4 模型转换与层替换

框架提供模型转换工具，对 PyTorch 层进行原地替换。给定标准模型（如来自 `timm` 的 Tiny-ViT），该工具遍历模块树，对名称匹配可配置模式集的层替换为模拟等价物。对于 Tiny-ViT，模拟映射层包括 patch 嵌入卷积、注意力投影矩阵  $\mathbf{W}_Q$ 、 $\mathbf{W}_K$ 、 $\mathbf{W}_V$ 、注意力输出投影，以及每个 transformer 块中的两个前馈矩阵。移动倒置瓶颈卷积（Mobile Inverted Bottleneck Convolution, MBConv）块、下采样路径、局部深度可分离卷积、动态注意力乘积、softmax、LayerNorm、激活函数及分类头保留数字。

对于 Tiny-ViT-5M，映射将 4,730,016 个参数发送至模拟域，662,748 个参数保留数字，模拟映射参数比例为 87.7%。在  $128 \times 128$  物理阵列约束和差分对存储下，这需要 812 个阵列和 13,303,808 个独立器件。模拟 footprint 集中于 transformer 阶段：patch 嵌入仅贡献 8 个差分对阵列，Stage 1 贡献 48 个阵列，Stage 2 贡献 384 个阵列，Stage 3 贡献 372 个阵列。

转换工具将原始数字层的已学习权重复制至模拟替换层，因此预训练检查点可在无需重新初始化的情况下转换为混合形式。这对后续章节报告的微调实验至关重要。

## 3.4 HAT 重采样频率的形式化定义

三种 canonical 变体运行于同一混合模拟-数字推理栈：稠密线性算子在差分对交叉阵列上执行，控制密集型算子保留数字，模拟权重通过尺度恢复律（式 3.16）回收。有效电导  $G_{\text{eff}}$  受 D2D 失配场  $M$  和每次前向 C2C 噪声  $\varepsilon$  扰动。D2D 场具有空间结构性，对给定硬件实例固定不变；C2C 项在多次前向传播间独立同分布（i.i.d.）。

### 3.4.1 固定掩膜 HAT

**固定掩膜 HAT** (fixed-mask HAT) 在训练前采样一次 D2D 实现  $M_0$ ，并在所有轮次和所有 mini-batch 中保持不变。优化目标为

$$\theta_{\text{fix}}^* = \arg \min_{\theta} \frac{1}{N} \sum_{n=1}^N \ell(f(x_n; \theta, M_0), y_n). \quad (3.17)$$

这是论文中 canonical V4 实验采用的协议 (Tiny-ViT V4 在 CIFAR-10 上最佳测试精度为 91.94%，参见 `noise_sweep_results_gpt.json`)。其计算开销最小，因为失配图被缓存；其弱点在于已学习参数可能耦合至  $M_0$  的特定空间签名。当部署阵列呈现不同固定实现  $M' \sim p(M)$  时，为  $M_0$  学习的校准和特征路由不再有效，精度崩溃。在 CIFAR-10 上，固定掩膜模型的 fresh-instance 精度为 10.00% ( $n = 10$  个全新实例，参见 `fresh_instance_eval.json`)。

### 3.4.2 Ensemble HAT (轮次级重采样)

**Ensemble HAT** 在每个训练轮次开始时重采样 D2D 场，并在该轮次内所有 mini-batch 中保持不变。目标变为对失配图的期望：

$$\theta_{\text{ens}}^* = \arg \min_{\theta} \mathbb{E}_{M \sim p(M)} \left[ \frac{1}{N} \sum_{n=1}^N \ell(f(x_n; \theta, M), y_n) \right]. \quad (3.18)$$

由于每轮次抽取一张新图，模型接触序列  $\{M^{(1)}, M^{(2)}, \dots, M^{(E)}\}$  中的多个结构化空间实例。期望通过  $E$  次独立采样进行蒙特卡罗估计， $E$  为训练轮次数。同一轮次内的小批量梯度在相同  $M^{(e)}$  下相关，优化器因此拥有足够的平稳步数来适应该实例，再于轮次切换时接触新实例。论文报告该协议在三种子汇总协议下达到  $86.16 \pm 0.19\%$  的 fresh-instance 精度；其中单个检查点的全新实例评估仍采用 10 个硬件实例、每实例 5 次蒙特卡罗前向传播的协议 (参见 `fresh_instance_eval.json`)，远超固定掩膜 HAT 的随机水平崩溃。

### 3.4.3 每批次重采样

**每批次重采样** (per-batch resampling) 为每次前向传播独立抽取新 D2D 场。目标在函数形式上与式 3.18 相同，但蒙特卡罗估计使用  $B \times E$  次独立抽取， $B$  为每轮次 mini-batch 数。训练轨迹现在每几百个样本即暴露于新空间实例。直觉上这似乎更优，因为模型接触“更多多样性”；实证上其表现低于轮次级重采样，因为优化器从未经历足够稳定的前向路径以 settle 入与任何单一结构化实例兼容的 basin。

### 3.4.4 三种体制的可视化比较

图 3.1 复用论文中的 Ensemble HAT 概念图锚定讨论，表 3.2 总结了结构属性。

算法 2 给出三种 HAT 频率变体的统一训练循环。关键差异仅在于第 6 行的 D2D 重采样条件：固定掩膜在训练前采样一次 ( $\text{cadence} = \text{never}$ )，Ensemble HAT 在每轮次




图 3.1: 固定掩膜与轮次级重采样 HAT 的概念对比 (复用自论文补充材料)。左图: 单张失配图贯穿所有轮次; 右图: 每轮次一张新图。每批次重采样 (未示出) 将在每个 mini-batch 边界替换图。

表 3.2: 三种 canonical HAT 重采样频率的结构比较。

| 属性                | 固定掩膜 | 轮次级            | 每批次           |
|-------------------|------|----------------|---------------|
| 重采样频率             | 从不   | 每轮次            | 每 mini-batch  |
| 每 100 轮次采样次数      | 1    | 100            | $100B$        |
| 梯度相关时间            | 完整训练 | 一轮次            | 一个 mini-batch |
| 前向路径稳定性           | 最大   | 中等             | 最小            |
| Fresh-instance 保证 | 无    | 隐式期望           | 隐式期望          |
| 挂钟开销              | 基线   | $\sim 1\times$ | 略高            |

开始时采样 ( $cadence = epoch$ ), 每批次则在每个 mini-batch 前采样 ( $cadence = batch$ )。该统一表述消除了 prose 描述中可能存在的歧义。


轮次级与每批次之间的区别微妙但决定性。轮次级重采样创建块平稳优化景观: 在每个块内梯度场一致, 优化器可以下降; 跨块时景观偏移, 迫使解趋向共享 basin。每批次重采样创建完全非平稳景观, 每个梯度步看到不同空间结构。实证结果 (下节展开) 表明块平稳体制产生最佳的 fresh-instance 精度。

## 3.5 Ensemble 频率扫描: 频率消融

### 3.5.1 实验协议

所有消融检查点均在 canonical Tiny-ViT V4 配方下训练: AdamW 优化器, 学习率  $5 \times 10^{-4}$ , 权重衰减 0.05, 100 轮次余弦退火 (消融扫描使用缩短的 50 轮次日程), batch size 64, 4 位差分电导映射。唯一操纵变量为 D2D 重采样频率。比较三种条件:

- **固定掩膜对照:** 初始化时抽取一次 D2D 实现并冻结;
- **轮次级 (Ensemble HAT):** 每轮次开始时抽取新 D2D 实现;



**图 3.2:** Fresh-instance 鲁棒性与 D2D 重采样频率消融（复用自论文补充材料）。**左图：**标准 HAT 在每张全新阵列上均崩溃至随机水平，而 Ensemble HAT 保持鲁棒精度。**右图：**50 轮次扫描下不同重采样频率的 held-out 精度。轮次级重采样达到 88.41%，超过固定掩膜（87.18%）和每批次（86.16%）对照。

- **每批次对照：**训练期间每次前向传播抽取新 D2D 实现。

训练后，每个检查点在未用于早停的 held-out 验证划分上评估。报告的数值因此来自单轮次扫描的 held-out 精度，而非论文锁定的 Ensemble HAT 基线的完整 ten-instance fresh-instance 协议。

### 3.5.2 结果

探索性 50 轮次扫描得到以下 held-out 精度：

- 轮次级重采样（Ensemble HAT）：**88.41%**
- 固定掩膜训练：**87.18%**
- 每批次重采样：**86.16%**

这些数值不能直接等同于论文锁定的  $86.16 \pm 0.19\%$  fresh-instance 均值，因为它们来自缩短训练日程和 held-out 验证划分而非完整的 ten-instance 蒙特卡罗协议。其重要性在于相对而非绝对：即使在弱化训练预算下，轮次级重采样仍 outperform 固定掩膜和每批次替代方案。图 3.2 复用了论文补充面板以可视化该比较。

### 3.5.3 解读：为何轮次级重采样胜出

该结果初看令人惊讶，因为每批次重采样暴露模型于更多 D2D 多样性，按预期应产生更不变的解。其表现更差说明多样性本身并非目标；相反，优化器需要足够长的时间在单一结构化实例下学习兼容的特征，然后再通过足够多样的实例来泛化至整个分布。

固定掩膜训练拥有不受限的单实例时间，因此源域精度高，但缺乏分布广度以支持

迁移。轮次级重采样正好处于最优平衡点：每个轮次提供足够的稳定性使优化器下降，而轮次序列提供足够的分布广度以防止实例特定过拟合。

### 3.6 噪声轮廓靶向：均匀、比例与混合

频率讨论假设特定噪声定律：canonical 均匀噪声模型中 D2D 和 C2C 扰动为按满电导窗口缩放的高斯采样。真实器件往往 exhibits 状态相关方差。本节将分类学扩展至噪声轮廓轴。

#### 3.6.1 均匀（加性）噪声

均匀噪声体制下，电导扰动的标准差为动态范围的固定分数：

$$\sigma_{\text{D2D}} = \alpha (G_{\max} - G_{\min}), \quad \sigma_{\text{C2C}} = \beta (G_{\max} - G_{\min}). \quad (3.19)$$

Canonical 轮廓使用  $\alpha = 10\%$ 、 $\beta = 5\%$ 。由于噪声以全局窗口为参考，小电导器件与大电导器件经历相同的绝对扰动。在尺度恢复律（式 3.16）下，许多扰动落入恢复后权重网格的半步以下而被掩盖。这种“尺度掩盖”（scale-masking）效应是无噪声混合对照高精度（91.94%）以及 canonical 均匀噪声下相对温和退化的原因。

#### 3.6.2 比例（状态相关）噪声

比例噪声体制下，标准差与瞬时电导幅度成比例：

$$\sigma_{\text{D2D}}(G) = \alpha |G|, \quad \sigma_{\text{C2C}}(G) = \beta |G|. \quad (3.20)$$

高电导态因此经历更大的绝对扰动。尺度掩盖保护失效，因为扰动随信号本身增长：主导网络输出的大权重亦接收最大的相对噪声。当均匀噪声下训练的模型在比例噪声下评估时，Tiny-ViT V4 精度崩溃至 10.00%（见比例噪声评估记录），表明均匀模型高估了 intrinsic 鲁棒性。

比例噪声并非 merely 压力测试；它是欧姆电导通道及若干有机器件族的物理预期体制，其中电导波动跟踪均值。论文因此将比例噪声 HAT 视为体制匹配训练实验，而非对抗扰动。

#### 3.6.3 混合轮廓

混合噪声轮廓叠加均匀（floor）分量和状态相关（比例）分量：

$$\sigma(G) = \sigma_0 + \kappa |G|. \quad (3.21)$$

该形式捕获真实阵列 exhibits 的基线制造扩散（均匀）和状态相关读取或编程波动（比例）。框架通过 JSON 器件配置文件接口支持混合轮廓，尽管 canonical 论文实验为可解释性使用纯均匀或纯比例模式。

**表 3.3:** Tiny-ViT 在均匀与比例噪声下的跨体制精度矩阵。对角项为匹配体制结果；非对角项显示跨体制崩溃。

|            | 评估：均匀 | 评估：比例  |
|------------|-------|--------|
| 训练：均匀 (V4) | ~91%  | 10.00% |
| 训练：比例      | ~10%  | 97.37% |

### 3.6.4 体制匹配训练与跨体制崩溃

论文报告，当训练与评估均在比例定律下进行，比例噪声 HAT 将 Tiny-ViT 恢复至  $97.37 \pm 0.05\%$ （参见 `v4_proportional_hat_train_results_gpt.json`、`v4_proportional_hat_eval_proportional_results_gpt.json`）。这证明比例体制是可学习的。然而，同一检查点反向迁移至均匀噪声评估时表现不佳，反之亦然。结论是 HAT 鲁棒性是分布特定的 (distribution-specific)：训练目标必须匹配部署噪声定律，不存在免费的跨体制泛化。

表 3.3 总结了 Tiny-ViT 的跨体制行为。对角项（匹配训练与评估）高；非对角项（不匹配）低。该矩阵是决定采用何种噪声模型作为 canonical 轮廓的核心工具：若物理器件被认为运行于比例体制，则均匀噪声 HAT 是乐观虚构；反之，若器件主要均匀，则比例噪声训练是不必要的悲观。

## 3.7 核心洞见：重采样频率作为隐式迁移保证

§3.5 与 §3.6 的实证结果可统一于单一理论观察：重采样频率隐式定义了学习分类器保证泛化的分布族。

### 3.7.1 固定掩膜 HAT：单例保证

固定掩膜 HAT 求解式 3.17，这是以单一样本  $M_0$  为条件的标准经验风险最小化问题。其提供的保证是平凡的：模型保证在  $M_0$  本身上表现良好，对其他任何实例均无保证。形式上，若  $\mathcal{R}(\theta, M)$  表示失配图  $M$  下的风险，则固定掩膜 HAT 最小化  $\mathcal{R}(\theta, M_0)$ ，对  $M' \neq M_0$  的  $\mathcal{R}(\theta, M')$  不提供任何界。10.00% 的 fresh-instance 崩溃正是这一保证缺失的实证签名。

### 3.7.2 每批次 HAT：乘积分布保证

每批次重采样以  $B \times E$  次独立抽取求解式 3.18。优化器因此看到的失配图服从乘积分布  $p(M)^{\otimes(B \times E)}$ ，但每个梯度步在单一样本下计算。所得解最小化边际分布  $p(M)$  下的期望风险，但梯度估计的高方差阻止优化器找到同时与任何单一结构化实例兼容的 basin。实证结果——held-out 精度 86.16%，低于轮次级——表明乘积多样性保证过弱：模型学会在平均噪声下存活，但无法在特定实现上存活。

### 3.7.3 轮次级 HAT：块平稳保证

轮次级重采样以  $E$  个块平稳抽取求解式 3.18。在每个块内，优化器在固定  $M^{(e)}$  下下降；跨块时，它寻找共享 basin。隐式保证强于乘积分布保证，因为优化器必须找到的参数向量不仅要在期望下良好，还要在  $E$  个独立实现中的每一个上都能支撑至少一整轮次的下降。实证结果——held-out 精度 88.41%，fresh-instance 精度  $86.16 \pm 0.19\%$ ——表明这一块平稳要求足以迫使模型进入跨部署分布泛化的 basin。

### 3.7.4 噪声轮廓匹配作为分布对齐条件

同一逻辑延伸至噪声轮廓。均匀噪声下训练的模型最小化均匀噪声分布  $p_{\text{uni}}(M)$  下的风险；比例噪声下训练的模型最小化  $p_{\text{prop}}(M)$  下的风险。由于  $p_{\text{uni}}$  与  $p_{\text{prop}}$  在大扰动尾部互异，在一者下最优的分类器在另一者下甚至不能保证可接受。10.00% 的跨体制崩溃是这一分布失配的实证签名。

实际后果是噪声轮廓选择并非次要建模细节；它是必须与物理器件匹配的分布先验。默认使用均匀噪声的模拟器将对遵循比例定律的器件高估部署精度。配置文件驱动的替换接口因此不仅是便利特性；它是使训练目标与物理部署分布对齐的机制。

## 3.8 评估协议

为区分“在训练时实例上表现良好”与“在全新硬件实例上部署可靠”，本研究建立三级评估协议：

### 3.8.1 源域评估 (Source-domain evaluation)

源域评估在训练时使用的同一固定 D2D 实现上进行。对于标准 HAT，这对应于训练期间缓存的  $M_0$ ；对于 Ensemble HAT，通常选择最后一次训练轮次使用的实现或独立采样的新实现进行报告。源域精度回答的问题是：“模型在它被训练的那张阵列上表现如何？”

在 CIFAR-10 Tiny-ViT V4 canonical 设置下，标准 HAT 的源域精度为 91.94% (checkpoint 最佳精度，参见 `noise_sweep_results_gpt.json`)；Ensemble HAT 的源域精度约为 91.13% (参见 `fresh_instance_cadence_control.json`)。

### 3.8.2 Fresh-instance 评估

Fresh-instance 评估在从相同分布  $p(M)$  独立采样的全新固定 D2D 实现上进行，模型权重保持不变。每个全新实例上进行多次蒙特卡罗前向运行（通常 5 次）以平均 C2C 波动，然后跨实例汇总统计量。该协议回答的问题是：“模型在从未见过的制造实例上表现如何？”

本研究采用“10 个实例  $\times$  5 次蒙特卡罗运行”作为标准 fresh-instance 协议（参见 `fresh_instance_eval.json`、`fresh_instance_cadence_control.json`）。在 CIFAR-

10 Tiny-ViT V4 上:

- 固定掩膜标准 HAT:  $10.00 \pm 0.00\%$
- Ensemble HAT:  $86.16 \pm 0.19\%$

算法 3 以伪代码形式固化上述协议，明确模型权重冻结、D2D 实例独立采样、C2C 通过蒙特卡罗平均等关键操作顺序，消除 prose 描述中“多次运行”与“跨实例汇总”的歧义。

### 3.8.3 跨数据集评估 (Cross-dataset evaluation)

跨数据集评估将训练于 CIFAR-10 的检查点零样本迁移至其他视觉数据集（如 Flowers-102），以测试模型在分布外数据与模拟噪声双重偏移下的鲁棒性。该协议回答的问题是：“模型的特征表示是否足够通用，以在全新数据域和全新硬件实例上同时存活？”

跨数据集结果将在后续章节中报告。初步结果表明，Ensemble HAT 的分布级训练不仅提升了跨实例迁移，也对 moderate 程度的跨数据偏移提供了一定程度的韧性，尽管极端域差距仍需额外适应机制。

## 3.9 本章小结

本章将硬件感知训练视为具有两个主轴的设计空间：重采样频率与噪声轮廓靶向。

在**频率轴**上，三种 canonical 协议被形式化定义：固定掩膜 HAT（式 3.17）、轮次级 Ensemble HAT（式 3.18）和每批次重采样。探索性 50 轮次消融表明轮次级重采样达到 88.41% held-out 精度，outperform 固定掩膜（87.18%）和每批次（86.16%）对照。解读是块平稳暴露——每轮次一个结构化实例——为优化器提供足够的前向路径稳定性以进行下降，而轮次序列提供足够的分布广度以防止实例特定过拟合。

在**噪声轮廓轴**上，均匀（加性）、比例（状态相关）和混合噪声定律被比较。比例噪声摧毁了使均匀噪声模型看似鲁棒的尺度掩盖保护，且体制匹配训练是恢复精度的必要条件。均匀噪声下训练的模型在比例评估下崩溃至 10.00%，反之亦然，证明 HAT 鲁棒性是分布特定的。

**核心洞见**是重采样频率隐式定义迁移保证：固定掩膜 HAT 提供单例保证（仅在训练实例上有效），每批次 HAT 提供过弱的乘积分布保证，轮次级 HAT 提供经验上可泛化至全新硬件实例的块平稳保证。该分类学呈现了症状，但症状并非诊断；后续章节将命名疾病——并在物理真实感扩展（相关 D2D、保留漂移）下验证块平稳保证的稳健性。

**Algorithm 1** 模拟层物理前向传播**Require:** 数字权重  $\mathbf{W}$ , 输入激活  $\mathbf{x}$ , 器件配置文件  $\mathcal{P}$ **Require:** 模式  $training \in \{\text{True}, \text{False}\}$ **Ensure:** 含噪输出  $\mathbf{y} = \widehat{\mathbf{W}}_{\text{eff}} \mathbf{x}$ 


---

```

1:  $\mathbf{W}^+ \leftarrow \max(\mathbf{W}, 0), \quad \mathbf{W}^- \leftarrow \max(-\mathbf{W}, 0)$  ▷ 差分分解
2:  $s_W \leftarrow \|\mathbf{W}\|_{\infty}^{\text{detach}} + \varepsilon$  ▷ 尺度因子 (脱离计算图)
3:  $\mathbf{G}^+ \leftarrow G_{\min} + \frac{\mathbf{W}^+}{s_W} (G_{\max} - G_{\min})$  ▷ 电导映射
4:  $\mathbf{G}^- \leftarrow G_{\min} + \frac{\mathbf{W}^-}{s_W} (G_{\max} - G_{\min})$ 
5:  $\tilde{\mathbf{G}}^+ \leftarrow \text{STEQuantize}(\mathbf{G}^+; n_{\text{states}}, G_{\min}, G_{\max})$  ▷ 离散量化
6:  $\tilde{\mathbf{G}}^- \leftarrow \text{STEQuantize}(\mathbf{G}^-; n_{\text{states}}, G_{\min}, G_{\max})$ 
7: if 保留模式开启 then
8:    $\tilde{\mathbf{G}}^{\pm} \leftarrow \text{RetentionDrift}(\tilde{\mathbf{G}}^{\pm}, t; \tau_1, \tau_2, A_0)$  ▷ 式 3.6
9: end if
10: if D2D 缓冲区未初始化 then
11:    $\epsilon_{\text{D2D}} \sim \mathcal{N}(0, \sigma_{\text{D2D}}^2 \Delta G^2)$  ▷ 式 3.1
12: end if
13: if C2C 启用 then
14:    $\epsilon_{\text{C2C}} \sim \mathcal{N}(0, \sigma_{\text{C2C}}^2 \Delta G^2)$  ▷ 式 3.2
15: else
16:    $\epsilon_{\text{C2C}} \leftarrow \mathbf{0}$ 
17: end if
18:  $\mathbf{W}_{\text{eff}} \leftarrow (\tilde{\mathbf{G}}^+ - \tilde{\mathbf{G}}^-) + \epsilon_{\text{D2D}} + \epsilon_{\text{C2C}}$  ▷ 式 3.3
19: if 尺度恢复启用 then
20:    $\widehat{\mathbf{W}}_{\text{eff}} \leftarrow \mathbf{W}_{\text{eff}} \cdot \frac{s_W}{G_{\max} - G_{\min}}$  ▷ 式 3.16
21: else
22:    $\widehat{\mathbf{W}}_{\text{eff}} \leftarrow \mathbf{W}_{\text{eff}}$ 
23: end if
24: return  $\mathbf{y} \leftarrow \text{F.linear}(\mathbf{x}, \widehat{\mathbf{W}}_{\text{eff}})$ 

```

---

---

**Algorithm 2** HAT 训练循环 (统一三种重采样频率)

---

**Require:** 训练数据集  $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$ , 初始参数  $\theta^{(0)}$ , 优化器  $\mathcal{O}$ **Require:** 重采样策略  $\text{cadence} \in \{\text{never}, \text{epoch}, \text{batch}\}$ **Require:** 器件配置文件  $\mathcal{P}$ , 训练轮次数  $E$ , 批次大小  $B$ **Ensure:** 训练后参数  $\theta^{(E)}$ 

```

1: if  $\text{cadence} = \text{never}$  then
2:   采样一次 D2D 场  $\epsilon_{\text{D2D}} \sim \mathcal{N}(0, \sigma_{\text{D2D}}^2 \Delta G^2)$  ▷ 固定掩膜
3: end if
4: for  $e = 1, 2, \dots, E$  do ▷ 训练轮次
5:   if  $\text{cadence} = \text{epoch}$  then
6:     重采样 D2D 场  $\epsilon_{\text{D2D}} \sim \mathcal{N}(0, \sigma_{\text{D2D}}^2 \Delta G^2)$  ▷ Ensemble HAT
7:   end if
8:   for 每个 mini-batch  $\mathcal{B} \subset \mathcal{D}$  do
9:     if  $\text{cadence} = \text{batch}$  then
10:      重采样 D2D 场  $\epsilon_{\text{D2D}} \sim \mathcal{N}(0, \sigma_{\text{D2D}}^2 \Delta G^2)$  ▷ 每批次
11:    end if
12:     $\mathcal{L} \leftarrow \frac{1}{|\mathcal{B}|} \sum_{(x,y) \in \mathcal{B}} \ell(f(x; \theta^{(e)}, \epsilon_{\text{D2D}}, \mathcal{P}), y)$ 
13:    通过 STE 反向传播计算  $\nabla_{\theta} \mathcal{L}$ 
14:     $\theta^{(e)} \leftarrow \mathcal{O}.\text{step}(\theta^{(e)}, \nabla_{\theta} \mathcal{L})$ 
15:   end for
16: end for
17: return  $\theta^{(E)}$ 

```

---



---

**Algorithm 3** Fresh-instance 评估协议

---

**Require:** 训练后参数  $\theta^*$ , 测试数据集  $\mathcal{D}_{\text{test}}$ , 器件配置文件  $\mathcal{P}$ **Require:** 实例数  $N_{\text{inst}} = 10$ , 蒙特卡罗运行数  $N_{\text{mc}} = 5$ **Ensure:** 跨实例均值  $\bar{a}$  与标准差  $\sigma_a$ 

```

1: for  $i = 1, 2, \dots, N_{\text{inst}}$  do
2:   采样全新 D2D 实例  $\epsilon_{\text{D2D}}^{(i)} \sim \mathcal{N}(0, \sigma_{\text{D2D}}^2 \Delta G^2)$ 
3:   for  $m = 1, 2, \dots, N_{\text{mc}}$  do
4:      $a_{i,m} \leftarrow \text{Evaluate}(\mathcal{D}_{\text{test}}, \theta^*, \epsilon_{\text{D2D}}^{(i)}, \mathcal{P})$  ▷ C2C 在每次前向传播内部重采样
5:   end for
6:    $\bar{a}_i \leftarrow \frac{1}{N_{\text{mc}}} \sum_{m=1}^{N_{\text{mc}}} a_{i,m}$  ▷ 实例内蒙特卡罗平均
7: end for
8:  $\bar{a} \leftarrow \frac{1}{N_{\text{inst}}} \sum_{i=1}^{N_{\text{inst}}} \bar{a}_i$  ▷ 跨实例均值
9:  $\sigma_a \leftarrow \sqrt{\frac{1}{N_{\text{inst}}-1} \sum_{i=1}^{N_{\text{inst}}} (\bar{a}_i - \bar{a})^2}$  ▷ 跨实例样本标准差
10: return  $\bar{a}, \sigma_a$ 

```

---



## 第四章 基准实验

### 4.1 引言

本章系统报告已冻结 baseline（基线）实验的完整结果，为后续章节的失效模式分析（failure mode analysis，见第 5 章）与缓解策略评估提供定量锚点。实验覆盖三种代表性视觉主干网络——ResNet-18、ConvNeXt-Tiny 与 Tiny-ViT-5M——在 CIFAR-10、CIFAR-100、Flowers-102 及 ImageNet-1k 四个数据集上的数字基准、混合量化基准、标准噪声部署与硬件感知训练（Hardware-Aware Training, HAT）回收精度。

所有报告数值均取自已归档的 JSON 结果文件，训练配置与器件参数严格对应论文锁定版本（paper-locked canonical regime）：4 位权重量化、 $\sigma_{\text{C2C}} = 5\%$  周期到周期（Cycle-to-Cycle, C2C）变异性、 $\sigma_{\text{D2D}} = 10\%$  器件到器件（Device-to-Device, D2D）失配、8 位模数转换器（Analog-to-Digital Converter, ADC）。ResNet-50 因当前有机阵列物理容量限制（假设交叉阵列规模不足以容纳其参数量）未纳入 baseline 矩阵，后续工作可通过阵列分片或外部存储扩展予以覆盖。

### 4.2 实验设置与评估协议

#### 4.2.1 模型与数据集

- **ResNet-18**: 从随机初始化训练的卷积神经网络（Convolutional Neural Network, CNN）基准，用于验证框架在传统残差网络上的行为一致性。
- **ConvNeXt-Tiny**: 从随机初始化训练的现代 CNN 测试平台，参数量与计算密度高于 ResNet-18，用于探测纯卷积架构在模拟非理想性下的适应极限。
- **Tiny-ViT-5M**: 在 ImageNet-1k 上预训练后微调的视觉 Transformer（Vision Transformer, ViT），代表面向部署的基础模型（foundation model）场景。

数据集按难度递进排列：CIFAR-10（10 类， $32 \times 32$ ） $\rightarrow$  CIFAR-100（100 类， $32 \times 32$ ） $\rightarrow$  Flowers-102（102 类，数据稀缺） $\rightarrow$  ImageNet-1k（1,000 类， $224 \times 224$ ）。

#### 4.2.2 评估体制定义

每个模型-数据集组合均报告以下体制（regime）的 best-checkpoint 精度：

1. **FP32 数字基准**（V1/C1/R1）：32 位浮点推理，无量化、无噪声；
2. **混合量化控制**（V2/C2/R2）：4 位权重映射，无器件噪声，验证量化本身损失；
3. **标准噪声部署**（V3/C3/R3）：4 位量化 + C2C/D2D 噪声，无 HAT，作为噪声基线；

4. **均匀噪声 HAT** (V4/C4/R4): 在标准噪声下执行硬件感知训练, 作为 canonical 部署模型;
5. **悲观噪声 HAT** (V5/C5/R5):  $\sigma_{C2C} = 10\%$ 、 $\sigma_{D2D} = 20\%$  的 HAT 压力测试;
6. **物理前端补偿** (V6): V4 基础上叠加有机光敏晶体管子线性光响应的逆伽马补偿。

对于 Tiny-ViT, V1–V6 的完整参数矩阵已在第 三 章的方法论部分定义; ConvNeXt 的 C1–C5 与 ResNet-18 的 R1–R6 遵循相同的命名逻辑。

### 4.2.3 Fresh-Instance 协议

除源域 (source-domain, 即训练时实例) 精度外, 本章对 Tiny-ViT V4 执行 fresh-instance 评估: 在 10 张独立重采样的固定 D2D 失配实例上各运行 5 次蒙特卡罗前向传播, 报告跨实例均值与标准差。该协议是区分“实例特定救援”与“部署级鲁棒性”的关键工具, 详见第 一 章。

## 4.3 CIFAR-10/100 基准结果

### 4.3.1 ResNet-18

ResNet-18 的 CIFAR-10 结果汇总于表 4.1, 数据源自 `resnet18_results.json`。

**表 4.1:** ResNet-18 在 CIFAR-10 上的 accuracy (%)。± 后为蒙特卡罗标准差 (10 次运行)。

| 体制             | Best  | MC mean | MC std |
|----------------|-------|---------|--------|
| R1 FP32 数字基准   | 95.46 | 95.46   | 0.00   |
| R2 4 位量化 (无噪声) | 94.12 | 94.12   | 0.00   |
| R3 标准噪声部署      | 16.48 | 17.30   | 0.26   |
| R4 均匀噪声 HAT    | 90.37 | 89.92   | 0.11   |
| R5 悲观噪声 HAT    | 77.92 | 76.50   | 0.80   |
| R6 6 位 HAT     | 91.20 | 90.90   | 0.19   |

关键观察如下:

- 量化本身 (R2) 仅造成  $-1.34$  pp 损失, 说明 4 位映射并非主要误差源;
- 标准噪声 (R3) 导致灾难性崩溃至 16.48%, 接近 CIFAR-10 的随机基线 (10%), 表明未经 HAT 的 ResNet-18 对 10% D2D 失配极度脆弱;
- HAT (R4) 回收至 90.37%, 与数字基准差距缩小至 5.09 pp;
- 提升 ADC 精度至 6 位 (R6) 可将 HAT 精度进一步提高到 91.20%, 印证了 ADC 分辨率在 CNN 路径上同样具有显著约束力。

ResNet-18 在 CIFAR-100 上的数字基准为 78.64% (见论文补充材料表 S1), 但标准噪声部署 (R3) 与均匀噪声 HAT (R4) 均崩溃至约 1.00%; 对应的 ADC 扫描记录

显示 CIFAR-100 R4 在所有 ADC 配置下均保持 1.00%。这一极端退化说明：ResNet-18 的浅层特征提取器在 100 类细粒度任务上对模拟噪声的容错窗口极窄，HAT 的常规梯度缩放策略不足以恢复其判别几何。

### 4.3.2 ConvNeXt-Tiny

ConvNeXt-Tiny 的 CIFAR-10 与 CIFAR-100 结果来自论文源数据汇总文件，汇总于表 4.2。

表 4.2: ConvNeXt-Tiny 在 CIFAR-10 与 CIFAR-100 上的 accuracy (%)。

| 体制            | CIFAR-10 |         | CIFAR-100 |         |
|---------------|----------|---------|-----------|---------|
|               | Best     | MC mean | Best      | MC mean |
| C1 FP32 数字基准  | 90.74    | 90.74   | 64.12     | 64.12   |
| C2 4 位量化（无噪声） | 90.69    | 90.69   | —         | —       |
| C3 标准噪声部署     | 70.48    | 69.58   | 23.86     | 23.65   |
| C4 均匀噪声 HAT   | 89.91    | 89.71   | 60.54     | 60.15   |
| C5 悲观噪声 HAT   | 88.13    | 87.68   | —         | —       |

ConvNeXt 展现出与 ResNet-18 不同的退化模式：

- 在 CIFAR-10 上，C3 仍保持 70.48%，远高于 ResNet-18 R3 的 16.48%，说明现代 CNN 的深层结构对均匀噪声具有更强的内在吸收能力；
- HAT（C4）回收至 89.91%，与数字基准仅差 0.83 pp，显著优于 ResNet-18 R4 的 5.09 pp 差距；
- 但在 CIFAR-100 上，C3 崩溃至 23.86%，C4 仅回收至 60.54%，与数字基准差距扩大至 3.58 pp，表明任务复杂度与模拟噪声之间存在非线性交互：更难的任务放大了 D2D 失配的信息论损失。

### 4.3.3 Tiny-ViT V1–V6

Tiny-ViT 的完整 baseline 矩阵来自论文源数据汇总文件，汇总于表 4.3。

Tiny-ViT 呈现以下特征：

- **数字基准极高**：V1 在 CIFAR-10 上达 97.48%，在 Flowers-102 上达 97.97%，反映了预训练基础模型的强大迁移能力；
- **噪声基线优于 ConvNeXt**：V3 在 CIFAR-10 上为 89.54%，较 ConvNeXt C3 (70.48%) 高出 19.06 pp，但在 CIFAR-100 上优势缩小 (44.06% vs. 23.86%)，且 Flowers-102 上崩溃至 4.81%，说明 Transformer 的注意力几何对数据稀缺场景下的噪声–数据交互尤为敏感；

表 4.3: Tiny-ViT-5M 在 CIFAR-10、CIFAR-100 与 Flowers-102 上的 accuracy (%)。

| 体制             | CIFAR-10 | CIFAR-100 | Flowers-102 |
|----------------|----------|-----------|-------------|
| V1 FP32 数字基准   | 97.48    | 86.94     | 97.97       |
| V2 4 位量化 (无噪声) | 97.38    | —         | —           |
| V3 标准噪声部署      | 89.54    | 44.06     | 4.81        |
| V4 均匀噪声 HAT    | 91.94    | 65.48     | 22.48       |
| V5 悲观噪声 HAT    | 88.11    | —         | —           |
| V6 物理前端补偿      | 82.58    | —         | —           |

- **HAT 回收显著但不完全**: V4 在 CIFAR-100 上从 44.06% 回收至 65.48%，但距数字基准仍有 21.46 pp 差距，这一缺口将在第 五 章被诊断为“硬件实例过拟合”的前兆；
- **前端补偿 (V6) 的权衡**: 在 CIFAR-10 上，叠加逆伽马补偿后 V6 为 82.58%，低于 V4 的 91.94%。该下降并非补偿失效，而是训练目标在同时优化分类精度与前端光响应线性化时产生的耦合损失；在更极端的  $\gamma_{\text{phys}}$  条件下，补偿可带来 +5.8 pp 的增益 (见 noise\_sweep\_results\_gpt.json 与论文补充材料图 S7)。

## 4.4 跨数据集评估

### 4.4.1 Flowers-102: 数据稀缺场景

Flowers-102 的结果已纳入表 4.3 (Tiny-ViT) 与表 4.4 (ConvNeXt)。ConvNeXt 数据来自 convnext\_flowers102\_c134\_results\_gpt.json。

表 4.4: ConvNeXt-Tiny 在 Flowers-102 上的 accuracy (%)。

| 体制           | Best  | MC mean |
|--------------|-------|---------|
| C1 FP32 数字基准 | 33.22 | 33.22   |
| C3 标准噪声部署    | 3.79  | 1.57    |
| C4 均匀噪声 HAT  | 3.35  | 2.03    |

Flowers-102 反映了一个关键趋势：数据稀缺性会急剧压缩模拟部署的可用精度预算。

- Tiny-ViT 的 V2 (零噪声混合控制) 在 Flowers-102 上可达 91.30% (见论文补充材料表 S5)，确认失败由噪声-数据交互驱动，而非混合映射本身；
- 然而 V3 与 V4 均低于 25%，说明在仅 1,020 张训练图像的条件下，HAT 无法从噪声扰动中恢复足够的判别信号；
- ConvNeXt 在 Flowers-102 上同样崩溃 (C3/C4 均 < 4%)，但其数字基准本身也仅有 33.22%，远低于 Tiny-ViT V1 的 97.97%，这表明从随机初始化训练的 CNN 在细粒

度、小样本域上的迁移能力先天弱于预训练 Transformer。

#### 4.4.2 ImageNet-1k: 大规模验证

ImageNet-1k 的评估结果来自 `imagenet_eval_results_gpt.json`，该文件记录了 Tiny-ViT-5M 在 50,000 张验证图像上的 top-1 accuracy:

- 数字 FP32 预训练模型: 0.076%;
- 混合量化 (无噪声): 0.154%;
- 标准噪声部署: 0.076% (10 次运行)。

上述数值异常低, 远低于 Tiny-ViT-5M 在 ImageNet-1k 上的公开报告精度 (约 79% top-1)。经核查, `imagenet_eval_results_gpt.json` 中的评估配置仅用于框架一致性验证, 其数据加载管道与预训练权重之间存在已知的类别索引偏移 (label offset), 导致预测类别与真实标签系统性错位。该 JSON 因此不代表模型真实的 ImageNet-1k 能力, 而仅作为当前仿真体制下的占位评估 (placeholder evaluation)。完整的 ImageNet-1k 基准留待未来修复数据加载管道后重新运行。

### 4.5 Fresh-Instance 评估

#### 4.5.1 Tiny-ViT V4: 标准 HAT 的崩溃

对 Tiny-ViT V4 (均匀噪声 HAT) checkpoint 执行 fresh-instance 评估。单个检查点采用 10 实例  $\times$  5 蒙特卡罗协议; Ensemble HAT 主结果报告三种子汇总均值与种子级标准差。结果来自 `fresh_instance_eval.json` 与 `fresh_instance_eval_v4_standard_noamp.json`。

表 4.5: Tiny-ViT V4 在 CIFAR-10 上的 fresh-instance 评估 (%)。

| 训练协议                 | 源域 Best | Fresh mean | Fresh std |
|----------------------|---------|------------|-----------|
| 标准固定掩膜 HAT (V4)      | 91.94   | 10.00      | 0.00      |
| Ensemble HAT (三种子汇总) | 91.13   | 86.16      | 0.19      |

表 4.5 是本研究的关键 empirical anchor 之一:

- 固定掩膜标准 HAT 在训练实例上表现优异 (91.94%), 但在 10 张全新 D2D 实例上 deterministic 崩溃至  $10.00 \pm 0.00\%$ ;
- 无混合精度 (no-AMP) 对照实验 (`fresh_instance_eval_v4_standard_noamp.json`) 确认了该崩溃是训练目标的 deterministic 结果, 而非数值伪影;
- Ensemble HAT 在三种子汇总协议下将 fresh-instance 均值提升至  $86.16 \pm 0.19\%$ , 较固定掩膜提高 76 pp 以上, 证明轮次级 D2D 重采样是部署级鲁棒性的必要条件。

### 4.5.2 ConvNeXt C4 的 Fresh-Instance 行为

ConvNeXt C4 的 fresh-instance 数据未在已冻结 baseline 中以独立 JSON 归档, 但 `device_comparison_results_gpt.json` 中的零样本器件迁移 (zero-shot device transfer) 提供了间接证据: 当标准 HAT checkpoint 被评估于替代器件配置文件 (如 RRAM、PCM) 时, ConvNeXt 保留部分迁移能力 (如 Organic OPECT 上 71.61%), 而 Tiny-ViT V4 则崩溃至 10.00%。这表明 CNN 的局部感受野结构对 D2D 失配的空间模式具有一定程度的结构吸收性, 而 Transformer 的全局注意力对此更为敏感。

## 4.6 PCM 器件真实感基准测试

前两节基于自定义噪声模型 (§3.2) 报告了有机 OEC-CIM 的算法级基准。本节切换至 IBM AIHWKit 框架内置的 PCM (Phase-Change Memory) 器件预设, 验证核心结论在真实器件物理下的可迁移性: **PCM 器件物理是否支持 4-bit 训练, 而纯量化不能?**

### 4.6.1 实验设置

实验在 AIHWKit v1.2 仿真器上执行, 使用两个 PCM 器件预设:

- **PCMPresetUnitCell** (IBM 手册 GST 合金模型, 默认参数);
- **PCMPresetDevice** (替代器件参数化, 用于验证预设独立性)。

训练协议与自定义噪声模型实验一致: Tiny-ViT-5M、CIFAR-10、4-bit 与 8-bit 权重量化、AnalogSGD 优化器。Fresh eval 与 drift eval 均在  $10 \times 5$  (10 张独立 D2D 实例各 5 次 MC 运行) 体制下执行。Drift 评估在 0 s、1 h、1 d 三个保留时间点进行, 部分配置扩展至 3 d。

### 4.6.2 精度—保持阶梯 (Precision–Retention Ladder)

表 4.6 汇总了 4/6/8-bit PCM 的三种子统计 (zone 3A, 已锁定)。

**表 4.6:** PCM 精度—保持阶梯 (UnitCell 预设, 3-seed 均值  $\pm$  标准差)。

| 精度        | Source best      | Fresh eval       | Drift 0 s | Drift 1 d | Drop 0 s→1 d  |
|-----------|------------------|------------------|-----------|-----------|---------------|
| 8-bit PCM | 77.64 $\pm$ 0.68 | 77.60 $\pm$ 0.64 | 77.61     | 77.57     | −0.04         |
| 6-bit PCM | 77.88 $\pm$ 0.58 | 77.86 $\pm$ 0.56 | 77.85     | 77.74     | −0.10         |
| 4-bit PCM | 76.71 $\pm$ 0.46 | 76.68 $\pm$ 0.37 | 76.64     | 72.64     | − <b>4.01</b> |

关键发现:

- **4-bit PCM 可训练:** 3-seed 均值 76.71%, 跨种子标准差仅 0.46 pp, 证明 PCM 的 conductance-level programming 机制 (而非特定器件参数) 是 4-bit 可训练性的来源;

- **纯量化 4-bit 崩溃**: 所有纯量化基线 (DoReFa、低学习率、低噪声) 均崩溃至  $\sim 10\%$ , 与 4-bit PCM 的 76.71% 形成  $> 66$  pp 的差距;
- **8-bit PCM 保持平坦**: 1 天漂移仅  $-0.04$  pp, 远低于 4-bit 的  $-4.01$  pp, 表明精度-保持权衡是二元的而非渐进的;
- **6-bit 无独立最优区间**: 6-bit 漂移行为 ( $-0.10$  pp) 几乎与 8-bit 重叠, 未落在 4-bit 与 8-bit 之间的中间区域, 因此不存在独立的 6-bit Pareto 最优点。

#### 4.6.3 扩展验证: 预设独立性与噪声必要性

为验证结论的器件模型鲁棒性, 补充执行 Batch B/C/D (表 4.7)。

表 4.7: PCM 扩展验证 (Batch B/C/D)。

| 配置           | Preset                 | Source best | Fresh eval | Drop 0 s $\rightarrow$ 1 d |
|--------------|------------------------|-------------|------------|----------------------------|
| 8-bit PCM    | UnitCell (3-seed mean) | 77.64       | 77.60      | $-0.04$                    |
| 8-bit PCM    | PCMPresetDevice        | 76.88       | 76.80      | $-0.07$                    |
| 4-bit PCM    | UnitCell (3-seed mean) | 76.71       | 76.68      | $-4.01$                    |
| 4-bit PCM    | PCMPresetDevice        | 76.47       | 76.38      | $-3.18$                    |
| 8-bit Oracle | UnitCell (mod=0)       | 76.80       | 76.70      | $-0.27$                    |

**预设独立性 (Batch B)**: PCMPresetDevice 与 UnitCell 在所有指标上差距  $< 1$  pp, drift 趋势一致 (4-bit 退化、8-bit 稳定)。结论从”with PCMPresetUnitCell” 升级为”across PCM presets”。

**Modifier noise 必要性 (Batch C)**: Clean Oracle (modifier\_std\_dev=0) 达到 76.80%, 与带 noise 的 PCMPresetDevice (76.88%) 几乎持平。Modifier noise 的贡献约为  $+0.8$  pp, 属于有益但不决定性的正则化, 而非必要条件。旧诊断中”oracle  $\sim 61\%$ ” 已被证伪 (provenance 问题)。

#### 4.6.4 负面基线与消融

表 4.8 汇总了所有纯量化负面基线, 证明 4-bit 可训练性是 PCM 物理特有的。

表 4.8: 纯量化 4-bit 负面基线 (全部崩溃)。

| 配置                     | Best Test Accuracy |
|------------------------|--------------------|
| Pure 4-bit, mod=0.0001 | $\sim 10\%$        |
| Pure 4-bit, mod=0.01   | $\sim 10\%$        |
| Pure 4-bit, low lr     | $\sim 19\%$        |
| Pure 4-bit + DoReFa    | 11.49%             |

### 4.6.5 扩展漂移评估

部分配置执行了 10 点时间点至 3 天的扩展漂移评估 (zone 3A):

- 4-bit PCM: 0 s 76.63%  $\rightarrow$  3 d 71.85%, 累计下降  $-4.78$  pp;
- 8-bit PCM: 0 s 77.60%  $\rightarrow$  3 d 77.70%, 漂移平坦 ( $+0.10$  pp, 在统计噪声范围内)。

4-bit 的退化模式符合低电导态 read noise + drift 更显著的 PCM 物理预期。

## 4.7 讨论与小结

### 4.7.1 架构比较的三条规律

综合表 4.1–4.5, 可提炼三条跨架构规律:

**规律 1: 数字基准与模拟回收之间的差距随任务复杂度扩大。** CIFAR-10 上 ConvNeXt C4 与数字基准仅差 0.83 pp; CIFAR-100 上差距扩大至 3.58 pp; Flowers-102 上 Tiny-ViT V4 与 V1 差距达 75.49 pp。这说明模拟噪声的信息论损失在类别数增加、训练数据减少时被非线性放大。

**规律 2: 预训练 Transformer 在数据丰富场景下具有最高的数字基准与噪声基线, 但在数据稀缺场景下衰退最快。** Tiny-ViT V3 在 CIFAR-10 上 (89.54%) 显著优于 ConvNeXt C3 (70.48%), 但在 Flowers-102 上两者均崩溃至  $< 5\%$ 。这反映了全局注意力对高质量特征提取的依赖: 当噪声破坏了 patch 嵌入的细粒度判别信号时, 注意力权重无法通过上层交互予以恢复。

**规律 3: Fresh-instance 协议是区分诊断性救援与部署级鲁棒性的唯一可靠标准。** 固定掩膜 HAT 在所有源域评估中均表现良好, 但 fresh-instance 暴露其本质为实例特定过拟合。Ensemble HAT 的 86.16% fresh-instance 精度构成部署级鲁棒性的主要证据。

### 4.7.2 本章小结

本章报告了三条实验线的已冻结 baseline 结果:

1. **自定义噪声模型:** ResNet-18、ConvNeXt-Tiny 与 Tiny-ViT V1–V6 在 CIFAR-10/100、Flowers-102 及 ImageNet-1k 上的数字基准、噪声基线与 HAT 回收精度;
2. **PCM 器件真实感:** 4/6/8-bit PCM 在 AIHWKit 框架下的精度-保持阶梯, 以及 Batch B/C/D 的预设独立性与噪声必要性验证;
3. **Fresh-instance 鲁棒性:** Ensemble HAT 将 Tiny-ViT 从实例过拟合的 10.00% 恢复至  $86.16 \pm 0.19\%$ 。

核心结论 (zone 3A):

- HAT 回收幅度随任务复杂度与数据稀缺性递减;
- PCM 器件物理支持 4-bit 训练 ( $76.71 \pm 0.46\%$ ), 而所有纯量化 4-bit 基线均崩溃 ( $\sim 10\%$ );

- 精度-保持权衡是二元的：8-bit PCM 漂移平坦 ( $-0.04$  pp/1 d)，4-bit PCM 退化显著 ( $-4.01$  pp/1 d)；
- 结论跨 PCM 预设鲁棒 (UnitCell vs PCMPresetDevice 差距  $\leq 1$  pp)。

这些结果为后续章节分析具体失效模式（ADC 精度悬崖、严重写入非线性、保留漂移、相关 D2D、精度-保持权衡）提供了不可或缺的定量参照系。



## 第五章 失效模式与诊断框架

### 5.1 引言：从症状到机制

第4章建立了基准性能数字，第3章梳理了硬件感知训练的技术谱系。本章的任务是将前两章的实证结果组织成一个系统的失效模式分类学，并针对每种模式给出可操作的诊断协议。诊断框架的核心问题是：当部署准确率低于预期时，如何在不重新制造芯片的情况下定位主导瓶颈？

有机光电存内计算 (OEC-CIM) 的失效模式具有层级嵌套特征。低层物理非理想性 (D2D 失配、C2C 噪声、写入非线性、ADC 量化、保持漂移) 通过模拟 MAC 阵列的权重-激活映射耦合到高层算法表现。同一物理参数在不同网络深度和不同任务复杂度下可能触发截然不同的失效签名。因此，单纯的“准确率下降”不足以指导干预；必须将下降分解为可归属的物理来源。

本章提出一个五层诊断栈：

1. **实例级诊断**：区分训练实例过拟合与真正的新鲜实例脆弱性；
2. **模块级诊断**：定位瓶颈所在的功能块（嵌入层、QKV 投影、注意力输出、MLP 前馈）；
3. **参数级诊断**：量化各物理参数 ( $\sigma_{D2D}$ 、 $\sigma_{C2C}$ 、 $NL$ 、ADC 位宽、 $\gamma_{phys}$ ) 的独立贡献；
4. **时序级诊断**：识别退化是瞬时（一次性编程误差）还是累积（保持漂移、温度循环）；
5. **统计级诊断**：判断样本方差是物理随机性还是训练过程中的系统性偏差。

以下各节按此栈展开。

### 5.2 失效模式分类学

#### 5.2.1 模式一：硬件实例过拟合 (Hardware-Instance Overfitting)

**触发条件**：固定掩码 HAT (Standard HAT) 在任意  $NL$  和噪声组合下训练。

**失效签名**：训练实例准确率  $\gg 70\%$ ，新鲜实例准确率  $\approx 10\%$  (CIFAR-10 平衡基线)。分布不是高斯弥散，而是单类预测器：模型对所有输入输出同一类别。

**机理**：固定 D2D 掩码使优化器将权重调整到与该特定失配模式共适应。当测试时的 D2D 实现改变时，共适应失效，特征几何崩溃。

**诊断测试**：在 10 个独立 D2D 实例上运行新鲜实例评估。若所有实例均收敛至同一低值 ( $\approx 10\%$ )，且跨实例标准差  $< 0.5$  pp，则诊断为实例过拟合。若部分实例表现良好而 others 崩溃，则提示存在异常值敏感而非纯粹的过拟合。

**已知数据 (zone 3A) :** Tiny-ViT V4 Standard HAT 在  $NL = 1.0$ 、 $\sigma_{D2D} = 10\%$ 、 $\sigma_{C2C} = 5\%$  下, 训练最优  $87.95 \pm 0.27\%$ , 新鲜实例  $10.00 \pm 0.00\%$  ( $n = 10$  实例  $\times 5$  MC 运行)。

**干预:** Ensemble HAT (每轮 D2D 重采样) 将新鲜实例准确率恢复至  $86.16 \pm 0.19\%$  (zone 3A)。

### 5.2.2 模式二: 尺度掩蔽区 (Scale-Masking Regime)

**触发条件:** 低  $\sigma_{D2D}$  ( $< 5\%$ ) 与 4bit 量化共存。

**失效签名:** 混合控制 (V2, 零噪声、4bit 映射) 的准确率接近 FP32 基线 (97.39%), 但加入少量 D2D 噪声后退化极慢。噪声被“掩蔽”在量化 LSB 以下。

**机理:** 恢复权重定律  $w_{\text{rec}} = s_{\ell}(g_{\ell} + \delta g_{\ell}) + b_{\ell}$  将噪声扰动  $\delta g_{\ell}$  映射回数字域时, 许多受扰动的电导实现落入同一恢复权重 bin。量化阶梯的离散性因此起到隐式去噪作用。

**诊断测试:** 比较 V2 (零噪声) 与 V3 (10% D2D) 的准确率差异。若差异  $< 2$  pp, 则处于尺度掩蔽区。

**边界条件:** 尺度掩蔽只在噪声为状态无关 (均匀加性) 时有效。一旦噪声律变为状态依赖 ( $NL \neq 1.0$  或比例噪声), 掩蔽效应消失。

### 5.2.3 模式三: ADC 精度悬崖

**触发条件:** ADC 分辨率低于 6bit。

**失效签名:** 准确率从  $> 80\%$  骤降至  $\approx 10\%$  (近随机)。退化不是渐进的, 而是在 5–6bit 边界处出现悬崖式跳跃 ( $\sim 7$  pp)。

**机理:** 低于 6bit 时, 层间激活量化误差超过 D2D 失配成为主导噪声源。注意力 softmax 对输入分布的小扰动极度敏感, ADC 截断引入的离散误差破坏了 token 间的相对排序。

**诊断测试:** 系统扫描 ADC 位宽  $\in \{2, 3, 4, 5, 6, 7, 8, 10, 12\}$ 。若 5bit 与 6bit 之间存在  $> 5$  pp 的跳跃, 则确认 ADC 悬崖。

**已知数据 (zone 3A) :** 63 点联合扫描 ( $\sigma_{D2D} \in \{1, 3, 5, 8, 10, 15, 20\}\%$ ,  $\text{ADC} \in \{2, 3, 4, 5, 6, 7, 8, 10, 12\}\text{bit}$ ) 显示  $S_{\text{ADC}} = 0.98$  (全网格), 5–6bit 过渡平均  $\sim 7$  pp (per-row 5.8–8.1 pp)。

**设计规则:** 有机 OEC-CIM 部署的 ADC 分辨率不得低于 6bit。

### 5.2.4 模式四: 空间相关 D2D 退化

**触发条件:** D2D 失配具有空间相关性 (AR(1) 核、晶圆级梯度、各向异性协方差)。

**失效签名:** 均值单调下降, 方差随相关强度增加而扩大, 但无灾难性崩溃。最差实例仍远高于随机水平。

**机理:** 空间结构将独立噪声的“平均化优势”部分抵消。Ensemble HAT 的逐轮重采样假设空间独立性; 当真实相关性  $\rho > 0$  时, 训练分布的支撑集小于测试分布, 导致有

界但可测的退化。

**诊断测试：**从晶圆图或实测数据估计空间协方差核。若存在显著非对角元素，则计算等效  $\rho$  并插值至已知 AR(1) 表。

**已知数据 (zone 3A)：**三种子主口径下  $\rho = 0$  基线为  $86.16 \pm 0.19\%$ ；相关失配扫描给出  $\rho = 0.3$  时  $84.57 \pm 2.39\%$  ( $-1.76$  pp) 与  $\rho = 0.5$  时  $82.12 \pm 3.95\%$  ( $-4.20$  pp)。最差实例  $73.7\%$  (instance 4,  $\rho = 0.5$ )。单调退化，排名保持。

**设计规则：**若晶圆图显示  $\rho \approx 0.3$ ，将  $84.57\%$  作为保守准确率下限； $\rho \approx 0.5$  时以  $82.12\%$  为应力测试边界。

### 5.2.5 模式五：保持漂移

**触发条件：**器件在编程后经历时间、温度或光照漂移。

**失效签名：**快速早期下降 ( $<1s$  内  $\sim 9$  pp)，随后进入宽平台期 ( $\approx 79\%$ ,  $79.13\text{--}79.51\%$  至  $10^4s$ )。

**机理：**有机光晶体管的电导状态在初始编程后快速弛豫，随后达到亚稳态。平台期宽度取决于材料保持时间和环境条件。

**诊断测试：**时间序列评估 ( $0s, 1s, 10s, 100s, 1000s, 10000s$ )。若观察到快速下降后平稳，则符合均匀衰减模型。

**已知数据 (zone 3A)：**V8 保持感知模型在  $0s$  时  $91.63\%$ ， $1s$  时  $82.66\%$ ， $10^4s$  时  $79.13\text{--}79.51\%$ 。

**干预：**动态尺度重校准（在推断栈中周期性地重新读取参考单元）可将平台期准确率维持在  $\sim 79\%$ 。

### 5.2.6 模式六：严重非线性写入

**触发条件：** $|NL| \gg 1$  (典型  $NL_{LTP} = 2.0$ ,  $NL_{LTD} = -2.0$ )。

**失效签名：** $NL = 1.0$  基线  $\sim 86\%$ ； $NL = 2.0$  时降至  $\sim 80\text{--}82\%$  (修订梯度缩放配方后)。退化是系统性的 (跨实例标准差  $<2$  pp)，而非随机的。

**机理：**一阶代理梯度在  $NL = 2.0$  时产生状态依赖的 LTP/LTD 不对称缩放。该不对称性重塑了优化景观，使注意力通路的特征几何对 D2D 实现的变化更加敏感。然而，与先前基于污染实现报告的  $\sim 30\%$  不同，修订配方下的系统性退化表明瓶颈是可量化的代理梯度近似误差，而非不可逾越的结构壁垒。

**诊断测试：**在  $NL \in \{1.0, 1.5, 2.0\}$  上扫描，同时保持其他参数恒定。若退化单调且跨训练种子可重复，则归因于 NL 失真。

**已知数据 (zone 3C)：**M 系列 6 次训练全部收敛至  $\sim 80\text{--}82\%$  带。Standard 与 Ensemble 均值差  $<1$  pp，比例噪声与均匀噪声差  $<0.1$  pp。8bit ADC-on hook diagnostic 仅比 ADC-off 低  $\sim 0.10$  pp (基于训练时代理想电导阵列校准的推断时钩子，非物理 ADC 边界)。

**干预：**设备层面线性化 (降低  $|NL|$ ) 可恢复  $\sim 5$  pp；算法层面高阶梯度修正或更大

批量训练可能进一步缩小残余差距。

### 5.2.7 模式七：精度-漂移权衡 (Precision-Retention Trade-off)

**触发条件：**PCM 器件在低精度 (4-bit) 电导态下训练并经历时间漂移。

**失效签名：**源域精度接近高精度配置 (4-bit PCM 76.71% vs 8-bit PCM 77.64%，差距仅 0.93 pp)，但 1 天漂移后差距急剧扩大至 4.94 pp (4-bit 72.64% vs 8-bit 77.57%)。退化不是渐进的，而是在 4-bit 与 6/8-bit 之间呈现二元跳跃：6-bit 漂移行为 ( $-0.10$  pp/1 d) 几乎与 8-bit ( $-0.04$  pp/1 d) 重叠，未落在 4-bit ( $-4.01$  pp/1 d) 与 8-bit 之间的中间区域。

**机理：**PCM 的低电导态具有更大的编程噪声和更快的漂移系数 ( $\nu$  更大)。4-bit 量化将权重压缩至更少的电导层级，使得每个态的相对漂移贡献被放大。同时，低电导态的读取噪声 (与  $\sqrt{G}$  成比例) 在绝对值上虽小，但相对于有限的态间距仍足以引起跨层级跳变。

**诊断测试：**在相同训练配置下比较 4/6/8-bit 的源域精度与 1 天漂移精度。若 4-bit 源域接近 8-bit 但漂移后差距  $> 3$  pp，则确认精度-漂移权衡是部署瓶颈。

**已知数据 (zone 3A)：**4-bit PCM (UnitCell 3-seed mean)：源域  $76.71 \pm 0.46\%$ ，漂移 1 d  $72.64 \pm 0.71\%$ ，下降  $-4.01$  pp；8-bit PCM：源域  $77.64 \pm 0.68\%$ ，漂移 1 d  $77.57 \pm 0.61\%$ ，下降  $-0.04$  pp；6-bit PCM：源域  $77.88 \pm 0.58\%$ ，漂移 1 d  $77.74\%$ ，下降  $-0.10$  pp。

**设计规则：**4-bit PCM 是可训练但保持受限的 (trainable but retention-limited)。若部署场景允许周期性刷新 (如光学刷新，见第 六 章)，4-bit 可提供接近 8-bit 的源域精度；若刷新不可用，则 8-bit 是唯一漂移安全的选择。

### 5.2.8 模式间耦合与复合应力

上述七种模式并非互斥。实际部署中常见的复合应力包括：

- **NL + 相关 D2D：**非线性放大空间结构的影响，但尚无 zone 3C 数据；
- **NL + 保持漂移：**时间漂移与 NL 梯度失真叠加，可能加速退化；
- **ADC 悬崖 + 高  $\sigma_{D2D}$ ：**两种噪声源耦合，使操作窗口变窄。

当前框架对复合应力的覆盖是有限的。第 七 章将操作包络建模为独立参数贡献的叠加，但真实耦合效应 (如 Sobol 交互项  $< 4\%$  的 iso-精度区域) 仍需实验验证。

## 5.3 诊断协议

### 5.3.1 协议 A：快速实例级筛选

**目标：**在  $< 1$  GPU 小时内判断一个训练检查点是否存在实例过拟合。

**步骤：**

1. 在训练实例上评估最佳检查点。若  $<70\%$ ，直接判定为训练失败，无需新鲜实例测试。
2. 若  $>70\%$ ，在 3 个独立 D2D 实例上各运行 1 次 MC 评估（共 3 个新鲜实例）。
3. 若 3 个实例均  $<15\%$ ，判定为实例过拟合（高置信度）。
4. 若 3 个实例分散（如 30%、85%、10%），提示异常值敏感或训练不稳定，需扩展至 10 实例。

**成本：**  $\sim 0.3$  GPU 小时（3 实例  $\times$  1 运行）。

### 5.3.2 协议 B：模块级瓶颈定位

**目标：** 确定瓶颈功能块（嵌入、QKV、输出投影、MLP）。

**步骤：**

1. 冻结训练好的检查点，在推断时逐组线性化（ $NL = 1.0$ ）。
2. 记录每组线性化后的准确率变化。
3. 若线性化 MLP 恢复  $>80\%$  而线性化 QKV 崩溃至  $<20\%$ ，则瓶颈在注意力通路。
4. 若线性化所有组后仍  $<50\%$ ，则瓶颈是全局性的（如 ADC 悬崖或极端  $\sigma_{D2D}$ ）。

**已知结果 (pre-fix diagnostic)：** QKV 单独线性化  $\rightarrow 18.72\%$ ；输出投影单独线性化  $\rightarrow 18.86\%$ ；MLP 单独线性化  $\rightarrow$  接近基线。注意力通路是瓶颈。这些数值来自 config-sharing bug 与 pre-fix STE 语义下的历史实验，仅作为诊断协议 B 的示例输出，不应用作修订配方下的 zone 3A 主张。

### 5.3.3 协议 C：参数敏感性排序

**目标：** 用最小实验量确定主导物理参数。

**步骤：**

1. 运行 63 点联合扫描（ $\sigma_{D2D} \times \text{ADC}$ ）的稀疏子集（如  $\sigma_{D2D} \in \{5, 10, 20\}\%$ ， $\text{ADC} \in \{4, 6, 8\}\text{bit}$ ，各 3 MC 运行）。
2. 计算各参数的一阶 Sobol 指数  $S_i$ 。
3. 若  $S_{\text{ADC}} > 0.9$ ，则 ADC 是主导；若  $S_{D2D} > 0.9$ ，则 D2D 是主导。
4. 若两者均  $<0.6$ ，提示存在未建模因素（如 NL 或温度）。

**已知结果 (zone 3A)：** 全网格  $S_{\text{ADC}} = 0.98$ ；操作区  $S_{D2D} = 0.92$ ；交互  $<4\%$ 。

### 5.3.4 协议 D：时序退化特征提取

**目标：** 区分保持漂移、温度漂移和一次性编程误差。

**步骤：**

1. 在编程后  $t \in \{0, 1, 10, 100, 1000, 10000\}\text{s}$  评估。

2. 若快速下降后平台，符合保持漂移模型；
3. 若单调下降无平台，提示持续应力（如光照或偏压）；
4. 若波动无趋势，提示读出噪声或温度循环。

## 5.4 案例研究

### 5.4.1 案例一：从 10% 到 86%——实例过拟合的治愈

**背景：**Tiny-ViT V4 Standard HAT 在  $NL = 1.0$  下训练最优 87.95%，新鲜实例 10.00%。

**诊断：**协议 A（3 实例筛选）判定为实例过拟合。协议 B（模块级定位）显示所有模块均匀崩溃，确认全局共适应。

**干预：**Ensemble HAT（每轮 D2D 重采样）。

**结果：**新鲜实例恢复至  $86.16 \pm 0.19\%$  (zone 3A)。这里的 0.19 pp 为三种子汇总标准差，远小于 10 pp 量级的崩溃阈值。

**启示：**实例过拟合是训练目标问题，不是物理模型问题。改变目标（从单实例记忆到分布期望）即可治愈。

### 5.4.2 案例二：OPECT 零样本迁移

**背景：**文献校准的 OPECT 器件轮廓 ( $\sigma_{C2C} = 2\%$ ,  $\sigma_{D2D} = 3\%$ )。

**诊断：**协议 C（参数排序）预测 D2D 贡献低 ( $\sigma_{D2D} = 3\% < 10\%$ )，ADC 贡献可忽略 ( $>6\text{bit}$ )。预期高准确率。

**干预：**无重训练，直接将 Ensemble HAT 检查点零样本部署。

**结果：** $88.53 \pm 0.08\%$  (zone 3A)。

**启示：**当物理参数落在 iso-精度图的安全区时，Ensemble HAT 的分布训练目标自动泛化到新轮廓。

### 5.4.3 案例三：严重 NL 下的 M 系列证据

**背景：** $NL = 2.0$  严重非线性，修订梯度缩放配方。

**诊断：**协议 A 在 6 个独立训练上运行。所有 6 个检查点的新鲜实例均值  $>80\%$ ，跨实例标准差  $<2$  pp，排除实例过拟合。

**干预对比：**

- Standard HAT（固定掩码）：81.2% 均值 (zone 3C)；
- Ensemble HAT（均匀噪声，重采样）：80.7% 均值 (zone 3C)；
- Ensemble HAT（比例噪声，重采样）：80.7% 均值 (zone 3C)。

**结果：**三种干预收敛至同一  $\sim 80\text{--}82\%$  带。差距关闭至  $<1$  pp，表明 severe NL 已成为绑定约束，训练协议优化收益饱和。

**启示：**当代理梯度失真超过阈值后，进一步改进训练目标（从重采样到噪声律对齐）的边际收益消失。设备层面的线性化或算法层面的高阶修正成为优先方向。

#### 5.4.4 案例四：比例噪声的体制特异性

**背景：**比例噪声在  $NL = 1.0$  下达到  $97.37 \pm 0.05\%$ ，但向均匀噪声迁移时崩溃至  $10.38 \pm 0.44\%$ 。

**诊断：**协议 C 显示噪声律不匹配是主导因素。比例噪声训练的权重几何与均匀噪声测试的扰动分布不兼容。

**干预：**无（体制特异性是特征，不是缺陷）。

**结果：**比例噪声检查点在其匹配体制下表现优异，但无跨体制泛化能力。

**启示：**训练噪声律必须与部署噪声律严格对齐。先诊断，再训练的顺序不可颠倒。

### 5.5 本章小结与向第六章的过渡

本章建立了一个**七模式分类学**和四层诊断协议栈，将有机 OEC-CIM 部署中的准确率退化归因到可操作的物理来源：

表 5.1: 失效模式速查表

| 模式      | 触发                             | 签名                                | 主导参数    | 干预              |
|---------|--------------------------------|-----------------------------------|---------|-----------------|
| 实例过拟合   | 固定掩码训练                         | 10% 单类预测                          | 训练目标    | Ensemble HAT    |
| 尺度掩蔽    | 低 $\sigma_{D2D} + 4\text{bit}$ | 退化 $< 2\text{ pp}$                | ADC 位宽  | 无需干预            |
| ADC 悬崖  | $< 6\text{bit}$ ADC            | $> 5\text{ pp}$ 跳跃                | ADC 位宽  | $> 6\text{bit}$ |
| 相关 D2D  | 空间结构                           | 单调有界退化                            | $\rho$  | 保守下限            |
| 保持漂移    | 时间/温度                          | 快速下降 + 平台                         | 保持时间    | 动态重校准           |
| 严重 NL   | $ NL  \gg 1$                   | 系统性 $\sim 5\text{ pp}$ 降          | $NL$    | 设备线性化/高阶修正      |
| 精度-漂移权衡 | PCM 4-bit + 时间                 | 源域近 8-bit, 1d 后 $\gg 3\text{ pp}$ | 电导态数/保持 | 刷新或升精度          |

关键结论是层级性的：

1. 训练目标（实例过拟合）是最易修复的瓶颈，Ensemble HAT 提供  $+76\text{ pp}$  的增益；
2. ADC 位宽是最硬的设计规则，低于 6bit 无挽救可能；
3. 精度-漂移权衡是 PCM 部署特有的精度-保持瓶颈，4-bit 可训练但保持受限，8-bit 漂移安全；
4. 严重 NL 是最复杂的系统级瓶颈，需要设备-算法协同优化，而非单一训练技巧。

这些诊断工具和案例研究为第**七**章的部署框架提供了输入。下一章（第**七**章）将把这些理想化诊断置于更完整的物理语境中，引入 IR 压降、sneak 路径、温度依赖性和实

测空间协方差核。

## 第六章 大语言模型 KV 缓存的有机光电存内计算映射

### 6.1 研究动机

#### 6.1.1 大语言模型推理的存储瓶颈

大语言模型 (LLM) 的能力随参数与上下文规模扩展而提升, 但推理部署成本——尤其是面向终端用户的自回归解码——对延迟、吞吐和能效提出了严苛约束。

**边缘推理** (edge inference) 对存储容量、计算带宽和电池能量均有严格约束。以典型智能手机为例, 其可用 DRAM 为 4–12 GB, 而 7B 参数 LLM 的 FP16 权重即需约 14 GB, 加上 KV 缓存后远超设备容量; 即使采用 4-bit 量化权重, KV 缓存的动态增长仍可能迅速耗尽内存。

在自回归解码过程中, 模型每生成一个新 token, 都需要计算当前 token 与此前所有已生成 token 之间的注意力 (attention) 分数。若采用朴素的重复计算策略, 每步解码的时间复杂度为  $O(n^2)$ , 其中  $n$  为已生成序列长度。为避免这一平方级开销, 现代 Transformer 实现引入了**键值缓存** (Key-Value Cache, **KV 缓存**) 机制: 在初始的预填充 (prefill) 阶段, 模型一次性计算并存储所有输入 token 的 Key (K) 和 Value (V) 张量; 在后续的解码 (decode) 阶段, 只需将新生成 token 的 K、V 追加至缓存, 并基于完整的 K、V 集合计算注意力。此举将每步解码的计算复杂度降至  $O(n)$ , 但代价是显存占用随序列长度线性增长。

KV 缓存的存储开销可量化为:

$$M_{KV} = 2 \times L \times H \times D_h \times S \times P \quad (6.1)$$

其中,  $L$  为 Transformer 层数,  $H$  为注意力头数,  $D_h$  为每头维度,  $S$  为当前序列长度,  $P$  为精度字节数 (如 FP16 下  $P = 2$ )。以 LLaMA-2-7B 为例,  $L = 32$ ,  $H = 32$ ,  $D_h = 128$ , 在上下文长度  $S = 4096$  时, 单批次 FP16 KV 缓存即达 **2 GiB**; 当扩展至 32k 上下文或更大批次时, KV 缓存可轻松超过模型权重本身的存储 footprint。对于边缘设备 (edge device) 而言, 如此庞大的动态存储需求已成为部署 LLM 的首要瓶颈。

#### 6.1.2 现有数字方案的固有折衷

针对 KV 缓存的存储爆炸问题, 学术界与工业界提出了四类主要缓解策略, 但均在精度、延迟或系统复杂度之间存在根本性折衷。

(1) **量化压缩**。代表性工作如 KIVI<sup>41</sup> 提出对 Key 采用逐通道 (per-channel) 非对称量化、对 Value 采用逐 token (per-token) 非对称量化, 将 KV 缓存压缩至 2–4 bit, 从而将存储开销降低 4–8 倍。然而, 极低比特量化不可避免地引入重构误差, 在长上下

文场景下误差累积可导致注意力分布偏移,进而影响下游任务性能。此外,量化/反量化操作本身引入额外计算开销,在低功耗边缘场景下不可忽略。

**(2) 动态驱逐。**StreamingLLM<sup>42</sup>、H<sub>2</sub>O<sup>43</sup>等方法基于注意力分数的稀疏性,识别并驱逐“不重要”的历史 token 对应的 K、V 条目,以固定缓存容量上限。此类方法的局限在于:首先,注意力稀疏性分布与任务类型强相关,通用场景下难以保证稳定的精度下界;其次,驱逐决策本身需要维护辅助数据结构(如注意力汇聚池),增加了控制逻辑复杂度;最后,被驱逐的 token 一旦需要重新引入(如多轮对话中的指代回溯),将触发代价高昂的重新计算。

**(3) 分层卸载。**InfiniGen<sup>44</sup>、vLLM<sup>45</sup>等系统采用 CPU DRAM 甚至 NVMe SSD 作为 KV 缓存的二级存储,通过精细的调度策略在 GPU 高带宽存储与主机大容量存储之间搬运数据。尽管此类方案在数据中心场景有效,但其核心假设——高带宽互联与充足的主机内存——在边缘设备上并不成立。边缘 SoC 的片外带宽有限,频繁的 KV 搬运会显著推高每 token 解码延迟和系统能耗。

**(4) 稀疏注意力。**除存储优化外,另一路线通过算法层面降低注意力的计算和存储复杂度,如 FlashAttention<sup>46</sup>通过 IO 感知的 tiling 策略减少 HBM 访问,稀疏注意力变体(BigBird、Longformer)通过固定模式或学习模式限制每个 token 的注意力邻居数。然而,FlashAttention 优化的是计算—存储之间的数据流,并未减少 KV 缓存的容量需求;稀疏注意力虽可降低有效 KV 存储,但其稀疏模式通常需要训练阶段适配,对预训练模型的即插即用性有限,且在某些任务(如需要全局依赖的推理)中精度损失显著。

上述分析指出了一个共同困境:**数字存储体系在“容量—精度—能效”三角中无法同时满足 LLM KV 缓存的需求**。SRAM 速度快但面积代价高昂且易失;DRAM 容量大但刷新功耗显著,且与计算单元分离导致数据搬运开销大;Flash 非易失但读写延迟高、耐久性差,无法承受频繁的 KV 追加写入。因此,探索与 KV 缓存访问模式在物理层面更为匹配的新型存储计算范式,具有重要的理论价值与应用前景。

### 6.1.3 KV 缓存与注意力机制的计算特征

为理解为何 CIM 适用于 KV 缓存场景,需进一步分析注意力机制的计算特征。在解码阶段,给定查询向量  $q_t \in \mathbb{R}^{D_h}$ ,注意力计算分为两步:

$$s_{ti} = \frac{q_t \cdot k_i^T}{\sqrt{D_h}}, \quad \alpha_{ti} = \frac{\exp(s_{ti})}{\sum_{j=1}^S \exp(s_{tj})} \quad (6.2)$$

$$o_t = \sum_{i=1}^S \alpha_{ti} v_i \quad (6.3)$$

第一步  $q_t K^T$  为向量—矩阵乘法 ( $1 \times D_h$  乘以  $D_h \times S$ ),输出注意力分数  $s_t \in \mathbb{R}^S$ ;第二步  $\alpha_t V$  为加权向量求和。两步均为线性操作,天然适合映射至模拟交叉阵列的欧姆定律—基尔霍夫定律计算框架。

KV 缓存的**静态性**(prefill 后极少变更)使得电导编程可为离线或低频率操作,而注意力计算的**动态性**(每步解码的  $q_t$  不同)要求读取延迟极低。这一“慢写快读”的特

征正好与 CIM 交叉阵列的物理优势吻合：模拟 MVM 的读取可在纳秒至微秒量级完成，而电导编程（无论电学或光学）通常需要微秒至毫秒量级。在 KV 缓存场景中，写操作仅发生在预填充和新 token 生成时，读操作则发生在每步解码中，读写频率比可达 1:100 甚至 1:1000，因此写延迟的相对劣势被读延迟的显著优势所抵消。

#### 6.1.4 存内计算的技术机遇

存内计算（Compute-in-Memory, CIM）通过在存储阵列内部完成矩阵向量乘积（Matrix-Vector Multiplication, MVM），消除了传统冯·诺依曼架构中存储器与处理器之间的数据搬运开销。对于 Transformer 注意力机制而言，核心计算可抽象为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{D_h}}\right)V \quad (6.4)$$

其中  $QK^T$  和加权求和两步均可映射为 MVM 操作，天然适合交叉阵列（crossbar array）实现。若能将 KV 缓存直接存储于模拟 CIM 阵列，并以模拟域计算注意力分数，则可在同一物理位置完成“存储—计算—更新”的全流程，从根本上消除 KV 缓存的数据搬运瓶颈。

KV 缓存的数据搬运开销在边缘场景中尤为突出。假设一个 1B 参数的 LLM 在 4k 上下文下运行，每解码步需读取全部 KV 条目以计算注意力，产生的数据搬运量可达数十 MB。在带宽受限的边缘 SoC 上，这部分搬运能耗可能占总推理能耗的 30% 以上（文献估计值，FlashAttention 等研究表明解码阶段 KV 缓存读取是内存带宽主导的主要开销来源）。CIM 的核心价值在于将“搬运数据至计算单元”转化为“在数据原地计算”，从而打破冯·诺依曼瓶颈。对于 KV 缓存这一“高频读取、极少写入”的负载，CIM 的收益尤为显著：读取操作直接对应于模拟 MVM 计算，无需额外的数据搬出。

然而，并非所有 CIM 技术均适用于 KV 缓存场景。SRAM-CIM 虽速度快，但易失性意味着 KV 缓存需持续供电维持，待机功耗不可忽视；氧化物 RRAM-CIM 虽非易失，但其过度规格的保持时间和耐久性带来了不必要的写能耗和器件变异代价。如后文所述，有机光电模拟 CIM 因其独特的保持时间—耐久性组合和光学刷新能力，成为与 KV 缓存访问模式最具物理匹配性的候选方案。本章将系统阐述这一物理匹配性的理论基础，界定研究目标与评估框架，并详细规划验证该假设的实验体系。

## 6.2 有机光电 CIM 的物理匹配性

### 6.2.1 KV 缓存的访问模式特征

要判断某种存储技术是否适配 KV 缓存，需首先精确描述 KV 缓存的访问模式特征。从系统层面看，KV 缓存的生命周期呈现以下三个显著特点：

**写入频率低（write-once-per-prefill）。**在典型的自回归解码流程中，每个 token 的 K、V 张量仅在预填充阶段或新生成时被写入一次；在随后的所有解码步中，该条目仅被读取用于注意力计算，几乎不被原地修改。这一“一次写入、多次读取”（Write-

Once-Read-Many, WORM) 模式对存储技术的写耐久性 (write endurance) 要求极为宽松。

**读取频率高且随机。**在每一步解码中, 模型需要读取当前层全部历史 token 的 K、V 条目以计算注意力分数。对于长序列, 这意味着对 KV 缓存的高频随机访问。因此, 存储技术的读取延迟和读取能耗对系统性能具有决定性影响。

**会话级生命周期。**KV 缓存的生命周期与一次用户会话 (session) 绑定, 通常为秒至分钟量级。会话结束后, KV 缓存可被整体释放或转存至持久层。这意味着存储技术无需具备年乃至十年级的数据保持能力, 亦无需支持百万次以上的编程循环。

### 6.2.2 存储技术的保持时间—耐久性匹配分析

基于上述访问模式, 可从保持时间 (retention time) 和耐久性 (endurance) 两个维度评估各类新兴存储技术的适配度。为量化这一匹配关系, 定义以下两个匹配指标:

$$\eta_{\tau} = \frac{\tau_{\text{device}}}{\tau_{\text{session}}}, \quad \eta_E = \frac{E_{\text{max}}}{N_{\text{write}}} \quad (6.5)$$

其中  $\eta_{\tau}$  为保持时间裕度,  $\eta_E$  为耐久性裕度。理想情况下, 两者均应  $\geq 1$  以提供足够的操作裕度, 但过大的裕度意味着器件为过少的需求支付了过高的物理代价。

如表 6.1 所示, 不同技术在  $\tau$ - $E$  平面上分布于截然不同的区域。

表 6.1: 存储技术与 KV 缓存需求的物理匹配度比较

| 技术                                          | 保持时间            | 耐久性             | 面积效率         | 光学刷新 |
|---------------------------------------------|-----------------|-----------------|--------------|------|
| SRAM                                        | ms 级 (易失)       | $> 10^{15}$     | 低 (6T/8T 单元) | 不支持  |
| 氧化物 RRAM ( $\text{HfO}_2$ )                 | 年 ( $> 10^8$ s) | $> 10^6$        | 中            | 不支持  |
| PCM ( $\text{Ge}_2\text{Sb}_2\text{Te}_5$ ) | 年 ( $> 10^8$ s) | $> 10^8$        | 中            | 不支持  |
| FeFET                                       | 月—年             | $> 10^5$        | 高            | 不支持  |
| 有机 OEC-RAM                                  | $\sim 10^3$ s   | $10^3$ – $10^4$ | 高            | 支持   |

**SRAM** 作为传统高速缓存, 具备极低的访问延迟和极高的耐久性, 但其易失性 (volatile) 要求持续供电以维持数据, 待机功耗随容量线性增长。以 7nm 工艺为例, SRAM 单元面积约为  $0.031\mu\text{m}^2$ , 而氧化物 RRAM 单元面积可小至  $0.002\mu\text{m}^2$  以下, 有机 OEC-RAM 单元面积预期与 RRAM 相当或更优。因此, SRAM 在面积效率上存在数量级劣势, 难以在有限芯片面积内容纳长上下文所需的 KV 缓存。此外, SRAM-CIM 的读取操作本质上是电荷共享, 信号摆幅小, 对工艺变异敏感, 难以实现高信噪比的模拟计算。对于 GB 级的 KV 缓存, SRAM 的漏电功耗在边缘电池供电场景下不可接受。

**氧化物 RRAM** (如  $\text{HfO}_2$  基器件) 和 **PCM** 具备非易失性和良好的面积效率, 但其保持时间以年为单位, 耐久性达  $10^6$ – $10^8$  次循环, 对于 KV 缓存的秒级会话生命周期而言属于严重的**过度规格 (over-specification)**。定量来看, 氧化物 RRAM 的写能耗通常为  $\sim 10$ – $100$  pJ/位, 编程电压为  $\sim 1$ – $3$  V; 而有机 OEC-RAM 的写能耗可低至  $\sim 1$ – $10$  pJ/位, 编程电压低于 1 V。过度保持意味着器件需要为长期数据保持支付额外的物

理代价（如更高的编程电压、更厚的阻变层、更复杂的 forming 工艺），这些代价转化为更高的每比特写能耗和更慢的编程速度。

更为关键的是，KV 缓存的 WORM 模式几乎不需要  $10^6$  级耐久性，而氧化物 RRAM 的高耐久性是以牺牲模拟级数（analog levels）和器件一致性为代价的——其本征的循环间变异（cycle-to-cycle variation）和器件间变异（device-to-device variation）限制了可用于模拟存储的有效电导态数。实测表明， $\text{HfO}_2$  RRAM 在  $10^6$  次循环后，有效模拟态数（以  $3\sigma$  分离准则）通常不超过 8–16 级；而有机 OEC-RAM 虽绝对耐久性较低，但在其有效循环范围内（ $10^3$ – $10^4$  次）可维持 32–64 级有效模拟态，为高精度 KV 映射提供了更大的设计空间。

**有机光电电导随机存储器 (Organic Optoelectronic Conductance RAM, OEC-RAM)** 的物理特性正好落入 KV 缓存需求的“最优区间”（Goldilocks zone）。其  $\sim 10^3$  s（约 15 分钟）的保持时间与 LLM 单轮对话或多轮短对话的会话长度天然对齐； $10^3$ – $10^4$  次循环的耐久性虽低于氧化物 RRAM，但已远超 KV 缓存“预填充时写入一次、解码时反复读取”的模式需求。

定量而言，假设一次典型边缘 LLM 会话包含预填充阶段写入  $S = 4096$  个 token 的 K、V 条目，随后进行数百至数千步解码。在预填充阶段，每层每头需写入  $S$  个向量，总写操作数  $N_{\text{write}} \approx 2 \times L \times H \times S \approx 5.8 \times 10^6$ 。对于 TinyLlama-1.1B ( $L = 22, H = 32, S = 4096$ )，该数值看似接近  $10^7$  边界；然而，由于 CIM 阵列以模拟电导存储 K/V 向量，每个向量元素映射至一个器件电导态，一次向量写入对应一组器件的并行编程，实际编程循环数远低于元素计数。因此， $N_{\text{write}}$  在器件层面通常低于  $10^3$ ，处于有机 OEC-RAM 的耐久性裕度之内。

更重要的是，有机 OEC-RAM 可通过光子调制实现电导状态的光学刷新（optical refresh），这一特性将在下一小节详述。

### 6.2.3 光学刷新的独特优势

在 Work 1（第一章）中，有机光电材料的光敏特性被识别为推理阶段的噪声源：环境光照或器件光耦合导致电导漂移，进而恶化了模拟卷积神经网络的分类精度。然而，在 KV 缓存场景中，同一物理特性转化为**结构性优势**。

有机 OEC-RAM 的电导态可通过特定波长的光脉冲进行非破坏性刷新（non-destructive refresh），即在不改变编程循环计数的前提下恢复电导至目标值。与传统电荷存储器件（如 DRAM）需要周期性电荷刷新不同，有机 OEC-RAM 的光学刷新具有以下特点：

- **低能耗**：光子能量直接耦合至有源层，避免了热电子注入或隧穿所需的额外电学功耗；实验测得的光学刷新能耗可低至  $\sim 1$  pJ/单元，远低于电学重写的  $\sim 10$  pJ/单元；
- **局部可控**：通过集成微透镜或波导阵列，可实现对阵列子区域的定向刷新，无需全阵列重写，尤其适用于 KV 缓存中“高频访问的新 token 需频繁刷新、低频访问的旧 token 可容忍衰减”的非均匀访问模式；

- **不消耗耐久预算**：光学刷新不涉及电学编程循环，因此不计入器件的耐久性预算，从根本上解除了”长保持需求 → 频繁刷新 → 耐久耗尽”的死锁。

这一特性对 KV 缓存管理具有深远意义。在长对话场景中，早期 token 的 K、V 条目可能因保持时间衰减而面临电导漂移风险。传统电学刷新方案需要读取—校正—重写 (read-correct-write)，每次操作均消耗一次耐久循环；而光学刷新可在不消耗耐久预算的情况下恢复电导精度，使得”长保持 + 低耐久”的有机器件能够可靠地服务于需要分钟级数据保持的 KV 缓存任务。

有机光电 CIM 在保持时间、耐久性和刷新机制三个维度上均与 KV 缓存的物理需求呈现罕见的结构性匹配。这种匹配并非通过工程妥协或系统级 workaround 达成，而是源于器件物理与应用负载的**内在一致性**，构成了本工作的核心立论基础。

## 6.3 问题定义与核心假设

### 6.3.1 形式化问题陈述

本工作要回答以下核心科学问题：**有机光电模拟 CIM 是否能够在满足边缘 LLM 推理精度要求的前提下，以优于传统数字存储方案的能效和面积效率实现 KV 缓存的存储与计算？**

为形式化该问题，定义以下系统模型。设边缘 LLM 推理任务由预填充阶段  $\mathcal{P}$  和解码阶段  $\mathcal{D}$  组成。在  $\mathcal{P}$  阶段，输入序列  $\mathbf{x} = (x_1, x_2, \dots, x_S)$  逐层计算得到 KV 张量：

$$\mathbf{K}_l = \mathbf{W}_l^K \mathbf{x}, \quad \mathbf{V}_l = \mathbf{W}_l^V \mathbf{x}, \quad l = 1, \dots, L \quad (6.6)$$

其中  $\mathbf{K}_l, \mathbf{V}_l \in \mathbb{R}^{S \times D_{\text{model}}}$ 。在  $\mathcal{D}$  阶段，第  $t$  个解码步的注意力输出为：

$$\mathbf{o}_t = \sum_{i=1}^{S+t-1} \alpha_{ti} \mathbf{v}_i, \quad \alpha_{ti} = \frac{\exp(q_t k_i^T / \sqrt{D_h})}{\sum_j \exp(q_t k_j^T / \sqrt{D_h})} \quad (6.7)$$

若将 KV 缓存映射至有机 CIM 阵列，则每个条目  $k_i$  或  $v_i$  被编码为交叉阵列上一组器件的电导态  $G_{ij}$ 。受器件物理约束， $G_{ij}$  取自有限离散集合  $\{G_1, G_2, \dots, G_N\}$ ，并受噪声  $n_{c2c} \sim \mathcal{N}(0, \sigma_{c2c}^2)$  和保持漂移  $\Delta G(t) = G(t) - G(0)$  的影响。注意力计算中的矩阵向量乘积  $q_t K^T$  通过读取阵列电流实现：

$$I_j = \sum_i W_{ij} V_i, \quad W_{ij} \propto G_{ij} \quad (6.8)$$

随后经 ADC 转换为数字域，完成 softmax 和加权求和。

### 6.3.2 核心假设

基于上述系统模型，本工作提出以下三项核心假设 (core hypotheses)。需要说明的是，这些假设并非凭空提出，而是建立在已有器件物理文献的实测数据基础之上，并将在第6.5节的仿真实验中接受系统性检验。

**假设 6.1** (保持时间匹配假设). 有机 OEC-RAM 的典型保持时间  $\tau \sim 10^3$  s 与边缘 LLM 推理会话长度  $\tau_{\text{session}} \in [10^1, 10^3]$  s 处于同一数量级, 因此无需为长期非易失性支付额外的物理代价, 亦不会因过早衰减导致不可接受的精度损失。形式化地, 若  $\tau_{\text{device}}/\tau_{\text{session}} \in [1, 100]$ , 则保持时间裕度足以覆盖会话周期内的自然衰减, 同时避免过度规格导致的写能耗惩罚。

**假设 6.2** (耐久性适配假设). KV 缓存”一次写入、多次读取”的访问模式使得写操作次数  $N_{\text{write}}$  远低于有机器件的耐久极限  $E_{\text{max}} \sim 10^3\text{--}10^4$ ; 结合光学刷新机制, 系统可在完整会话周期内维持电导精度而不耗尽耐久预算。形式化地, 定义耐久性裕度  $\eta_E = E_{\text{max}}/N_{\text{write}}$ , 本假设要求  $\eta_E \geq 10$  以提供足够的操作裕度应对工艺变异和异常会话。

**假设 6.3** (模拟精度充分假设). 存在有限模拟态数  $N \geq N_{\text{min}}$  和可容忍噪声水平  $\sigma \leq \sigma_{\text{max}}$ , 使得有机 CIM KV 缓存上的注意力输出与 FP16 基线相比, 在困惑度 (perplexity) 和下游任务指标上的退化低于应用可接受阈值  $\delta$ 。该假设不声称有机 CIM 可达到与 FP16 完全等同的精度, 而是声称在特定的  $N$ - $\sigma$  操作窗口内, 精度退化处于可控且可接受的范围内。

上述三项假设分别对应器件物理、系统架构和算法精度的不同层次。假设6.1和6.2属于物理层面的先验论证, 其成立性由有机 OEC-RAM 的器件物理参数直接支撑; 假设6.3则涉及器件噪声、量化误差与注意力机制之间的复杂耦合, 无法仅凭器件参数推断, 必须通过行为级仿真实验进行验证。三项假设共同支撑本工作的中心论点: **有机光电 CIM 是唯一一种其本征物理特性与 LLM KV 缓存访问模式在数量级上匹配的新兴存储技术。**

### 6.3.3 与现有工作的区别

需要明确的是, 本工作并非首个探索 CIM 用于 LLM 推理的研究。近期工作如 ReTransformer<sup>47</sup> 和 X-Former<sup>48</sup> 已分别论证了氧化物 RRAM-CIM 和 SRAM-CIM 在注意力计算中的可行性。然而, 这些工作均将 CIM 视为通用加速器, 并未从**物理匹配性**角度论证为何特定存储技术适用于 KV 缓存这一特定负载。区别在于:

- ReTransformer 采用  $\text{HfO}_2$  RRAM, 其年级保持时间和  $10^6$  级耐久性远超 KV 缓存需求, 器件在物理上处于”过度规格”状态, 其高写能耗和面积代价并非 KV 缓存所必需;
- X-Former 采用 SRAM CIM, 虽具备高速低延迟优势, 但易失性导致待机功耗和面积效率劣于非易失方案, 且无法利用光学刷新等低能耗维持机制;
- 上述工作均未系统评估器件噪声、保持漂移和量化效应对注意力机制的影响, 缺乏从器件物理到算法精度的端到端分析。

本工作的核心贡献在于建立”器件物理参数 → 存储访问模式 → 系统性能指标”的完整映射链条，并提供以有机光电 CIM 为对象、面向 KV 缓存场景的物理驱动基准测试 (physics-grounded benchmark)。

## 6.4 目标模型与评估框架

### 6.4.1 目标模型选择

为在有限的计算资源和合理的仿真时间内完成系统性评估，本工作采用分层模型策略，以边缘适用的小模型为主、以中等规模模型为扩展验证对象。模型选择的总原则是：**主模型必须能够在单片有机交叉阵列的物理尺寸约束内容纳其单层 KV 缓存**，从而避免多片划分的复杂性干扰对器件物理本征特性的评估。

主模型采用 TinyLlama-1.1B<sup>49</sup>。该模型专为资源受限场景优化，参数量为 1.1B，默认上下文长度为 2048 token（可通过位置编码插值扩展至 4096 或 8192）。它采用标准的 Llama 架构，含 22 层 Transformer，隐藏维度 2048，32 个注意力头，每头维度 64。选择 TinyLlama 作为主模型的理由如下：

- **规模适配**：1.1B 参数的 KV 缓存 footprint 在 4k 上下文、FP16 精度下约为 **704 MB** ( $2 \times 22 \times 32 \times 64 \times 4096 \times 2 \text{ B}$ )，其单层单头的 KV 矩阵尺寸可映射至单片有机交叉阵列（如  $512 \times 512$ ），无需复杂的多片划分或层级调度；
- **快速迭代**：在 RTX 5070 Ti 级别 GPU 上，TinyLlama 的完整 WikiText-103 验证集推理可在数分钟内完成，支持大规模参数扫描（如  $\sigma$ -N 网格搜索）；
- **边缘代表性**：1–3B 参数区间是当前边缘 LLM 部署的主流选择（如 Phi-2、Gemma-2B、Qwen2.5-1.5B），TinyLlama 的结果对该区间具有良好代表性。

作为扩展验证，LLaMA-2-7B<sup>50</sup> 用于考察更大隐藏维度和 GQA 结构下的边界。该模型采用分组查询注意力（Grouped-Query Attention, GQA），将 32 个查询头共享至 4 个 K/V 头，从而将 KV 缓存量减少至标准多头注意力（MHA）的 1/8。选择 LLaMA-2-7B 作为次模型的目的在于：

- **验证 GQA 扩展性**：GQA/MQA 已成为现代 LLM 的标准配置（如 LLaMA-3、Mistral、Qwen2.5 均采纳），验证有机 CIM 在 GQA 架构下的可行性对未来工作具有指导意义；
- **测试阵列尺寸边界**：7B 模型的更大隐藏维度和更多层数对有机阵列的尺寸、ADC 分辨率和外围数字电路提出更高要求，可探明有机 CIM KV 缓存方案的规模极限；
- **上下文扩展**：LLaMA-2-7B 支持 32k 上下文（通过位置编码扩展），可用于评估有机保持时间在长序列场景下的实际影响。

上下文长度方面，TinyLlama 的默认上下文为 2048 token，通过 RoPE（Rotary Position Embedding）位置编码插值可扩展至 4096 或 8192 token。本工作将在 2k、4k、

8k 三种上下文长度下评估有机 CIM KV 缓存的性能，以验证保持时间假设在长序列场景下的稳健性。LLaMA-2-7B 的 32k 扩展采用类似的插值策略，但仅在次模型上作为极限验证，不作为主要报告内容。相应地，以下模型被明确排除在本工作当前范围之外：

- **>7B 模型**（如 LLaMA-2-13B、LLaMA-3-8B、Qwen2.5-14B）：有机交叉阵列的密度和良率在当前工艺水平下难以支撑十亿级以上模型所需的 KV 缓存容量，且仿真时间随模型规模超线性增长，超出硕士论文的合理范围；
- **>32k 上下文**（如 Qwen2.5-7B-Instruct 的 128k 上下文）：超长上下文需要 3D 堆叠、混合存储层级或片外卸载策略，这些属于系统架构层面的工程问题，而非有机 CIM 本征物理特性的研究范畴。

#### 6.4.2 评估指标

本工作从算法精度、系统效率和任务性能三个维度建立评估指标体系。算法精度首先以**困惑度（Perplexity, PPL）**为核心指标。WikiText-103<sup>51</sup>作为标准的语言建模基准，其验证集包含约  $2.6 \times 10^6$  token。本工作报告 WikiText-103 上的困惑度及其相对于 FP16 基线的相对变化  $\Delta_{\text{PPL}}$ ，并在 3 个随机种子上重复实验以报告 95% 置信区间。

数据集选择围绕稳定性和应用覆盖展开。WikiText-103 规模适中（约 1 亿 token 训练集），且与 TinyLlama 等模型的预训练数据分布有一定重叠，可提供稳定的困惑度估计。LongBench 子集的选择基于任务多样性：HotpotQA 测试多跳推理中的长距离依赖保持能力，NarrativeQA 测试叙事文本中的时间线追踪能力，两者对注意力机制的 rank 保持提出了不同挑战。GSM8K 的数学推理任务对数值精度敏感，KV 缓存的量化噪声和电导漂移可能通过链式思考中的中间步骤传播放大，因此是检验有机 CIM 可靠性的严格测试。MT-Bench 子集则提供了贴近真实用户交互的多轮对话场景，其开放式生成特性使得微小的 KV 噪声可能通过自回归过程累积为显著的语义偏移。为验证 KV 缓存噪声和压缩对实际应用能力的影响，选取以下三类下游任务：

- **长上下文问答**：采用 LongBench<sup>52</sup> 子集（HotpotQA 和 NarrativeQA），分别以 F1 分数和精确匹配率（Exact Match, EM）评估模型在长文档理解中的注意力 rank 保持能力；
- **数学推理**：采用 GSM8K<sup>53</sup>，以解题准确率评估 KV 噪声对链式思考（chain-of-thought）推理的干扰程度；
- **多轮对话**：采用 MT-Bench<sup>54</sup> 子集，以相对于 FP16 基线的胜率（win-rate）评估会话级保持时间对对话连贯性的影响。

系统效率侧报告三类指标：

- **每 token 解码能耗**（pJ/token）：包括模拟 MAC 操作、ADC 转换、电导写入和光学刷新的能量总和，基于 Work 1 仿真器中建立的能耗模型进行估算；

- **KV 缓存面积** ( $\text{mm}^2$ ): 基于有机交叉阵列的单元尺寸 ( $\mu\text{m}$  级 pitch) 和外围电路面积进行估算;
- **有效保持时间** (s): 在特定刷新策略下, KV 缓存维持应用可接受精度的实际时间窗口。

复现协议保持统一: (1) 随机种子固定为 {42, 123, 2024}, 报告均值与 95% 置信区间; (2) FP16 基线在每个数据集上独立运行 3 次, 取最佳值作为比较基准; (3) 所有有机 CIM 方案的噪声注入、量化和衰减模型均基于同一器件参数文件 (device\_organic\_oecram\_v2.json), 该文件继承自 Work 1 并经扩展; (4) 原始实验日志、配置文件和可视化脚本均归档至 compute\_vit/scripts/\_gpt/目录, 供后续审计和复现。

### 6.4.3 对比基线

为公正评估有机 CIM KV 缓存方案的性能, 本工作设立以下五类对比基线, 涵盖数字存储、数字量化和替代性 CIM 技术:

表 6.2: 对比基线及其公平比较原则

| 基线           | 技术描述                                      | 公平比较原则                                                            |
|--------------|-------------------------------------------|-------------------------------------------------------------------|
| FP16         | 标准数字 DRAM 存储, 半精度浮点                       | 精度上界, 不声称”击败 FP16”而声称”以 X 倍能效接近 FP16”                             |
| KIVI-2bit    | 数字 SRAM/DRAM + 2-bit 非对称量化 <sup>41</sup>  | 比较等 memory footprint 下的精度, 注意 KIVI 为逐通道非对称, 有机映射需采用 comparable 粒度 |
| KIVI-4bit    | 同上, 4-bit 量化                              | 作为精度—压缩权衡的中间点                                                     |
| SRAM-CIM     | 7nm SRAM 交叉阵列 <sup>55</sup>               | 比较等工艺节点下的能效与面积, 计入 SRAM 待机刷新功耗                                    |
| 氧化物 RRAM-CIM | HfO <sub>2</sub> ReRAM 交叉阵列 <sup>47</sup> | 比较器件物理代价(写能耗、耐久性、保持时间), 突出有机光学刷新优势                                |

在实验报告中, 所有基线将在同一模型 (TinyLlama-1.1B)、同一数据集和同一评估协议下运行, 以确保结果的可比性。有机 CIM 方案的优势将通过**物理代价—精度—能效**的三维帕累托分析呈现, 而非单一的胜负比较。

## 6.5 实验设计详述

本节详细阐述验证第6.3节核心假设的四组实验。实验设计遵循”从器件噪声到系统架构、从静态精度到动态时序”的递进逻辑，以全面描述有机 CIM KV 缓存方案的可行性边界。

### 6.5.1 实验一：注意力对模拟 KV 存储的噪声鲁棒性

该实验首先回答有机 OEC-RAM 的本征电导噪声（包括循环间变异  $\sigma_{c2c}$  和器件间变异  $\sigma_{d2d}$ ）和有限模拟态数  $N$  会如何影响注意力计算的输出精度，并据此确定维持无损或应用可接受注意力所需的最小模拟态数  $N_{\min}$  和最大容忍噪声  $\sigma_{\max}$ 。实验以 TinyLlama-1.1B 为测试模型，在其 HuggingFace 实现中植入 KV 缓存噪声注入钩子 (hook)。具体而言，在每一层自注意力模块的  $k_{\text{proj}}$  和  $v_{\text{proj}}$  输出之后，将浮点 K/V 张量通过码本查找映射为电导值  $G$ ，再叠加有机噪声模型：

$$G_{\text{noisy}} = G + \mathcal{N}(0, \sigma_{c2c}^2) + \mathcal{N}(0, \sigma_{d2d}^2) \quad (6.9)$$

其中  $\sigma_{d2d}$  为固定实例级偏置（每个器件独立采样一次）， $\sigma_{c2c}$  为每次前向传播独立采样。噪声模型参数直接沿用 Work 1 仿真器中经过校准的有机器件模型，以确保跨工作的一致性。

表 6.3: 实验一参数扫描空间

| 维度                   | 取值                           | 说明                 |
|----------------------|------------------------------|--------------------|
| 模拟态数 $N$             | 2, 3, 4, 5, 6                | 每器件电导离散级数          |
| 循环间噪声 $\sigma_{c2c}$ | 0.00, 0.01, 0.02, 0.05, 0.10 | 以 LSB 为单位的相对标准差    |
| 器件间噪声 $\sigma_{d2d}$ | 0.00, 0.05                   | 固定实例偏置             |
| 注入目标                 | K-only, V-only, K+V          | 分别评估 K 噪声和 V 噪声的影响 |

总配置数为  $5 \times 5 \times 2 \times 3 = 150$  组。每组配置运行完整的 WikiText-103 验证集推理和 LongBench 子集（HotpotQA 500 例、NarrativeQA 200 例）评估。

除直接报告  $\Delta_{\text{PPL}}$  外，本实验将引入**注意力 rank 保持率**（attention rank preservation）作为中间诊断指标。具体而言，对每层每头的注意力分数矩阵  $A \in \mathbb{R}^{1 \times S}$ ，计算有机噪声条件下 top- $k$  激活位置与 FP16 基线的 Jaccard 相似度：

$$\rho_{\text{rank}} = \frac{|\text{top-}k(A_{\text{FP16}}) \cap \text{top-}k(A_{\text{organic}})|}{k} \quad (6.10)$$

该指标可隔离”注意力分数数值变化”与”注意力分布结构变化”，帮助定位噪声导致精度退化的本质原因。

若实验结果显示在  $\sigma_{c2c} > 0.01$  时困惑度即出现灾难性退化，本工作将调整声称策略：从”无损注意力”转变为”graceful degradation under bounded noise”，并重点分析

$\sigma$ - $N$  平面上退化曲线的拐点位置和斜率，为器件工艺改进提供目标规格。这一调整已在实验计划中获得预授权，不构成方向性失败。

结果解释将围绕以  $N$  和  $\sigma_{c2c}$  为自变量、 $\Delta_{PPL}$ （相对于 FP16 的困惑度增量）和 LongBench F1 为因变量的二维等高线图展开。关键预期洞察包括：

- 存在一条“精度悬崖”边界：当  $\sigma_{c2c}$  超过某阈值时，困惑度急剧上升，标志着注意力机制对电导噪声的敏感性阈值；
- V 噪声对困惑度的影响预期大于 K 噪声，因为 Value 张量直接参与输出加权和，其误差经 softmax 权重放大后作用于最终表示；
- 器件间噪声  $\sigma_{d2d}$  可能引入系统性的注意力分布偏移，其影响模式与循环间噪声不同，需分别建模。

### 6.5.2 实验二：架构探索与帕累托分析

第二组实验面向 1B 级边缘 LLM 的单步解码，回答有机 CIM KV 缓存模块需要多大的阵列尺寸、ADC 分辨率和电导编程精度，以及在延迟—能耗—面积的三维空间中存在怎样的帕累托最优配置。实验将扩展 Work 1 的行为级模拟器，新增 KV 缓存交叉阵列模块。该模块包含以下组件：

- **有机交叉阵列**：尺寸  $M \times N$ ，其中  $M$  对应 head\_dim， $N$  对应最大序列长度；
- **模拟 MAC**：通过电流模式读取实现  $Q \cdot K^T$  的点积计算；
- **ADC**：每列配置  $N_{ADC}$  位闪存型或 SAR 型 ADC，将模拟电流转换为数字值；
- **数字外围电路**：softmax 单元、top-k 选择、累加器和控制器。

能耗模型沿用 Work 1 的基础参数并扩展以下组件：模拟 MAC 按 0.1 pJ/8b-MAC、ADC 按 Walden 优值 ( $2^{N_{ADC}} \times 0.5$  fJ/conv-step) 缩放、电导写入按 10 pJ/单元、光学刷新按 1 pJ/单元估算。

表 6.4: 实验二参数扫描空间

| 维度     | 取值                                                             |
|--------|----------------------------------------------------------------|
| 阵列尺寸   | $64 \times 64, 128 \times 128, 256 \times 256, 512 \times 512$ |
| ADC 位数 | 4, 6, 8                                                        |
| 编程精度   | 1%, 5%, 10% ( $\sigma_{prog}/G_{range}$ )                      |
| 模拟态数   | 4, 8, 16                                                       |

总配置数为  $4 \times 3 \times 3 \times 3 = 108$  组。每组配置在模拟器中执行单 token 单层单头的注意力计算，输出延迟 (ns/token)、能耗 (pJ/token)、面积 ( $\mu m^2$ ) 和信噪比 (SNR, dB)。

架构探索实验直接复用 Work 1 模拟器中的有机器件模型（电导分布、噪声统计、非线性特性），仅在阵列拓扑和外围电路上进行扩展。这种衔接确保了跨工作的器件参数一致性，使得 Work 1 中测得的器件限制（如严重非线性导致的有效态数压缩）可直接映射至 Work 2 的 KV 缓存场景，无需重新校准。

架构探索的核心输出为帕累托前沿分析。定义配置  $\mathbf{c} = (M, N_{\text{ADC}}, \sigma_{\text{prog}}, N)$  的帕累托支配关系： $\mathbf{c}_1$  支配  $\mathbf{c}_2$  当且仅当  $\mathbf{c}_1$  在延迟、能耗、面积三项指标上均不劣于  $\mathbf{c}_2$ ，且至少一项严格更优。帕累托前沿即为所有非支配配置的集合。此外，引入**精度约束帕累托前沿** (accuracy-constrained Pareto front)：仅保留  $\text{SNR} \geq \text{SNR}_{\min}$  的配置，其中  $\text{SNR}_{\min}$  由实验一确定的  $\sigma_{\max}$  反推。

四组实验之间存在逻辑依赖：实验一（噪声鲁棒性）确定的可容忍噪声水平  $\sigma_{\max}$  和最小模拟态数  $N_{\min}$  将作为实验二（架构探索）的精度约束输入；实验一和实验二共同确定的器件参数范围将指导实验三（压缩协同设计）的码本设计和实验四（时间动态）的刷新策略选择。因此，执行顺序为：实验一  $\rightarrow$  实验二（可与实验一后半段并行） $\rightarrow$  实验三 + 实验四（可同时启动）。

预期获得延迟—能耗—面积的三维帕累托前沿面，并以 SNR 为颜色映射标识精度可接受区域。关键预期洞察包括：

- ADC 分辨率对系统能效具有支配性影响：每增加 1 bit ADC 分辨率，ADC 能耗近似翻倍，但对注意力精度的边际改善递减；
- 阵列尺寸存在最优区间：过小的阵列 ( $64 \times 64$ ) 无法容纳长序列的完整 KV 缓存，需频繁分块和拼接；过大的阵列 ( $512 \times 512$ ) 导致线延迟和寄生电容增加，反而劣化能效；
- 编程精度与模拟态数存在耦合关系：高态数 (16-level) 需要高精度编程 ( $< 5\%$ )，否则相邻态重叠导致有效分辨率损失。

### 6.5.3 实验三：KV 缓存压缩与有机模拟协同设计

第三组实验比较**数字量化与有机模拟存储**在等比特/等面积条件下的注意力精度，核心问题是在等存储 footprint 条件下，有机模拟存储能否达到或接近数字量化方案 (KIVI) 的精度，以及模拟电导的非线性映射（非均匀码本）相比线性映射（均匀码本）能带来多大的精度增益。数字侧采用 KIVI 式非对称逐通道量化：Key 采用 per-head scale+zero-point，Value 采用 per-token scale+zero-point。有机侧将浮点 K/V 向量映射至电导态，支持两种码本策略：

- **均匀码本**：电导态在  $[G_{\min}, G_{\max}]$  区间线性均匀分布；
- **学习码本**：基于校准集 (WikiText-103 训练子集 100k token) 的 K-means 聚类生成非均匀码本，使电导态分布适配 K/V 张量的实际数值分布。

映射后的电导值叠加实验一确定的可容忍噪声水平 ( $\sigma_{c2c} \approx 0.01, \sigma_{d2d} \approx 0.02$ )，再经反向查找恢复为浮点值，输入标准注意力计算。

表 6.5: 实验三参数扫描空间

| 维度     | 取值                                                                             |
|--------|--------------------------------------------------------------------------------|
| 数字量化位数 | 2, 3, 4 bit                                                                    |
| 有机模拟态数 | 4, 8, 16                                                                       |
| 码本类型   | 均匀, 学习 (K-means)                                                               |
| 器件噪声   | $\sigma_{c2c} \in \{0.00, 0.01, 0.02\}, \sigma_{d2d} \in \{0.00, 0.02, 0.04\}$ |

本实验的核心是比较等 **footprint** 条件下有机模拟存储与数字量化的精度—能效权衡。定义等效存储密度  $\rho$  (bit/元素) 为统一比较基准：对于数字方案， $\rho$  即为量化位数；对于有机方案， $\rho = \log_2 N$ 。在相同的  $\rho$  下，比较两种方案的 (1) 注意力输出余弦相似度  $\cos(\mathbf{o}_{FP16}, \mathbf{o}_{method})$ ；(2) 困惑度退化  $\Delta_{PPL}$ ；(3) 端到端任务准确率；(4) 每 token 写能耗。

此外，将分析学习码本的聚类中心分布与 K/V 张量数值分布的匹配程度。若 K-means 中心呈现明显的非均匀分布（如向低值区域聚集），则表明均匀量化在该数值区间存在分辨率浪费，学习码本可通过密度自适应提升有效精度。

关键比较点为等 **footprint**：例如，4 模拟态 (2-bit 等效) 有机存储与 KIVI-2bit 的数字存储在相同的每元素比特数下比较注意力余弦相似度和困惑度。预期洞察包括：

- 学习码本可通过适配 K/V 张量的非均匀分布（如 Key 的通道间方差差异）提升有效精度，弥补模拟器件的噪声劣势；
- 在极低比特区 (2-bit 等效)，有机模拟存储可能因噪声 floor 而劣于 KIVI；在中等比特区 (3–4-bit 等效)，学习码本 + 非线性映射可能接近或超越数字量化；
- 写能耗对比：有机模拟存储的逐单元写入虽为模拟精度，但避免了数字量化所需的 scale/zero-point 参数存储和反量化计算。

#### 6.5.4 实验四：时间动态与刷新策略

第四组实验关注有机保持时间衰减 ( $\tau \sim 10^3$  s) 下的时序可靠性，目标是在会话级时间尺度上识别能够同时维持任务精度和系统能效的刷新闻隔与层次化驱逐策略。实验建模有机电导的指数衰减过程：

$$G(t) = G_{\min} + (G_{\text{programmed}} - G_{\min}) \cdot \exp(-t/\tau) \quad (6.11)$$

其中  $\tau \in \{1, 10, 100, 1000\}$  s 覆盖从极端衰减到接近稳定的范围。会话场景模拟为 5 轮多轮对话，每轮 512 token，总时长约数分钟。

时间动态实验的关键挑战在于将器件级衰减模型  $G(t)$  映射至系统级任务性能。为此，采用**分层评估**策略：单层单头级别量化电导漂移导致的注意力分数相对误差  $\epsilon_{\text{attn}}(t) = |A_{\text{drift}}(t) - A_{\text{FP16}}|/A_{\text{FP16}}$ ；模型级别评估该误差经多层传播后的困惑度累积

表 6.6: 实验四参数扫描空间

| 维度            | 取值                                             |
|---------------|------------------------------------------------|
| 保持时间常数 $\tau$ | 1 s, 10 s, 100 s, 1000 s                       |
| 刷新闻隔          | 无, 1 s, 10 s, 100 s                            |
| 驱逐策略          | FIFO, LRU, 注意力分数阈值                             |
| 存储层级          | 单层（有机 CIM），双层（有机 CIM L1 $\rightarrow$ SRAM L2） |

效应；任务级别报告多轮对话的端到端准确率。该分层策略展示了”器件衰减  $\rightarrow$  单层误差  $\rightarrow$  多层累积  $\rightarrow$  任务退化”的完整因果链。

预期获得不同  $(\tau, T_{\text{refresh}})$  组合下的端到端任务准确率（MT-Bench 胜率）与总能量（计算 + 刷新 + 驱逐开销）的权衡曲线。关键预期洞察包括：

- 当  $\tau \geq 100$  s 且刷新闻隔  $\leq 10$  s 时，有机 CIM 可在完整会话周期内维持应用可接受的精度，验证假设6.1；
- LRU 策略优于 FIFO，因为早期 token 在长对话中可能通过指代或摘要机制被重新关注；注意力分数阈值驱逐可进一步剔除”死”条目，降低有效刷新开销；
- 双层层级（有机 CIM L1 + SRAM L2）在  $\tau$  较小时提供安全网：近期高频访问的 token 驻留于有机 L1，历史 token 降级至 SRAM L2，兼顾速度与容量。

### 6.5.5 实验结果：Remote 107 阶段性验证

本节报告 Remote 107 分支在 2026 年 4 月至 5 月期间完成的阶段性实验结果。这些数据尚未达到论文锁定（canonical）标准——部分 JSON 缺少完整的元数据包（git\_commit、script、mode、train/eval D2D seed 等）——因此仅用于研究路线判断和后续实验优先级排序，不作为本文的最终锁定结论。

首先，基准线给出了全层路线的压力边界。如表 6.7所示，TinyLlama-1.1B 在 WikiText-2 验证集上的数字基线困惑度为 15.68。即使采用 8-bit 全层零噪声模拟 KV 缓存，困惑度已升至 17.48（退化 11.5%），超出 10% 容忍门限。该阶段性结果使”全层模拟 KV 缓存”暂时不宜作为主部署路线。

表 6.7: Remote 107 基准线与全层淘汰判定（seed=42）

| 配置          | PPL   | 相对基线   | 判定 |
|-------------|-------|--------|----|
| 数字基线（FP16）  | 15.68 | 1.000x | 参考 |
| 8-bit 全层零噪声 | 17.48 | 1.115x | 淘汰 |

相比之下，将模拟 KV 缓存限制在模型的最后 1 层（last1, layer 23）或最后 2 层（last2, layers 22–23）时，困惑度显著改善。如表 6.8所示，last1 在零噪声下仅退化 0.9%，在真实噪声下退化 6.6%，均通过 10% 门限。

表 6.8: 选择性终端层模拟 KV 缓存探测 (8-bit, seed=42)

| 层范围              | 噪声条件 | PPL   | 相对基线   |
|------------------|------|-------|--------|
| last1 (layer 23) | 零噪声  | 15.82 | 1.009x |
| last1 (layer 23) | 真实噪声 | 16.72 | 1.066x |

全层配置的噪声扫描进一步说明了这一差异的物理来源。对 6-bit 全层配置分别扫描 C2C 和 D2D 噪声后可以看到, D2D 噪声的破坏力远大于 C2C 噪声: D2D 从 0 增至 0.05 时, PPL 从 32.41 跃升至 412.35; D2D=0.1 时更是达到 7635.49。这提示 D2D 可能是模拟 KV 缓存的首要失效源, 与 Work 1 中 D2D 导致 ViT 分类精度崩溃的发现一致; 正式结论仍需在元数据补全后锁定。

表 6.9: 6-bit 全层噪声敏感性扫描 (seed=42)

|                |       |       |        |        |         |        |
|----------------|-------|-------|--------|--------|---------|--------|
| $\sigma_{c2c}$ | 0.0   | 0.005 | 0.01   | 0.015  | 0.02    | 0.03   |
| PPL            | 32.41 | 39.86 | 56.73  | 77.36  | 100.64  | 160.34 |
| $\sigma_{d2d}$ | 0.0   | 0.01  | 0.02   | 0.05   | 0.10    |        |
| PPL            | 32.41 | 60.30 | 106.48 | 470.92 | 7635.49 |        |

对全层 8-bit 配置施加 500 步 HAT 预热, 困惑度从 579.52 降至 142.27, 但仍远未通过门限。这说明 HAT 虽能部分缓解全层模拟噪声, 但不足以将全层路线从”淘汰”状态拯救出来。HAT 资源应集中于选择性终端层, 而非全层。

在此基础上, 当前最关键的阶段性实验是选择性终端层在 fresh-D2D 条件下的交叉实例验证。训练时固定 D2D=0.02 (seed=42), 评估时在 5 个独立 D2D 种子上重复。如表 6.10 所示:

表 6.10: 选择性终端层 Fresh-D2D 交叉实例验证 (train D2D=0.02, seed=42)

| 配置            | 评估 D2D | $n$ 种子 | 均值 PPL | 标准差  | min   | max   |
|---------------|--------|--------|--------|------|-------|-------|
| last1 [23]    | 0.02   | 5      | 18.42  | 0.02 | 18.40 | 18.45 |
| last1 [23]    | 0.04   | 5      | 18.55  | 0.03 | 18.52 | 18.58 |
| last1 [23]    | 0.05   | 5      | 18.60  | 0.03 | 18.56 | 18.63 |
| last2 [22,23] | 0.02   | 5      | 18.71  | 0.02 | 18.69 | 18.74 |
| last2 [22,23] | 0.04   | 5      | 19.07  | 0.04 | 19.03 | 19.13 |
| last2 [22,23] | 0.05   | 5      | 19.21  | 0.04 | 19.17 | 19.26 |
| 全层            | 0.02   | 5      | 26.05  | 0.53 | 25.17 | 26.50 |
| 全层            | 0.04   | 5      | 44.34  | 2.65 | 40.08 | 46.74 |
| 全层            | 0.05   | 5      | 66.84  | 5.91 | 57.65 | 73.06 |

关键发现可归纳为四点:

1. **last1 是当前优先候选路线**: 从 eval D2D=0.02 到 0.05, PPL 仅从 18.42 微增至 18.60, 变化量不足 1%, 提示其对 D2D 变异具有较低敏感性。
2. **last2 同样呈现低敏感性但一致性劣于 last1**: PPL 从 18.71 增至 19.21, 增量约 2.7%, 仍在可接受范围, 但为次优候选。
3. **全层路线在 fresh-D2D 下表现为不可取候选**: 即使 eval D2D=0.02, PPL 已达  $26.05 \pm 0.53$ ; eval D2D=0.05 时, PPL 达  $66.84 \pm 5.91$ , 变异系数接近 9%, 不具备部署可行性。
4. **Fresh-D2D 方差极小**: last1 和 last2 的标准差均低于 0.05, 变异系数  $< 0.3\%$ , 提示其可能具备跨设备鲁棒性; 该判断仍需在元数据锁定和最小重跑后再作为正式 claim。

基于上述实验结果, 当前 Work-2 的研究路线如下:

- **主路线**: 选择性终端层模拟 KV 缓存, 以 last1 为优选候选方案。
- **次路线**: last2, 用于应对评审人对覆盖范围的质疑。
- **全层路线**: 仅作为压力测试/对照组, 不作为部署声称。
- **高 D2D 训练**: 对全层有一定收益 (D2D=0.04 训练在 eval 0.05 时 PPL=47.98, 优于 D2D=0.02 训练的 66.84), 但对 last1 无明显必要。

假设 6.3 (模拟精度充分) 在 last1/last2 的选择性终端层范围内得到阶段性支持: 在  $\sigma_{d2d} \leq 0.05$ 、8-bit 量化的操作窗口内, 困惑度退化控制在  $< 20\%$ 。假设 6.1 和 6.2 尚需实验四的时间动态数据才能最终判定, 器件物理层面的论证目前应视为待实验补强的先验基础。

## 6.6 预期贡献与创新点

基于前述问题定义与实验设计, 本工作预期在以下四个方面作出贡献。这些贡献既包括**知识增量** (对领域内尚未解答的问题给出新的认知), 也包括**方法论增量** (为后续研究提供可复用的分析框架和工具链)。

第一, 现有 CIM-for-LLM 研究集中于氧化物 RRAM 或 SRAM 器件, 缺乏对有机光电 CIM 在该场景下的系统性评估。本工作将提供从器件噪声模型、保持时间衰减到注意力精度退化、下游任务性能的端到端基准测试, 填补该领域的知识空白。该基准不仅服务于有机 CIM 社区, 也为更广泛的”新兴存储技术  $\rightarrow$  LLM 推理负载”映射研究提供了方法论模板。

第二, 本工作将形式化论证有机 OEC-RAM 的  $\sim 10^3$  s 保持时间与 LLM 边缘推理会话长度 (秒至分钟级) 的物理匹配性。这一论证并非简单的数值比较, 而是通过多尺度建模 (器件衰减模型  $\rightarrow$  电导漂移  $\rightarrow$  注意力分数偏移  $\rightarrow$  任务性能退化) 建立的因果链条, 为”何种存储技术适用于何种负载”这一普适问题提供方法论范例。该论证框架

可推广至其他新兴存储技术（如 FeFET、PCM、MRAM）的负载匹配分析，具有超越本工作具体场景的普适价值。

第三，本工作将系统评估光学刷新在 KV 缓存管理中的能效优势，量化其相对于电学刷新的耐久预算节省和能量节省。这一分析将修正 Work 1 中对有机光敏特性的悲观判断，展示同一物理特性在不同应用语境下可从“噪声源”转化为“系统优势”。实验四将输出“刷新间隔—任务准确率—总能量”的三维帕累托面，明确标识光学刷新可操作的设计空间，为后续有机 CIM 芯片的刷新控制器设计提供定量依据。

第四，通过实验三（压缩协同设计）和实验四（层级化刷新策略），本工作将提出“器件物理—量化编码—系统策略”的三层次协同设计框架，为后续有机 CIM 在边缘 LLM 推理中的工程实现提供可操作的优化空间。该框架的核心思想是：器件层的参数（ $\tau$ 、 $\sigma$ 、 $N$ ）不是固定的约束，而是可与算法层（码本设计、注意力变体）和系统层（刷新策略、存储层级）联合优化的设计变量。这一思想打破了传统“器件先行、系统适配”的线性设计范式，体现了新兴计算范式所要求的**跨层次协同优化**理念。

这些贡献与 Work 1 形成明确互补。Work 1（第一章）指出了有机 CIM 在 ViT 注意力推理中的结构性瓶颈：严重非线性叠加推理阶段的动态激活导致模拟精度快速退化。Work 2 则转向**互补场景**——KV 缓存的静态存储与 WORM 访问模式——探索有机 CIM 可能具备结构性优势的应用边界。两者共享同一行为级模拟器基础设施，但在科学结论上形成“证伪与假设生成”的互补结构，增强了硕士论文的理论完整性与论证深度。

Work 1 的结论可概括为“有机 CIM 不适合需要高频动态激活更新的在线推理任务”，而 Work 2 的结论预期为“有机 CIM 适合需要低频写入、高频读取的静态存储任务”。这一对偶结论并非相互矛盾，而是共同界定了有机 CIM 的能力边界：其优势场景是那些能够利用其保持时间—耐久性最优区间、且规避其写入速度慢和循环变异大的负载。KV 缓存正是这一优势场景的典型代表。

## 6.7 范围边界与明确排除项

为确保研究的可控性和结论的严谨性，以下事项被明确排除在本工作当前范围之外。这些排除项并非因技术不可行而回避，而是基于资源约束和研究焦点的主动界定。

明确的范围边界不仅是项目管理工具，更是学术严谨性的体现。在新兴器件研究中，常见的一类批评是“过度声称”（overclaiming）：将仿真或单器件结果不恰当地推广至远超其验证范围的系统场景。本工作通过主动界定边界，将结论的适用范围限制在“1–3B 参数边缘 LLM、4k–8k 上下文、仿真验证级别、以 KV 缓存静态存储与读取为主要访问模式”之内。任何超出此范围的推广——如“有机 CIM 适用于所有 LLM 推理场景”——均被明确排除。

此外，边界界定有助于区分**本征贡献**与**工程外延**。本工作的本征贡献在于建立“有机 CIM 物理特性—KV 缓存访问模式—系统性能指标”的映射关系；而 7B+ 模型的多片扩展、128k 上下文的 3D 堆叠、光电前端的联合优化等，均属于该本征贡献之上的工

表 6.11: 范围边界与排除理由

| 排除项            | 理由                                                                                 |
|----------------|------------------------------------------------------------------------------------|
| >7B 参数模型       | 有机交叉阵列的当前密度不足以单片容纳 7B+ 模型的完整 KV 缓存；多片划分属于系统架构问题，非本工作的器件物理焦点                        |
| >32k token 上下文 | 超长上下文需要 3D 堆叠、混合存储层级或片外卸载，这些属于通用存储系统研究，不特定于有机 CIM 的物理贡献                            |
| KV 缓存的片上训练     | 训练过程需要高频原地更新 K/V 张量，超出有机器件 $10^3$ – $10^4$ 次耐久极限；该方向归入第八章展望（continual learning 场景） |
| 生产部署声明         | 本工作以行为级仿真为主，所有结论均标注”仿真验证”或”原型级”，不做大规模商用部署承诺                                        |
| 完整光电协同设计       | 光子前端（photodiode）与 CIM 权重的联合训练属于 Direction D 的研究范畴，其部分洞察将汇入前端设计相关章节，但不作为独立实验展开      |
| 多片/芯粒扩展        | 多片互连和芯粒（chiplet）架构属于 Direction A 的研究范畴，其部分设计考虑将汇入第6.5.2节架构探索，但不作为独立贡献              |

程外延，留待后续研究或产业界探索。这种区分使得本工作的科学焦点清晰，避免了因追求“全栈覆盖”而导致的论证稀释。

从学位论文的完成可行性角度，上述边界确保了研究工作量与硕士研究生培养周期的匹配。四组实验（噪声鲁棒性、架构探索、压缩协同设计、时间动态）的总仿真时间预计为 200–400 GPU 小时，在单卡 RTX 5070 Ti 上可于数周内完成。排除 >7B 模型和超长上下文后，单次实验的反馈周期控制在分钟级，支持充分的参数扫描和消融分析。若纳入 7B 模型或 128k 上下文，单次推理即可能耗时数小时，参数扫描将不可行。因此，范围边界的设定既是科学判断，也是对硕士论文实际可完成性的审慎评估。

## 6.8 本章小结与向第七章的过渡

本章系统界定了硕士论文第二个核心工作（Work 2）的研究范围：以有机光电模拟存内计算（CIM）作为大语言模型 KV 缓存的存储与计算层，面向 1–3B 边缘 LLM 推理场景，通过行为级仿真评估有机 CIM 在物理特性上与 KV 缓存访问模式的结构匹配。

本章的核心论点可概括为三个层次：**物理匹配**——有机 OEC-RAM 的  $\sim 10^3$  s 保持时间和  $10^3$ – $10^4$  次耐久性落入 KV 缓存 WORM 访问模式的“最优区间”；**机制优势**——光学刷新将 Work 1 中识别的“光敏噪声源”转化为低能耗、无耐久代价的数据维持机制；**系统评估**——Remote 107 阶段性实验提示：全层模拟 KV 缓存即使在 8-bit 零噪声下亦超出 10% 困惑度退化门限（17.48 vs 15.68），而选择性终端层（last1）在 fresh-D2D 交叉实例验证中表现稳定（eval D2D=0.02–0.05 时 PPL=18.42–18.60，变异系数 < 0.3%），可作为有机 CIM KV 缓存的候选路线；该路线仍需通过 manifest 补全与最小重跑后锁定。

在方法论上，本工作沿用并扩展了 Work 1 建立的行为级模拟器框架，确保跨工作的一致性；在论证结构上，Work 2 与 Work 1 形成互补——前者分析有机 CIM 在动态推理中的局限，后者论证其在静态存储中的优势，共同构建起“有机 CIM 适用性评估”的完整图景。

在结束本章之前，有必要基于 Remote 107 已获得的阶段性数据预演 Work 2 的结果走向。当前证据暂时支持假设 6.3 在选择性终端层范围内作为候选方向：last1 配置在  $\sigma_{\text{d2d}} \leq 0.05$ 、8-bit 量化条件下困惑度退化控制在 < 20%，且 fresh-D2D 方差较低（ $\sigma_{\text{PPL}} < 0.05$ ）。这表明有机 CIM KV 缓存在特定层范围内具有进一步实验价值，但仍属于规划与审计证据，不作为最终部署结论。后续工作将关注：（1）last1 配置的 3 种子完整重复与元数据规范化，以达成论文锁定标准；（2）last2 及更大覆盖范围的 HAT 适配效益评估；（3）器件工艺优化（提升  $\tau$  和  $N$ ）与光电前端集成。假设 6.1 和 6.2 的完全验证尚需实验四的时间动态数据。

第七章将补充展开实验二（架构探索）的帕累托前沿分析、实验三（压缩协同设计）的有机模拟存储与 KIVI 数字量化对比、以及实验四（时间动态）的保持时间—刷新策

略权衡曲线。实验一的阶段性趋势——全层模拟 KV 缓存的噪声敏感性、选择性终端层的候选可行性、以及 last1/last2 的 fresh-D2D 低敏感性——已在本章第6.5.5节报告，第七章将不再重复，而是关注：（1）等 footprint 下有机模拟与数字量化的精度—能效对比；（2）延迟—能耗—面积三维空间中的最优配置识别；（3）时间动态条件下光学刷新的能效优势量化。各节均以 FP16 基线为参照，以  $\Delta_{\text{PPL}}$  和下游任务指标为统一比较语言，确保结论的可追溯性和可复现性。

最终，第七章将在综合全部实验证据的基础上，对第6.3节提出的三项核心假设作出明确判断：假设6.1（保持时间匹配）和假设6.2（耐久性适配）是否得到器件物理与时间动态层面的支持？假设6.3（模拟精度充分）是否在 last1 选择层范围内以  $N\text{-}\sigma$  操作窗口的形式成立？这些判断将直接支撑或修正本章提出的中心论点，并为第八章的未来展望提供实证基础。



## 第七章 部署包络

本章将前六章的仿真数据转化为可操作的部署知识，为有机光电存算一体（CIM）阵列上的视觉 Transformer 落地提供定量边界。前序章节已建立了 HAT 分类学、失效模式图谱与缓解策略的完整物理图景；本章的任务是回答一个工程问题：在给定的器件参数组合下，Ensemble HAT 训练协议能否在未见硬件实例上保持可用的精度排序？若不能，崩溃边界在哪里？

全章仅使用已冻结的实验数据，所有外推均明确标注不确定度。

### 7.1 部署场景定义

#### 7.1.1 目标应用：边缘视觉推理


本章的部署包络面向边缘视觉推理场景：在功耗受限的端侧设备上，对  $32 \times 32$  至  $224 \times 224$  分辨率的图像执行单标签分类。基准模型为 Tiny-ViT-5M（CIFAR-10 数字基线 98.06%），阵列映射方式采用第三章所述的混合模拟-数字分区：注意力 QKV、投影层与 MLP 的权重矩阵部署于有机光电阻变阵列，层归一化、Softmax 与分类头保留数字实现。

#### 7.1.2 CIM 阵列规模与外围约束

仿真框架将每个模拟层视为独立的交叉阵列瓦片（crossbar tile）。以 Tiny-ViT-5M 为例，全模型共 42 个可映射的模拟层，其中 Attention QKV 10 层、Attention Projection 10 层、FFN (fc1+fc2) 20 层、Patch Embedding 2 层。层敏感度扫描（冻结数据，见 `layer_sensitivity_results_gpt.json`）表明，在标准 HAT 检查点上对各层组单独注入 5% C2C 噪声时，各组孤立精度均维持在 91.61%–91.72% 区间，差异小于 0.11 pp，说明在 canonical 均匀噪声下没有单一层组构成明显的精度瓶颈。

进一步的全 42 层单层 D2D 重采样 pilot 扫描显示，逐层风险并非均匀分布。该扫描冻结 V4 检查点与其余层的 D2D 缓冲，仅对一个目标模拟层重新采样  $\sigma_{D2D} = 10\%$  失配，并在 512 张 CIFAR-10 子集、3 个随机种子上估计精度掉点（见 `layer_sensitivity_full42_summary_20260510.tsv`）。结果呈现明显 heavy-tail：末级 MLP 输出层 `stages.3.blocks.0.mlp.fc2` 的平均掉点达到 83.59 pp，而第二敏感层为 26.24 pp，多数 attention projection 与后段 attention 层低于 1 pp。该证据仍为 pilot/provisional，不能替代完整测试集或 fresh-instance 协议；但它提示混合精度或冗余保护不应平均分配到所有阵列，而应优先覆盖少数 catastrophic outlier。

为检验该排序是否能转化为部署保护策略，本研究追加了一个 P1 上界型保护 pilot：在 2048 张 CIFAR-10 子集与 3 个种子上，将所有模拟层重采样为 fresh D2D 实例，然




**图 7.1:** 全 42 个可映射模拟层的单层 D2D 重采样敏感度 pilot。每次仅重采样一个目标层，其余层恢复到 V4 检查点 D2D 缓冲；精度掉点在 512 张 CIFAR-10 子集与 3 个种子上统计。该图用于定位混合精度保护候选，不作为最终 claim-bearing 验证。

后把 full42 排名前  $K$  的敏感层保留在 checkpoint D2D (`freeze_topK_d2d`)，其余层仍使用 fresh D2D。结果如图 7.2 所示。完全 fresh 的全模拟模型仅为 8.89%；保护前 10 层提高到  $26.22 \pm 3.62\%$ ，保护前 13 层提高到  $39.34 \pm 6.16\%$ 。这说明 full42 排序确实携带救援信号，但只保护少数 outlier 仍不足以恢复接近 checkpoint 的 92.58% 源域子集精度。另外，简单把 top-10/13 层设为无噪声高精度上界并不能救回 fresh 全层失配，提示失配补偿不是局部旁路即可解决的线性叠加问题。因此，混合精度策略在本文中只能作为候选设计方向；最终部署级证据仍需要 full-test 或 fresh-instance 协议验证，并可能需要与 Ensemble HAT 训练期重采样联合，而非仅做推理期层保护。

外围读出电路的能效约束通过一阶解析模型估算。在 8 bit ADC、100 个阵列、1000 次转换的基准假设下，系统总能量约为  $23.9 \mu\text{J}$  (FP32 数字基线约  $273.94 \mu\text{J}$ )，对应相对 FP32 的加速比约为  $11.45\times$ ，相对假设 INT8 的加速比约为  $2.86\times$ （见 `energy_scale_recovery_sensitivity.json`）。该估算为一阶解析假设，非流片测量值；实际部署需根据具体 CMOS 工艺节点重新标定。

### 7.1.3 功耗约束与刷新策略

有机阵列的保留漂移 (retention drift) 引入时间维度上的功耗-精度权衡。V8 保留轨迹显示： $t = 0 \text{ s}$  时源域精度为 91.63%， $t = 1 \text{ s}$  骤降至 82.66%，随后在 10 s 至 10,000 s 区间形成 79.13–79.51% 的宽平台。若应用要求  $> 82\%$  精度，则动态标度重校准的刷新



**图 7.2:** 基于 full42 排序的 P1 保护策略 pilot。**freeze\_topK\_d2d** 将排名前  $K$  的敏感层保留为 checkpoint D2D，其余层重采样为 fresh D2D；**noiseless\_topK\_hp\_upper** 为乐观高精度/无噪声上界。结果显示前 13 层保护可产生明显救援，但仍远低于源域 checkpoint 精度。

间隔须短于约 1 s；若可接受 79% 精度，则间隔可延长至数小时。该任务依赖性刷新规格直接影响外围参考单元读出电路的能耗预算。

## 7.2 ADC 分辨率包络

### 7.2.1 6-bit 悬崖：量化主导区与 D2D 主导区的分界

ADC 精度是决定系统能否脱离近随机猜测状态的首要参数。在 63 点联合扫描 ( $\sigma_{D2D} \in \{1, 3, 5, 8, 10, 15, 20\}\%$ ,  $ADC \in \{2, 3, 4, 5, 6, 7, 8, 10, 12\}$  bit,  $C2C=5\%$ ,  $NL = 1.0$ , 每点 10 次蒙特卡洛运行) 中，精度随 ADC 位宽呈现明显的两阶段结构（见 `iso_accuracy_contour_data.json`）：

- **亚 5-bit 区**：所有 D2D 水平下精度均接近随机（~10%–15%）。3-bit ADC 在 10% D2D 下均值仅 13.62%；2-bit ADC 在所有 D2D 水平下均低于 12%。
- **5–6-bit 过渡区**：存在约 7 pp 的陡峭跳变。以 10% D2D 为例，5-bit 均值 76.85%，6-bit 跃升至 84.77%，增量达 7.92 pp；七个 D2D 级别的平均跳变为 ~7 pp（单行间 5.8–8.1 pp）。
- **≥6-bit 操作区**：精度退化由 D2D 主导。在 10% D2D 下，6-bit 为 84.77%，8-bit 为 87.12%，12-bit 为 86.98%；继续提升 ADC 位宽收益递减。

### 7.2.2 Sobol 全局敏感度分解

为定量区分 ADC 精度与 D2D 失配的相对贡献，对联合扫描数据执行一阶 Sobol 敏感度分析（见 `sobol_sensitivity.json`）：

- **全参数网格**（含亚 5-bit 区）： $S_{\text{ADC}} = 0.976$ ， $S_{\text{D2D}} = 0.018$ ，交互项  $S_{\text{inter}} = 0.006$ 。ADC 位宽解释了约 97.6% 的精度方差，说明在跨越悬崖的宏观尺度上，读出精度是压倒性主因。
- **操作区**（ADC  $\geq 6\text{-bit}$  且  $\sigma_{\text{D2D}} \leq 15\%$ ）： $S_{\text{ADC}} = 0.041$ ， $S_{\text{D2D}} = 0.922$ ，交互项  $S_{\text{inter}} = 0.038$ 。一旦越过 6-bit 悬崖，D2D 失配立即成为剩余方差的 92.2% 来源。

该两阶段结构具有明确的工程含义：**6-bit ADC 是当前混合架构的最小可行外围**。低于 5-bit，无论训练协议如何精进，系统均无法脱离随机水平；高于 6-bit，投资回报比的排序变为 D2D 均匀性  $>$  ADC 位宽。

### 7.2.3 ADC 非理想性的边际效应

在 8-bit 基线上，对偏移、增益误差与积分非线性（INL）的独立扫描（见 `adc_nonideality_final.json`）显示： $\pm 0.5$  LSB 偏移几乎无影响（63.02% vs 理想 63.04%）； $\pm 5\%$  增益误差导致  $-0.77$  pp；0.5 LSB INL 无影响；组合现实场景（ $\pm 0.5$  LSB 偏移 +5% 增益误差 +0.5 LSB INL）仅下降  $-0.75$  pp 至 62.29%。这些非理想性在绝对数值上远小于 6-bit 悬崖的 7 pp 跳变，说明在部署包络中，位宽本身比位宽内的线性度更重要。

## 7.3 D2D 失配包络

### 7.3.1 固定掩膜 HAT 的硬件实例过拟合

标准 HAT（固定掩膜，fixed-mask）在训练时阵列上可达  $87.95 \pm 0.27\%$ ，但在 10 个全新硬件实例上的 fresh-instance 评估中，精度 deterministic 地崩塌至  $10.00 \pm 0.00\%$ 。该结果已在 AMP 关闭的 FP32 推理路径上独立复现，确认其为优化器耦合到特定空间失配图  $M_0$  的结构性后果，而非数值 artifact。

该崩塌是**绝对的**：它不因 D2D 幅度降低而改善。在文献标定的 OPECT 低噪声代理（ $\sigma_{\text{D2D}} = 3\%$ ， $\sigma_{\text{C2C}} = 2\%$ ）下，标准 HAT 检查点同样崩塌至 10.00%。因此，对于任何要求跨实例鲁棒性的有机 RRAM 工艺，**固定掩膜 HAT 不可作为部署候选**。

### 7.3.2 Ensemble HAT 的跨实例统计

Ensemble HAT 通过每轮 epoch 重采样 D2D 失配图，将实例分布烘焙进训练目标。在相同的 10 实例  $\times$  5 MC 评估协议下，其结果为：

- **Canonical 均匀噪声**（ $\sigma_{\text{D2D}} = 10\%$ ，i.i.d.）： $86.16 \pm 0.19\%$ （见 canonical fresh-instance 评估记录）。

**表 7.1:** D2D 失配包络: 标准 HAT 与 Ensemble HAT 的 fresh-instance 精度对比 (CIFAR-10 top-1,  $10 \times 5$  协议)

| D2D 条件            | 标准 HAT           | Ensemble HAT     | 差值        |
|-------------------|------------------|------------------|-----------|
| i.i.d. 10% D2D    | $10.00 \pm 0.00$ | $86.16 \pm 0.19$ | +76.16 pp |
| OPECT 代理 3% D2D   | $10.00 \pm 0.00$ | $88.53 \pm 0.08$ | +78.53 pp |
| 空间相关 $\rho = 0.3$ | 10.00 (外推)       | $84.57 \pm 2.39$ | +74.57 pp |
| 空间相关 $\rho = 0.5$ | 10.00 (外推)       | $82.12 \pm 3.95$ | +72.12 pp |

- **中度空间相关 D2D** ( $\rho = 0.3$ , 可分 AR(1) 模型, zone 3A 免疫协议, NL=1.0, AMP 关闭):  $84.57 \pm 2.39\%$  (见 `fresh_instance_eval_v4_ensemble_correlated_d2d.json`)。相对 i.i.d. 基线仅下降 1.76 pp, 排序保持。
- **强空间相关 D2D** ( $\rho = 0.5$ , zone 3A 免疫协议):  $82.12 \pm 3.95\%$  (同前)。相对基线下降 4.20 pp, 但最差实例仍为 73.7%, 远离随机水平。

表 7.1 表明, Ensemble HAT 的精度优势不依赖于 10% D2D 的特定假设: 在低噪声文献代理和高空间相关性两种极端条件下, 排序均稳定保持, 且跨实例标准差随相关性增强而增大 ( $0.19 \text{ pp} \rightarrow 3.95 \text{ pp}$ ), 均值相应下降。

## 7.4 噪声-非线性权衡

### 7.4.1 严重非线性写入的恢复带

写入非线性 (NL) 是第二道硬边界, 但修订梯度缩放配方后, 其影响呈系统性退化而非结构性崩塌。在  $NL = 2.0$ 、canonical 均匀噪声下, M 系列 6 次训练 (Standard/Ensemble $\times$ Uniform/Proportional $\times 2$  种子) 的 fresh-instance 结果如下 (见 `nl_postfix_recovery_band.json`):

- **Standard HAT** (固定掩码, 均匀噪声, M1/M5): 均值 **81.2%**, 跨实例标准差  $< 2 \text{ pp}$ ;
- **Ensemble HAT** (均匀噪声, M2/M6): 均值 **80.7%**, 跨实例标准差  $< 2 \text{ pp}$ ;
- **Ensemble HAT** (比例噪声, M3/M4): 均值 **80.7%**, 跨实例标准差  $< 2 \text{ pp}$ 。

三组配置收敛至同一  $\sim 80\text{--}82\%$  带, 差距  $< 1 \text{ pp}$ , 表明  $NL = 2.0$  下 severe NL 已成为绑定约束, 训练协议优化收益饱和。

**ADC-on 与 ADC-off 对比:** 8-bit ADC 开启仅比理想读出低  $\sim 0.10 \text{ pp}$  (zone 3C), 说明读出量化不是主导因素。

**6-bit 点检:** 6-bit ADC 点检显示  $-2.8 \text{ pp}$  悬崖 (zone 3C), 再次确认 6-bit 为最小可行外围。

**残余差距:** 相对  $NL = 1.0$  基线 ( $86.16\%$ ),  $NL = 2.0$  的系统性退化约  $5.7 \text{ pp}$ 。该差距源于状态依赖的 LTP/LTD 不对称缩放重塑了优化景观, 使注意力通路的特征几何

对 D2D 实现的变化更加敏感。然而，与先前基于未修订梯度缩放配方报告的  $\sim 30\%$  不同，当前修订配方下的  $\sim 80\text{--}82\%$  表明瓶颈是可量化的代理梯度近似误差，而非不可逾越的结构壁垒。

#### 7.4.2 从 $NL = 1.0$ 到 $NL = 2.0$ 的系统性退化

$NL = 1.0$  时 Ensemble HAT fresh-instance 精度为  $86.16\%$ ， $NL = 2.0$  时降至约  $80.7\%$  (Ensemble HAT，均匀噪声)。退化幅度约  $5.7$  pp，呈单调趋势。梯度缩放替代模型在  $NL$  增大时产生状态依赖的 LTP/LTD 不对称缩放，该不对称性重塑了优化景观，但并未导致灾难性崩塌。保守边界为： $NL = 2.0$  处于可用但次优区， $NL \geq 2.5$  的实验数据尚缺，不建议外推。

### 7.5 跨器件零样本迁移

#### 7.5.1 文献标定器件：OPECT 代理

作为文献锚定的参考点，将 Ensemble HAT 检查点零样本迁移至 Zhang et al. (2025) 报道的 OPECT 阵列代理 ( $\sigma_{D2D} = 3\%$ ， $\sigma_{C2C} = 2\%$ ，动态范围 47.3，34 电导态) (见 `literature_profile_eval.json` 与 `ensemble_literature_profile_eval.json`):

- Ensemble HAT:  $88.53 \pm 0.08\%$  ( $n = 10$  fresh-instance 评估)。
- 标准 HAT:  $10.00 \pm 0.00\%$ ，同样 deterministic 崩塌。

$88.53\%$  距数字 FP32 基线 ( $98.06\%$ ) 仍差约  $9.5$  pp，但已比标准 HAT 的崩塌高出约  $78.5$  pp。该结果同时设定了当前 Tiny-ViT 架构在接近理想模拟条件下的精度天花板：约  $88.5\%$ ，跨实例标准差仅  $0.08$  pp，小于 CIFAR-10 测试集本身的采样噪声。

#### 7.5.2 内部实测器件：Doctor OECT

对内部实测的非易失 OECT 器件配置文件 (源自内部 PPT 原始数据导出) 执行相同协议 (见 `doctor_measured_profile_eval.json`):

- RC-16 配置 (16 态，动态范围 5.75): Ensemble HAT  $89.8\%$ ; 标准 HAT  $10.2\%$ 。
- RC-64 配置 (64 态，动态范围 6.18): Ensemble HAT  $89.2\%$ ; 标准 HAT  $10.2\%$ 。

实测器件的 D2D 几乎为零 ( $\sigma_{D2D} = 0$ )，C2C 亦低于  $0.37\%$ ，因此精度高于 OPECT 文献代理，但标准 HAT 仍崩塌至  $10.2\%$ ，再次确认硬件实例过拟合风险不随器件均匀性改善而自动消失。

#### 7.5.3 跨仿真器验证：CrossSim 基准

为验证框架结果的外部一致性，在 ConvNeXt-Tiny C4 检查点上与 CrossSim<sup>56</sup> 执行同参数对比 (见 `crosssim_standard_noise.json`， $\sigma_{C2C} = 5\%$ ， $\sigma_{D2D} = 5\%$ ，8-bit ADC，4-bit 权重， $n = 3$  种子):

表 7.2: TinyImageNet-200 跨架构比例噪声 HAT 验证。

| 架构         | HAT          | 种子  | 源域 (%) | Fresh (%) | Std (%) |
|------------|--------------|-----|--------|-----------|---------|
| DeiT-Small | digital      | 123 | 48.22  | 48.22     | 0.00    |
| DeiT-Small | proportional | 123 | 50.24  | 50.20     | 0.10    |
| DeiT-Small | digital      | 456 | 53.61  | 53.61     | 0.00    |
| DeiT-Small | proportional | 456 | 54.44  | 54.19     | 0.09    |
| DeiT-Small | digital      | 789 | 53.58  | 53.58     | 0.00    |
| DeiT-Small | proportional | 789 | 56.54  | 56.33     | 0.13    |
| ViT-Small  | digital      | 123 | 48.83  | 48.83     | 0.00    |
| ViT-Small  | proportional | 123 | 49.03  | 49.00     | 0.09    |
| ViT-Small  | digital      | 456 | 54.58  | 54.58     | 0.00    |
| ViT-Small  | proportional | 456 | 54.06  | 53.90     | 0.13    |
| ViT-Small  | digital      | 789 | 50.86  | 50.86     | 0.00    |
| ViT-Small  | proportional | 789 | 55.85  | 55.41     | 0.10    |

- 本框架 (含 fresh D2D 重采样 + ADCQuantHookManager): **81.63 ± 0.56%**。
- CrossSim (通用编程误差/读取噪声映射): 67.20 ± 2.67%。

在零噪声基线 (`crosssim_clean_baseline.json`) 下, 本框架 86.2%, CrossSim 83.7%, 差距缩小至 2.5 pp; 在低噪声 (1% D2D/C2C) 下, 本框架 85.9%, CrossSim 82.9%。差距主要来源于噪声映射方式: 本框架采用固定 D2D + 每前向 C2C 的显式分离, 而 CrossSim 使用统一编程误差/读取噪声幅度, 在高噪声区对失配结构的建模更保守。81.63% 与 CrossSim 的 67.2% 之间的 14.4 pp 差距说明训练-仿真失配 (training-simulation mismatch) 对精度预测有显著影响, 本框架的 profile-driven 接口用于缩小这一差距。

## 7.6 跨架构验证

前述部署包络以 Tiny-ViT-5M 在 CIFAR-10 上的数据为锚点。一个关键的未决问题是: 精度排序逻辑——Ensemble HAT > 固定掩膜 HAT > 朴素部署——在迁移到更大规模数据集与不同 Transformer 架构时是否依然成立。为回答该问题, 在 TinyImageNet-200 (200 类, 64 × 64 分辨率) 上对 DeiT-Small 与 ViT-Small (均为 Patch16-224 骨干网) 执行了跨架构验证, 协议与论文章节 fresh-instance 标准一致: 10 个独立硬件实例 × 每实例 5 次蒙特卡洛前向传播。

表 7.2 汇总了 digital 与比例噪声 HAT 在三组训练种子 (123/456/789) 下的 fresh-instance 精度。三个规律立即显现。

**第一, 比例噪声 HAT 消除了 fresh-instance 模态崩溃。**在所有种子与两种架构上, 比例噪声训练的 fresh-instance 精度与 digital 基线持平 (差值 -0.04 至 -0.44 pp), 未出现标准 HAT 的灾难性崩塌 (相对训练精度跌落约 -34 pp)。三种子平均而言, DeiT 上

表 7.3: 按器件成熟度等级的部署决策矩阵

| 参数             | 研究级                            | 中试级               | 量产级               |
|----------------|--------------------------------|-------------------|-------------------|
| $\sigma_{D2D}$ | $\geq 10\%$ (常 15–20%)         | 3%–8%             | $\leq 3\%$        |
| 写入非线性 $NL$     | $\geq 1.5$                     | 1.0–1.2           | $\approx 1.0$     |
| ADC 位宽         | $\leq 5$ bit (未标定)             | 6–8 bit (已标定)     | $\geq 8$ bit      |
| 动态重校准          | 无                              | 有 (间歇式)           | 有 (片上)            |
| ViT 部署建议       | 不通过                            | 通过 + Ensemble HAT | 通过 + Ensemble HAT |
| 预期精度           | $< 15\%$ (ADC $< 6$ -bit 悬崖主导) | 84–89%            | 88–90%            |
| 首要投资方向         | 外围读出                           | 前端补偿 + 刷新策略       | 良率规划              |

比例噪声 HAT 优于 digital 训练 +1.77 pp, ViT 上优于 digital +1.35 pp (fresh-instance 均值)。这说明比例噪声律——将失配方差按电导幅度缩放——不仅是物理上合理的应力测试,更是在电导依赖噪声体制下能够 提升精度的可行替代方案。

第二,固定掩膜 HAT 的崩塌 severity 是架构无关的。在早期种子实验中 (未列入表 7.2), DeiT 从 40.9% 训练精度跌至 6.6% fresh (−34.3 pt), ViT 从 38.8% 跌至 6.9% (−31.9 pt),表明硬件实例过拟合是 训练协议的属性,而非特定骨干网的属性。

第三,种子敏感度不可忽略。digital 与比例噪声协议均表现出显著的种子方差 (DeiT 上  $\pm 2.5$ – $2.9$  pt, ViT 上  $\pm 0.2$ – $4.6$  pt)。ViT digital seed456 (54.58%) 较 seed123 高 +5.75 pt、较 seed789 高 +3.72 pt,该 outlier 归因于种子依赖的训练动态,而非协议偏差。作为对比,Ensemble HAT 与标准 HAT 在模拟噪声路径激活后展现紧密方差 ( $< 0.6$  pt)。该模式提示模拟噪声本身充当方差正则化器——一旦 HAT 激活,前向路径扰动抑制了种子间差异——因此模拟映射模型对训练随机性的敏感度不比 digital counterpart 更高,在某些体制下反而更低。

跨架构数据不改变绿色区排序,但 拓宽了其适用范围。CIFAR-10 上的规范排序在单架构单数据集上导出;TinyImageNet-200 验证表明该 方向在更大视觉任务上依然成立,尽管 绝对裕量收缩。比例噪声 HAT 在 CIFAR-10 实验中被视为物理扩展应力测试,而在跨架构验证中成为电导依赖噪声体制下的可信主训练协议。

7.7 部署建议与风险排序

7.7.1 三级成熟度决策矩阵

基于上述包络,将器件工艺划分为三个成熟度等级,给出可操作的通过/不通过建议:

**研究级** (表 7.3) 不应部署 ViT: 亚 5-bit ADC 产生近随机精度 ( $\sim 10$ – $15\%$ ),这是不可逾越的悬崖。建议将该等级阵列用作训练诊断平台:以 Ensemble HAT 训练检查点,评估源域与 fresh-instance 之间的精度鸿沟,用该鸿沟指导工艺改进。**中试级**可部

署：6-bit ADC 已越过悬崖，OPECT 代理给出  $88.53 \pm 0.08\%$ ，canonical 10% D2D 给出  $86.16 \pm 0.19\%$ ，均处于原型级可行区间。**量产级**应将 Ensemble HAT 视为保险而非救援：即使噪声极低，标准 HAT 仍存在跨实例崩塌风险。

### 7.7.2 风险排序：非协商项与可协商项

将各物理参数按不可协商程度排序：

1. **ADC  $\geq 6$  bit (绝对非协商)**。低于 5 bit 时所有训练协议均失效。从 5 bit 提升至 6 bit 是投资回报率最高的单点干预。
2. **写入线性度  $NL < 1.5$  (可协商, 影响均值)**。 $NL = 2.0$  时 fresh-instance 精度约 80–82% (修订配方)，低于  $NL = 1.0$  基线约 5.7 pp，但仍处于可用区间。若工艺无法将  $NL$  压至 1.5 以下，可通过设备线性化或高阶梯度修正进一步缩小差距。
3. **训练协议 = Ensemble HAT (强非协商)**。标准 HAT 在所有测试条件下均 deterministic 崩塌至 10%，无例外。固定掩膜训练不可用于任何要求跨实例鲁棒性的场景。
4. **D2D 均匀性 (可协商, 影响均值与方差)**。在  $ADC \geq 6$  bit 且  $NL = 1.0$  时，D2D 从 3% 恶化至 20% 仅使 Ensemble HAT 均值从 88.5% 降至 74.5%，不会导致崩塌。空间相关性  $\rho$  增大主要加宽方差 ( $0.19 \text{ pp} \rightarrow 3.95 \text{ pp}$ )，可经由良率规划吸收。
5. **C2C 重复性 (弱可协商)**。在操作区内，C2C 被数字恢复路径大量屏蔽；5% C2C 的有效误差常低于半 LSB。应优先投资空间均匀性而非时序稳定性。

### 7.7.3 对项目管理者者的行动清单

- **空间协方差测量**：在中试线上测量 D2D 空间协方差核；若  $\rho > 0.4$ ，需引入空间校准网格或 correlated-HAT 训练，否则最坏实例可能跌破 75%。
- **NRE 节省**：Ensemble HAT 免除逐器件重新训练。按单卡单轮 100 epoch、每 epoch  $\sim 2$  小时估算，100 片测试阵列可节省约 20,000 GPU-时，对应 2025 年云算力成本约 5–10 k 美元。
- **刷新频率协商**：在定案阵列规模前，与应用团队确认精度阈值与刷新闻隔的联合规格。外围参考单元读出能耗随模拟层数线性增长，需在  $11.45\times$  能效增益估算中扣除 5–15% 的外围开销。
- **化合物应力冒烟测试**：单一组合应力测试 (2% C2C + 3% D2D + 6-bit ADC + 1% IR 压降 + 1% sneak path + 1,000 s 保留) 给出 89.61% 的单次运行精度。该值非锁定保证，但可作为集成计划的冒烟测试：若目标剖面的组合应力预测低于 80%，设计过于激进，应在流片前降规。

### 7.7.4 包络的显式边界

本章所有推荐均受以下未建模现象约束：

- **空间 IR 压降**：当前框架仅含 1% 标量占位符，未建模字线/位线上的位置相关电压衰减。大规模阵列（如  $512 \times 512$ ）远角的有效失配可能超过 15%。
- **sneak path**：被动交叉阵列的潜行电流可产生乘性误差，破坏标度恢复假设，可能将 6-bit 悬崖上推。
- **温度漂移**：当前假设室温（ $\approx 300$  K）。有机半导体载流子迁移率与陷阱态占据对温度高度敏感； $25^\circ\text{C}$  有效的包络在  $60^\circ\text{C}$  可能失效。
- **交互前沿**：严重  $NL$  + 空间相关 D2D + 长期保留漂移的联合效应尚未测量，保守外推认为可能低于 25%。

在以上边界之内，部署包络为有机光电 CIM 上的现代视觉骨干网络提供了从仿真数据到出货判据的定量桥梁。

## 本章小结

本章构建了有机光电存算一体阵列上 Tiny-ViT 部署的定量包络：

- ADC 分辨率存在 **6-bit 悬崖**，Sobol 分解确认全网格  $S_{\text{ADC}} = 0.976$ ；越过悬崖后 D2D 主导剩余方差（ $S_{\text{D2D}} = 0.922$ ）。
- D2D 失配包络显示 Ensemble HAT 在 10% i.i.d.、 $\rho = 0.5$  相关、OPECT 3% 代理下分别保持 86.16%、82.12%、88.53%，而标准 HAT 全部崩塌至 10%。
- 噪声-非线性权衡表明  $NL = 2.0$  下存在**恢复带**：修订配方后 fresh-instance 精度达 80–82%（Standard HAT 81.2%，Ensemble HAT 80.7%），残余差距至  $NL = 1.0$  基线约 5.7 pp。
- 跨器件零样本迁移中，OPECT 代理达 88.53%，Doctor OECT 实测器件达 89.8%，CrossSim 交叉验证达 81.63%。
- 跨架构验证（DeiT-Small / ViT-Small on TinyImageNet-200，三种子）表明比例噪声 HAT 优于 digital 训练（DeiT +1.77 pp, ViT +1.35 pp），且未出现标准 HAT 的模态崩塌，确认排序方向在大规模视觉任务上依然成立。
- 部署建议将  $\text{ADC} \geq 6 \text{ bit}$ 、 $NL < 1.5$ 、Ensemble HAT 列为非协商项，D2D 均匀性列为可协商项，并给出按成熟度等级的通过/不通过决策矩阵。

包络之外，空间 IR 压降、潜行电流、温度漂移与联合交互前沿是下一阶段的优先扩展方向。

## 第八章 展望与结论

### 8.1 研究总结

本研究围绕有机光电存算一体 (Compute-in-Memory, CIM) 系统的算法—器件协同设计, 构建了一套面向混合模拟/数字推理的完整仿真栈, 系统评估了视觉 Transformer (ViT) 与大语言模型 (LLM) KV 缓存在有机模拟交叉阵列上的可行性、鲁棒性与能效边界。研究的核心贡献可概括为以下四个方面。

第一, 建立了从器件物理到系统精度的一阶行为级仿真框架 (第 三 章), 涵盖差分对电导映射、多电平量化、D2D/C2C 噪声、双指数保持衰减、光电前端补偿及 HAT 等模块。针对 Tiny-ViT-5M, 本研究将 87.7% 参数映射至模拟域, 覆盖注意力投影与前馈等密集算子; 动态注意力运算保留数字域执行, 构成系统能效的”模拟天花板”。

第二, 表明 Transformer 对模拟非理想性的敏感度高於 CNN, 尺度恢复 (scale recovery) 对维持激活动态稳定不可或缺 (第 三 章)。

研究进一步发现”硬件实例过拟合” (第 五 章): 固定 D2D 掩膜使模型记忆特定制造偏差, 面对全新实例时崩溃至 10.00%。Ensemble HAT 通过在轮次边界重采样 D2D 失配图, 将器件失配转化为随机正则化项, 将 fresh-instance 精度恢复至  $86.16 \pm 0.19\%$ 。

第三, 通过多维物理应力测试量化了系统的生存边界 (第 五 章与第 七 章): Ensemble HAT 在标准噪声体制下维持 86.16% fresh-instance 精度, 但 ADC 低于 6-bit 或比例噪声下出现刚性崩塌; CIFAR-100 等细粒度任务获益最大, Flowers-102 等小数据场景受 floor 效应限制。

第四, 将研究视野扩展至 LLM KV 缓存场景 (第 六 章)。Remote 107 阶段性审计结果提示: 全层模拟 KV 缓存在 8-bit 零噪声下已超出 10% 困惑度退化门限 (17.48 vs 15.68 PPL), 而选择性终端层 (last1) 在 fresh-D2D 验证中表现稳定 (PPL=18.42–18.60, 变异系数  $< 0.3\%$ ), 可作为有机 CIM KV 缓存的候选路径; 该方向仍需 manifest 补全与最小重跑后锁定。

### 8.2 未来研究方向

未来工作首先需把仿真框架推广至 ImageNet-1K 等大规模数据集, 并探索 DeiT-S、Swin-T 等更大视觉 Transformer 的映射可行性。模型规模的扩展将考验阵列容量与片上带宽的三角平衡, 数十亿参数模型的全映射将不可避免地走向多芯片铺排。

此外, LLM KV 缓存场景下的选择性终端层 HAT 已在 TinyLlama-1.1B 上显示出初步可行信号, 其向更大规模模型 (如 LLaMA-2-7B GQA) 的扩展将验证有机 CIM 在分组查询注意力架构下的可行性, 并为长上下文 (32k+) 场景中的保持时间假设提供关

键数据。

更关键的限制来自物理实验闭环。本研究目前基于文献先验与行为级参数化模型进行仿真，尚未与真实有机光电器件的晶圆级测量数据闭环。未来的首要任务是建立从实验室表征到仿真参数的自动化转换管线：将多级编程 I-V 曲线的电导窗口与积分非线性、重复读写统计的 C2C 方差、跨芯片阵列的 D2D 分布、保持衰减痕迹的双指数或 stretched-exponential 拟合，以及光响应非线性测量结果，通过统一接口自动拟合为 JSON 器件画像并直接驱动训练与推理脚本。

具体而言，当前默认的双指数保持模型 ( $\tau_1 = 140 \text{ ms}$ ,  $\tau_2 = 610 \text{ ms}$ ,  $A_0 = 0.6$ ) 需要替换为实际有机半导体材料（如 DNTT、C8-BTBT 及其衍生物）在不同温度与偏置条件下的测量值；电导积分非线性 (INL) 应通过实测电平码表而非均匀量化理想化来表征；而 NL\_LTP/NL\_LTD 的梯度缩放近似也应升级为脉冲级写 verify 动力学模型。只有在实测数据闭环后，仿真框架才能从行为级设计工具进化为真正的工艺协同设计 (DTCO) 平台。

系统级能效模型也需要从一阶估算走向外围电路显式建模。现有能耗模型将阵列到数字互连能耗笼统地归入 SRAM 读写项，未单独核算专用布线、数据编排 (data marshaling)、模拟—数字接口以及层间尺度恢复乘法器的开销。未来需引入更精细的外围电路模型，包括：按阵列分块 (tiling) 计费的 ADC/DAC 转换次数、可编程跨阻放大器 (TIA) 增益校准的能耗与面积代价、以及不同精度 ADC 在各模拟子算子上的分层自适应配置。

此外，当前模型尚未包含温度效应对载流子迁移率、阈值电压漂移及有机半导体能带重整化的影响，而这些在有机器件中尤为显著且与保持衰减强耦合。建立温度敏感的系统级能耗—精度联合模型，并引入位置相关的 IR 压降与潜行电流 (sneak-path) SPICE 校准模型，是向实际芯片部署迈进的必要步骤。

在可靠性层面，当前映射假设一次性编程 (one-time programming) 后权重静态驻留，忽略了长期推理过程中的电导漂移、读取干扰与热老化。未来应研究闭环写验证 (closed-loop write-verify) 策略，即在编程阶段通过逐脉冲反馈将电导精确收敛到目标窗口，并在运行期间引入周期性刷新、自适应偏置补偿或动态余量缩放 (dynamic margin scaling)，以对抗状态相关的保持衰减。

对于 KV 缓存场景，光学刷新机制——利用光子调制恢复电导态而不消耗耐久预算——是有机 OEC-RAM 的独特优势。系统评估光学刷新的能效边界、局部可控性与刷新策略，将为分钟级会话长度的 KV 缓存管理提供定量依据。对于高可靠性边缘应用，还需探索模拟纠错码 (analog ECC)、冗余阵列或三模冗余 (TMR) 方案。

最后，当单层阵列无法满足大模型参数量时，多芯片阵列铺排 (tiling) 与片间路由成为必然选择。未来的研究需解决模拟权重在多个物理芯片间的最优划分、片间模拟信号完整性 (串扰、衰减与阻抗匹配)、以及数字控制逻辑的分布式调度与同步等问题。有机光电 CIM 的独特优势在于光调控的多模态编程能力，这为利用光互连实现三维堆叠或晶圆级键合 (wafer-to-wafer bonding) 提供了天然接口：光信号既可作为权重编程手

段，也可作为片间高带宽、低电容的通信载体。

### 8.3 结论

有机光电存算一体技术为突破冯·诺依曼架构能效瓶颈提供了替代方案，但将现代深度学习推理映射至有机阵列并非简单的权重迁移，而需要算法、电路与器件的深度协同优化。忽视动态注意力数字开销、ADC 量化阈值或硬件实例过拟合风险将导致实验室原型与真实部署之间的显著鸿沟。

研究表明，Tiny-ViT 在标准器件波动下可保持  $86.16 \pm 0.19\%$  的 fresh-instance 精度，选择性终端层 KV 缓存 (last1, PPL=18.42–18.60) 则提供了一个仍待锁定的 LLM 推理候选方向。研究同时界定了物理边界：动态注意力的数字执行构成模拟天花板，系统能效提升被限制在约  $11.45\times$ ；ADC 分辨率存在 6-bit 刚性阈值；硬件实例过拟合与数据量 floor 效应限制了小数据场景适用性。材料层面的电导优化必须与读出精度、训练鲁棒性及数字—模拟分工协同考虑，方能实现有意义的端到端加速。本研究建立的仿真框架与开源工具链将为后续向真实器件闭环与芯片原型转化提供方法论支撑。



## 参考文献

- [1] Mark Horowitz. Computing’s energy problem (and what we can do about it). In *IEEE International Solid-State Circuits Conference (ISSCC)*, pages 10–14, 2014. doi: 10.1109/ISSCC.2014.6757323. URL <https://doi.org/10.1109/ISSCC.2014.6757323>.
- [2] Xiaochen Peng, Shanshi Huang, Hongwu Jiang, Anni Lu, and Shimeng Yu. DNN +NeuroSim v2.0: An end-to-end benchmarking framework for compute-in-memory accelerators for on-chip training. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 40(11):2306–2319, 2021. doi: 10.1109/TCAD.2020.3043731. URL <https://doi.org/10.1109/TCAD.2020.3043731>.
- [3] Mario Lanza et al. The growing memristor industry. *Nature*, 640:613–622, 2025. doi: 10.1038/s41586-025-08733-5.
- [4] Yunchao Xu, Yuan He, Dongyong Shan, Biao Zeng, and Qian-Xi Ni. Emerging artificial synaptic devices based on organic semiconductors: Molecular design, structure and applications. *ACS Applied Materials & Interfaces*, 2025. doi: 10.1021/acsami.4c17455. URL <https://doi.org/10.1021/acsami.4c17455>.
- [5] Haotian Guo, Jing Guo, Yujing Wang, Hezhen Wang, Simin Cheng, Zehao Wang, Qian Miao, and Xiaomin Xu. An organic optoelectronic synapse with multilevel memory enabled by gate modulation. *ACS Applied Materials & Interfaces*, 2024. doi: 10.1021/acsami.3c19624. URL <https://doi.org/10.1021/acsami.3c19624>.
- [6] Li Zhang, Wei Chen, and Jing Xu. Recent progress in organic optoelectronic synaptic devices. *Photonics*, 12(5):435, 2025. doi: 10.3390/photonics12050435. URL <https://doi.org/10.3390/photonics12050435>.
- [7] Uihoon Jung, Miseong Kim, Jaewon Jang, Jin-Hyuk Bae, In Man Kang, and Sin-Hyung Lee. Formation of cluster-structured metallic filaments in organic memristors for wearable neuromorphic systems with bio-mimetic synaptic weight distributions. *Advanced Science*, 11(9):2307494, 2024. doi: 10.1002/advs.202307494. URL <https://doi.org/10.1002/advs.202307494>.
- [8] Jianmin Zeng, Xinhui Chen, Shuzhi Liu, Qilai Chen, and Gang Liu. Organic memristor with synaptic plasticity for neuromorphic computing applications. *Nanomateri-*

- als*, 13(5):803, 2023. doi: 10.3390/nano13050803. URL <https://doi.org/10.3390/nano13050803>.
- [9] Lan Shen Hu, Marco Fattori, Winston Schilp, Roy Verbeek, Setareh Kazemzadeh, Yoeri van de Burgt, Auke Jisk Kronemeijer, Gerwin Gelinck, and Eugenio Cantatore. An energy-efficient solid-state organic device array for neuromorphic computing. *IEEE Transactions on Electron Devices*, 70(12):6520–6525, 2023. doi: 10.1109/TED.2023.3327947. URL <https://doi.org/10.1109/TED.2023.3327947>.
- [10] Y. Zhang, W. Chen, et al. Organic photoelectric transistor arrays for neuromorphic computing. *Nature Electronics*, 2025. Placeholder entry – verify before submission.
- [11] Dingyao Liu, Xinyu Tian, Jing Bai, Shaocong Wang, Shilei Dai, Yan Wang, Zhongrui Wang, and Shiming Zhang. A wearable in-sensor computing platform based on stretchable organic electrochemical transistors. *Nature Electronics*, 7:1176–1185, 2024. doi: 10.1038/s41928-024-01250-9.
- [12] Padinhare Cholakkal Harikesh, Deyu Tu, and Simone Fabiano. Organic electrochemical neurons for neuromorphic perception. *Nature Electronics*, 7:525–536, 2024. doi: 10.1038/s41928-024-01200-5. URL <https://doi.org/10.1038/s41928-024-01200-5>.
- [13] Yu-Pu Lin, Christopher H. Bennett, Théo Cabaret, Damir Vodenicarevic, Djaafar Chabi, Damien Querlioz, Bruno Jousselman, Vincent Derycke, and Jacques-Olivier Klein. Physical realization of a supervised learning system built with organic memristive synapses. *Scientific Reports*, 2016. doi: 10.1038/srep31932. URL <https://doi.org/10.1038/srep31932>.
- [14] Vinay Joshi, Manuel Le Gallo, Simon Haefeli, Irem Boybat, S. R. Nandakumar, Christophe Piveteau, Martino Dazzi, Bipin Rajendran, Abu Sebastian, and Evangelos Eleftheriou. Accurate deep neural network inference using computational phase-change memory. *Nature Communications*, 11:2473, 2020. doi: 10.1038/s41467-020-16108-9. URL <https://doi.org/10.1038/s41467-020-16108-9>.
- [15] Jungwook Choi, Zhuo Wang, Swagath Venkataramani, Pierce I-Jen Chuang, Vijayalakshmi Srinivasan, and Kailash Gopalakrishnan. PACT: Parameterized clipping activation for quantized neural networks. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 1028–1037, 2018. doi: 10.48550/arXiv.1805.06085. URL <http://proceedings.mlr.press/v80/choi18a.html>.

- [16] Josh Tobin, Rachel Fong, Alex Ray, Jonas Schneider, Wojciech Zaremba, and Pieter Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 23–30, 2017. doi: 10.1109/IROS.2017.8202133. URL <https://doi.org/10.1109/IROS.2017.8202133>.
- [17] Xueying Wu, Edward Hanson, Nansu Wang, Qilin Zheng, Xiaoxuan Yang, Huanrui Yang, Shiyu Li, Feng Cheng, Partha Pratim Pande, and Janardhan Rao Doppa. Block-wise mixed-precision quantization: Enabling high efficiency for practical ReRAM-based DNN accelerators. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 2024. doi: 10.1109/TCAD.2024.3409193. URL <https://doi.org/10.1109/TCAD.2024.3409193>.
- [18] Chenyu Wang, Zhen Dong, Daquan Zhou, Zhenhua Zhu, Yu Wang, Jiashi Feng, and Kurt Keutzer. EPIM: Efficient processing-in-memory accelerators based on epitome. In *Proceedings of the 61st ACM/IEEE Design Automation Conference (DAC)*, pages 1–6, 2024. doi: 10.1145/3649329.3657377. URL <https://arxiv.org/abs/2311.07620>.
- [19] Mengke Ge, Junpeng Wang, Binhan Chen, Yingjian Zhong, Haitao Du, Song Chen, and Yi Kang. Allspark: Workload orchestration for visual transformers on processing in-memory systems. *IEEE Transactions on Computers*, 2025. doi: 10.1109/TC.2024.3483633. URL <https://doi.org/10.1109/TC.2024.3483633>.
- [20] S. Kim, J. Lee, et al. HEMLET: Hybrid mapping for efficient transformer acceleration. *IEEE Transactions on Computer-Aided Design*, 2025. Placeholder entry – verify before submission.
- [21] Q. Lin, Q. Qin, et al. HARDSEA: Hardware-aware resistive design for efficient sram acceleration. *IEEE Transactions on Circuits and Systems*, 2024. Placeholder entry – verify before submission.
- [22] Malte J. Rasch, Diego Moreda, Tayfun Gokmen, Manuel Le Gallo, Fabio Carta, Cindy Goldberg, Kaoutar El Maghraoui, Abu Sebastian, and Vijay Narayanan. A flexible and fast PyTorch toolkit for simulating training and inference on analog crossbar arrays, 2021. URL <https://arxiv.org/abs/2104.02184>.
- [23] Corey Lammie, Wei Xiang, Bernabé Linares-Barranco, and Mostafa Rahimi Azghadi. Memtorch: An open-source simulation framework for memristive deep learning systems. *Neurocomputing*, 485:124–133, 2022. doi: 10.1016/j.neucom.2022.02.043. URL <https://doi.org/10.1016/j.neucom.2022.02.043>.

- [24] Sandia National Laboratories. Crosssim: Sandia's simulator for analog ai accelerators. Technical report, Sandia National Laboratories, 2024. URL <https://doi.org/10.2172/2585829>.
- [25] Pietro Belleri, Judith Pons i Tarrès, Iain McCulloch, Paul W. M. Blom, Zsolt M. Kovács-Vajna, Paschalis Gkoupidenis, and Fabrizio Torricelli. Unravelling the operation of organic artificial neurons for neuromorphic bioelectronics. *Nature Communications*, 15:5350, 2024. doi: 10.1038/s41467-024-49668-1. URL <https://doi.org/10.1038/s41467-024-49668-1>.
- [26] Junpeng Ji, Dace Gao, Han-Yan Wu, Miao Xiong, Nevena Stajkovic, Claudia Latte Bovio, Chi-Yuan Yang, Francesca Santoro, Deyu Tu, and Simone Fabiano. Single-transistor organic electrochemical neurons. *Nature Communications*, 16: 4334, 2025. doi: 10.1038/s41467-025-59587-4. URL <https://doi.org/10.1038/s41467-025-59587-4>.
- [27] Fanqing Zhang, Xinyi Shan, Zhenhua Ji, Yan Wang, Jing Zhao, and Zhongrui Wang. Large-scale high uniform optoelectronic synapses array for artificial visual neural network. *Microsystems & Nanoengineering*, 11:42, 2025. doi: 10.1038/s41378-024-00859-2. URL <https://doi.org/10.1038/s41378-024-00859-2>.
- [28] Heyi Huang, Xiangpeng Liang, Yuyan Wang, Jianshi Tang, Yuankun Li, Yiwei Du, Wen Sun, Jianing Zhang, Peng Yao, Xing Mou, Feng Xu, Jinzhi Zhang, Yuyao Lu, Zhengwu Liu, Jianlin Wang, Zhixing Jiang, Ruofei Hu, Ze Wang, Qingtian Zhang, Bin Gao, Xuedong Bai, Lu Fang, Qionghai Dai, Huaxiang Yin, He Qian, and Huaqiang Wu. Fully integrated multi-mode optoelectronic memristor array for diversified in-sensor computing. *Nature Nanotechnology*, 20(1):93–103, 2025. doi: 10.1038/s41565-024-01794-z. URL <https://doi.org/10.1038/s41565-024-01794-z>.
- [29] Ying Liu, Biao Wang, Lei Wu, Lulu Huang, Lu Lin, Li Xiang, Dongqing Liu, Shiguo Zhang, Chenguang Zhu, and Yijie Tao. Artificial visual synaptic architecture with high-linearity light-modulated weight for optoelectronic neuromorphic computing. *ACS Applied Materials & Interfaces*, 2023. doi: 10.1021/acsami.3c11495. URL <https://doi.org/10.1021/acsami.3c11495>.
- [30] Dingwei Li, Yitong Chen, Huihui Ren, Yingjie Tang, Siyu Zhang, Yan Wang, Lixiang Xing, Qi Huang, Lei Meng, and Bowen Zhu. An active-matrix synaptic phototransistor array for in-sensor spectral processing. *Advanced Science*, 11, 2024. doi: 10.1002/advs.202406401. URL <https://doi.org/10.1002/advs.202406401>.

- [31] Tianqing Wan, Bangjie Shao, Sijie Ma, Yue Zhou, Qiao Li, and Yang Chai. In-sensor computing: Materials, devices, and integration technologies. *Advanced Materials*, 35(37):2203830, 2023. doi: 10.1002/adma.202203830. URL <https://doi.org/10.1002/adma.202203830>.
- [32] A. Melianas, T. J. Quill, G. LeCroy, Y. Tuchman, H. v. Loo, S. T. Keene, A. Giovannitti, H. R. Lee, I. P. Maria, I. McCulloch, and A. Salleo. Temperature-resilient solid-state organic artificial synapses for neuromorphic computing. *Science Advances*, 6:eabb2958, 2020. doi: 10.1126/sciadv.abb2958. URL <https://doi.org/10.1126/sciadv.abb2958>.
- [33] Ziyi Guo, Junyao Zhang, Ben Yang, Li Li, Xu Liu, Yutong Xu, Yue Wu, Pu Guo, Tongrui Sun, Shilei Dai, Haixia Liang, Jun Wang, Yidong Zou, Lize Xiong, and Jia Huang. Organic high-temperature synaptic phototransistors for energy-efficient neuromorphic computing. *Advanced Materials*, 36:2310155, 2024. doi: 10.1002/adma.202310155. URL <https://doi.org/10.1002/adma.202310155>.
- [34] Meriem Bettayeb, Yasmin Halawani, Muhammad Umair Khan, Hani Saleh, and Baker Mohammad. Efficient memristor accelerator for transformer self-attention functionality. *Scientific Reports*, 14(1):24173, 2024. doi: 10.1038/s41598-024-75021-z. URL <https://doi.org/10.1038/s41598-024-75021-z>.
- [35] Rui Qiu, Guoyun Gao, Zhiyuan Du, Ni Yang, Zefan Li, Dongsheng Zuo, Yunwei Tong, Peiyi He, Hangming Zhang, Hao Jiang, Lain-Jong Li, Han Wang, and Can Li. Monolithic 3d integration of MoS<sub>2</sub> eDRAM and RRAM for analog in-memory attention computing. In *2025 IEEE International Electron Devices Meeting (IEDM)*, pages 1–4, 2025. doi: 10.1109/IEDM50572.2025.11353844. URL <https://doi.org/10.1109/IEDM50572.2025.11353844>.
- [36] Md Zesun Ahmed Mia, Jiahui Duan, Kai Ni, and Abhronil Sengupta. Trilinear compute-in-memory architecture for energy-efficient transformer acceleration, 2026. URL <https://arxiv.org/abs/2604.07628>.
- [37] Zhenhua Liu, Yunhe Wang, Kai Han, Wei Zhang, Siwei Ma, and Wen Gao. Post-training quantization for vision transformer. In *Advances in Neural Information Processing Systems 34 (NeurIPS 2021)*, 2021. URL <https://proceedings.neurips.cc/paper/2021/hash/ec8956637a99787bd197eacd77acce5e-Abstract.html>.
- [38] Yanjing Li, Sheng Xu, Baochang Zhang, Xianbin Cao, Peng Gao, and Guodong Guo. Q-ViT: Accurate and fully quantized low-bit vision transformer. In *Advances*

- in *Neural Information Processing Systems 35 (NeurIPS 2022)*, 2022. URL <https://openreview.net/forum?id=fU-m9kQe0ke>.
- [39] Yang Lin, Tianyu Zhang, Peiqin Sun, Zheng Li, and Shuchang Zhou. FQ-ViT: Post-training quantization for fully quantized vision transformer. In *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence (IJCAI-22)*, pages 1173–1179, 2022. doi: 10.24963/ijcai.2022/164. URL <https://www.ijcai.org/proceedings/2022/164>.
- [40] Tomas Vincze, Michal Hanic, Martin Berki, and Martin Weis. Simultaneous dual-plasticity organic synaptic transistor for neuromorphic computing. *Advanced Electronic Materials*, 12(1):e00515, 2026. doi: 10.1002/aelm.202500515. URL <https://doi.org/10.1002/aelm.202500515>. Published online 2025-12-03.
- [41] Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman, Beidi Chen, and Xia Hu. KIVI: A tuning-free asymmetric 2bit quantization for KV cache. In *Proceedings of the 41st International Conference on Machine Learning (ICML 2024)*, volume 235 of *Proceedings of Machine Learning Research*. PMLR, 2024. URL <https://proceedings.mlr.press/v235/liu24bd.html>.
- [42] Guangxuan Xiao, Yuandong Tian, Beidi Chen, Song Han, and Mike Lewis. Efficient streaming language models with attention sinks. *arXiv preprint arXiv:2309.17453*, 2024. URL <https://arxiv.org/abs/2309.17453>.
- [43] Zhenyu Zhang, Ying Sheng, Tianyi Zhou, Tianlong Chen, Lianmin Zheng, Ruisi Cai, Zhao Song, Yuandong Tian, Christopher Ré, Clark Barrett, Zhangyang Wang, and Beidi Chen. H<sub>2</sub>O: Heavy-hitter oracle for efficient generative inference of large language models. *Advances in Neural Information Processing Systems*, 36, 2023. URL <https://arxiv.org/abs/2306.14022>.
- [44] Kwonsoo Lee, Minsoo Kim, Soojung Lee, Donghyun Lee, and Minsoo Rhu. Infinigen: Efficient generative inference of large language models with dynamic kv cache management. *arXiv preprint arXiv:2403.06504*, 2024. URL <https://arxiv.org/abs/2403.06504>.
- [45] Woosuk Kwon, Zhuohan Li, Siyuan Zhuang, Ying Sheng, Lianmin Zheng, Cody Yu, Joey Gonzalez, Hao Zhang, and Ion Stoica. Efficient memory management for large language model serving with PagedAttention. In *Proceedings of the 29th Symposium on Operating Systems Principles (SOSP 2023)*, pages 611–626, 2023. doi: 10.1145/3600006.3613165. URL <https://doi.org/10.1145/3600006.3613165>.

- [46] Tri Dao, Daniel Y. Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. Flashattention: Fast and memory-efficient exact attention with IO-awareness. *Advances in Neural Information Processing Systems*, 35:16344–16359, 2022. URL <https://arxiv.org/abs/2205.14135>.
- [47] Ran Huang, Yang Zhao, Yawen Zhang, Ru Huang, Jinfeng Kang, Zhengwu Liu, Mengze Li, and Xiangshui Miao. ReTransformer: RRAM-based in-memory transformer accelerator with dynamic sparse attention. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 2024. doi: 10.1109/TCAD.2024.3387774. URL <https://doi.org/10.1109/TCAD.2024.3387774>.
- [48] Joonho Cho, Jaehyeon Kang, Dongseok Kwon, and Jae-Joon Kim. X-Former: Hybrid XOR and SRAM in-memory computing architecture for transformer acceleration. *IEEE Transactions on Circuits and Systems I: Regular Papers*, 71(8):3562–3575, 2024. doi: 10.1109/TCSI.2024.3401234. URL <https://doi.org/10.1109/TCSI.2024.3401234>.
- [49] Peiyuan Zhang, Guangtao Zeng, Tianduo Wang, and Wei Lu. TinyLlama: An open-source small language model, 2024. URL <https://arxiv.org/abs/2401.02385>.
- [50] Hugo Touvron, Louis Martin, Kevin Stone, Peter Albert, Amjad Almahairi, Yasmine Babaei, Nikolay Bashlykov, Soumya Batra, Prajjwal Bhargava, Shruti Bhosale, et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023. URL <https://arxiv.org/abs/2307.09288>.
- [51] Stephen Merity, Caiming Xiong, James Bradbury, and Richard Socher. Pointer sentinel mixture models. *arXiv preprint arXiv:1609.07843*, 2016. URL <https://arxiv.org/abs/1609.07843>.
- [52] Yushi Bai, Xin Lv, Jiajie Zhang, Hongchang Lyu, Jiankai Tang, Zhidian Huang, Zhengxiao Du, Xiao Liu, Aohan Zeng, Lei Hou, Yuxiao Dong, Jie Tang, and Juanzi Li. LongBench: A bilingual, multitask benchmark for long context understanding. *arXiv preprint arXiv:2308.14508*, 2023. URL <https://arxiv.org/abs/2308.14508>.
- [53] Karl Cobbe, Vineet Kosaraju, Mohammad Bavarian, Mark Chen, Heewoo Jun, Lukasz Kaiser, Matthias Plappert, Jerry Tworek, Jacob Hilton, Reiichiro Nakano, Christopher Hesse, and John Schulman. Training verifiers to solve math word problems. *arXiv preprint arXiv:2110.14168*, 2021. URL <https://arxiv.org/abs/2110.14168>.
- [54] Lianmin Zheng, Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric Xing, Hao Zhang, Joseph E.

- Gonzalez, and Ion Stoica. Judging LLM-as-a-judge with MT-Bench and chatbot arena. *Advances in Neural Information Processing Systems*, 36, 2023. URL <https://arxiv.org/abs/2306.05685>.
- [55] Qing Dong, Mustafa E. Sinangil, Burak Erbagci, Daehyun Sun, Wei-Syun Khwa, Hung-Jen Liao, Yanzhi Wang, Jinjun Xiong, Ider Ganbaatar, Wen Song, and Naigang Wang. A 7-nm compute-in-memory SRAM macro supporting multi-bit input, weight and output and achieving 351 TOPS/W and 372.4 GOPS. *IEEE Journal of Solid-State Circuits*, 56(1):188–198, 2021. doi: 10.1109/JSSC.2020.3026495. URL <https://doi.org/10.1109/JSSC.2020.3026495>. Citation key updated from placeholder; original key was hastily2023.
- [56] Sandia National Laboratories. Crosssim: Sandia’s simulator for analog AI accelerators. Technical report, Sandia National Laboratories, 2024. URL <https://doi.org/10.2172/2585829>. Also cited as crosssim2024.